

**Федеральное государственное автономное образовательное учреждение
высшего образования
«РОССИЙСКИЙ УНИВЕРСИТЕТ ДРУЖБЫ НАРОДОВ ИМЕНИ
ПАТРИСА ЛУМУМБЫ»
(РУДН)**

Факультет искусственного интеллекта (ФИИ)

Основное учебное подразделение (ОУП)

Кафедра прикладного искусственного интеллекта

Выпускающее базовое учебное подразделение (БУП)

«ВКР ДОПУЩЕНА К ЗАЩИТЕ»

Заведующий кафедрой прикладного ИИ

Подолько П. М.

Фамилия И.О. заведующего кафедрой

Подпись

Дата

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА (ВКР)

02.04.02 Фундаментальная информатика и информационные технологии

Шифр и наименование направления подготовки/специальности

Управление данными и искусственный интеллект

Название образовательной программы (профиля/специализации)

*«Машинное зрение для управления процессом индукционной пайки
волноводных трактов космических аппаратов»*

Тема ВКР

ВЫПОЛНИЛ:

Фамилия И.О. обучающегося **Ильин А. В.**

Студенческий билет № **1132249438**

Группа **ЗФИмд-01-24**

РУКОВОДИТЕЛЬ ВКР:

Фамилия И.О. руководителя **Тынченко В. С.**

Ученая степень, ученое звание **доктор технических наук, доцент**

Должность **профессор**

Москва, 2026

ОГЛАВЛЕНИЕ

ГЛОССАРИЙ И ПЕРЕЧЕНЬ СОКРАЩЕНИЙ	4
Перечень сокращений и обозначений.....	4
Глоссарий.....	6
ВВЕДЕНИЕ	11
ГЛАВА 1. АНАЛИТИЧЕСКИЙ ОБЗОР И МЕТОДОЛОГИЯ ИССЛЕДОВАНИЯ	15
1.1. Технологический процесс индукционной пайки волноводных трактов	15
1.2. Визуальные стадии процесса пайки и признаки их различия	17
1.3. Существующие подходы к управлению процессом индукционной пайки.....	19
1.4. Возможности компьютерного зрения в задаче контроля пайки	22
1.5. Постановка задачи машинного зрения для определения стадии пайки	25
1.5.1. Задача классификации стадии процесса	26
1.5.2. Задача обнаружения события начала активной пайки.....	28
1.5.3. Требования к качеству и времени обработки	30
1.5.4. Ограничения постановки задачи	32
1.6. Выводы.....	33
ГЛАВА 2. АРХИТЕКТУРА И РЕАЛИЗАЦИЯ МОДУЛЯ МАШИННОГО ЗРЕНИЯ.....	35
2.1. Общая архитектура разрабатываемой системы	35
2.2. Подготовка видеоданных и разметки	39
2.3. Выбор и использование области интереса	44
2.4. Базовый подход на основе OpenCV-признаков	47
2.5. Нейросетевая модель классификации стадий	52
2.6. Алгоритм стабилизации стадии на основе конечного автомата	57
2.7. Триггер начала активной пайки.....	62
2.8. Реализация прототипа и структура репозитория	66
2.9. Выводы.....	71
ГЛАВА 3. ЭКСПЕРИМЕНТАЛЬНАЯ ОЦЕНКА МОДЕЛИ И ПРОТОТИПА	73
3.1. Экспериментальный стенд и протокол оценки.....	73
3.2. Оценка базового OpenCV-подхода	77
3.3. Оценка нейросетевого baseline на 3 FPS.....	80
3.4. Финальная нейросетевая классификация стадий на 10 FPS	82
3.5. Оценка алгоритма стабилизации стадий	86
3.6. Оценка триггера начала активной пайки.....	90
3.7. Демонстрация работы финальной системы.....	93
3.8. Оценка задержки обработки кадра.....	97

3.9. Оптимизация моделей для запуска на центральном процессоре	100
3.10. Ограничения эксперимента и анализ сложных случаев	108
3.11. Выводы.....	111
ЗАКЛЮЧЕНИЕ.....	115
СПИСОК ЛИТЕРАТУРЫ	119
ПРИЛОЖЕНИЕ А. СТРУКТУРА РЕПОЗИТОРИЯ ПРОЕКТА	124
ПРИЛОЖЕНИЕ Б. КОМАНДЫ ЗАПУСКА ПРОГРАММНОГО ПРОТОТИПА	125
Б.1. Получение информации о видеозаписи.....	125
Б.2. Создание шаблона интервальной разметки	125
Б.3. Формирование временной сетки для одного видео	125
Б.4. Формирование временных сеток для набора видео	126
Б.5. Извлечение кадров и формирование покадровой разметки	126
Б.6. Разбиение датасета на train, val и test	127
Б.7. Расчёт OpenCV-признаков.....	127
Б.8. Запуск демонстрационного видео с нейросетевой моделью.....	128
Б.9. Запуск демонстрационного видео с OpenCV-триггером.....	129
Б.10. Измерение задержки обработки кадра	129
ПРИЛОЖЕНИЕ В. ДОПОЛНИТЕЛЬНЫЕ ЭКСПЕРИМЕНТАЛЬНЫЕ АРТЕФАКТЫ....	131
В.1. Структура и распределение данных в сформированном датасете	131
В.2. Анализ области интереса при обработке видеокадров.....	132
В.3. Анализ признаков и ошибок базового OpenCV-подхода.....	133
В.4. Временной анализ предсказаний нейросетевого baseline	134
В.5. Подбор параметров конечного автомата	134
В.6. Подбор параметров триггера начала активной пайки	135
В.7. Дополнительные результаты оптимизации моделей	135

ГЛОССАРИЙ И ПЕРЕЧЕНЬ СОКРАЩЕНИЙ

Перечень сокращений и обозначений

ВКР	выпускная квалификационная работа.
ИИ	искусственный интеллект.
Accuracy	доля правильно классифицированных кадров среди всех кадров выборки.
AdamW	вариант оптимизатора Adam с отделённой регуляризацией весов.
CNN	свёрточная нейронная сеть (Convolutional Neural Network).
CPU	центральный процессор (Central Processing Unit).
CPU-friendly	модель или режим работы, ориентированные на выполнение на центральном процессоре с учётом ограничения задержки обработки кадра.
CUDA	программно-аппаратная платформа NVIDIA для параллельных вычислений на GPU.
CV	компьютерное зрение (Computer Vision).
F1-score	гармоническое среднее precision и recall; рассчитывается поклассово.
FPS	кадры в секунду (Frames Per Second); частота извлечения кадров из видеозаписи.
GPU	графический процессор (Graphics Processing Unit).

macro-F1	среднее F1-score по классам без учёта числа кадров каждого класса.
MAE	средняя абсолютная ошибка (Mean Absolute Error).
MobileNetV3 Small	компактная свёрточная архитектура для быстрого инференса на устройствах с ограниченными ресурсами.
NAS-like	подход, близкий к поиску нейросетевой архитектуры; используется для обозначения эволюционного подбора классификационной головы MobileNetV3 Small.
ONNX	открытый формат представления нейросетевых моделей.
OpenCV	открытая библиотека компьютерного зрения и обработки изображений.
p95	95-й перцентиль распределения; при измерении задержки — устойчивая верхняя оценка задержки одного кадра.
precision	точность; доля верных положительных решений среди всех положительных решений модели.
PyTorch	фреймворк глубокого обучения.
recall	полнота; доля найденных объектов класса относительно их общего числа в выборке.
ResNet18	свёрточная нейронная сеть из семейства Residual Networks с 18 слоями.

ROI область интереса (Region of Interest); прямоугольный участок кадра, содержащий волновод, флюс, припой и шов.

weighted-F1 среднее значение F1-score по классам с весами, пропорциональными числу кадров в каждом классе.

Глоссарий

Активация флюса стадия, на которой флюс выходит на рабочую температуру: становится прозрачнее, снимает оксиды, готовит поверхность к смачиванию припоем.

Активная пайка стадия процесса индукционной пайки, в которой припой плавится и заполняет шов; к её началу привязан сигнал «active_brazing_started».

Видеопоток последовательность кадров с камеры или из файла записи пайки, поступающая в модуль машинного зрения.

Волноводный тракт радиотехнический элемент передачи электромагнитных волн; в работе — тракты космических аппаратов, элементы которых соединены пайкой.

Датасет структурированный набор данных для обучения, валидации и тестирования; в работе состоит из кадров видеозаписей пайки и соответствующих меток стадий.

Индукционная пайка	соединение деталей припоем при локальном нагреве зоны шва электромагнитной индукцией.
Инференс	применение обученной модели к новым входным данным.
Покадровая классификация	отнесение каждого кадра к стадии независимо от соседних кадров, без существенного учёта временной истории.
Классификационная голова	верхняя часть нейросетевой модели, которая преобразует признаки, извлечённые backbone, в вероятности классов.
Классификатор стадий пайки	модель машинного обучения, которая принимает ROI-кадр и возвращает распределение вероятностей по четырём стадиям процесса пайки.
Классическая модель машинного обучения	ML-алгоритм, не относящийся к глубокому обучению; в работе — Logistic Regression, Random Forest и Gradient Boosting на OpenCV-признаках.
Компьютерное зрение	направление ИИ, связанное с автоматическим анализом кадров и видеопоследовательностей средствами обработки изображений и моделей машинного обучения.
Конечный автомат стадий пайки	алгоритм постобработки; допускает переходы только в направлении, разрешённом технологическим порядком стадий.
Ложное раннее срабатывание	событие «active_brazing_started» формируется раньше размеченного начала стадии

«active_brazing».

Машинное зрение	прикладное направление компьютерного зрения для инженерных, производственных и технологических задач.
Нейросетевой классификатор	глубокая нейронная сеть; извлекает признаки ROI-кадра и относит его к одной из четырёх стадий.
Область интереса	прямоугольный фрагмент кадра, содержащий волновод, зону шва, флюс и припой; остальная область исключается из обработки.
Операторская стадия	стабилизированная предсказанная стадия процесса после применения конечного автомата.
Пайка	соединение материалов через припой; основной материал деталей при этом остаётся в твёрдой фазе.
Плавление припоя	переход припоя в жидкое или полужидкое состояние; ключевой визуальный признак стадии «active_brazing».
Постобработка предсказаний	преобразование выхода модели для временной устойчивости и согласованности с технологическим порядком стадий.
Припой	материал для формирования паяного соединения; при нагреве плавится, смачивает поверхности и заполняет зазор между деталями.
Рекомендательный сигнал	сигнал от прототипа для оператора или управляющего контура; в прототипе — «Hold Temperature», формирующийся после

«active_brazing_started».

Стабилизация	стадия после активной пайки; плавление и протекание припоя завершились, шов выдерживается в достигнутом режиме.
Стадия пайки	выделенный шаг технологического процесса; имеет собственный набор визуальных признаков в кадре.
Сырой прогноз модели	покадровое предсказание нейросетевой модели до временного сглаживания и применения конечного автомата.
Тестовая выборка	часть датасета, отделённая от обучения и валидации; используется для финальной оценки качества.
Триггер начала активной пайки	алгоритм, формирующий событие «active_brazing_started» при устойчивых признаках плавления и протекания припоя.
Флюс	вспомогательное вещество; снимает оксидные плёнки, улучшает смачивание и облегчает растекание припоя по шву.
Backbone	основная свёрточная часть нейросетевой модели, извлекающая признаки изображения.
Frame-level разметка	покадровая разметка; каждому кадру сопоставляется стадия процесса.
Checkpoint	сохранённое состояние обученной модели, включающее веса модели и параметры.

Fine-tuning	дообучение модели на данных конкретной задачи.
Hard-case видео	видеозапись со сложными визуальными условиями (засветы, плохая видимость флюса, нетипичное поведение припоя); такие записи используются для анализа пределов применимости системы и отделяются от штатной оценки.
Latency benchmark	измерение задержки полного цикла обработки кадра: чтения, выделения ROI, предобработки, инференса модели, работы триггеров и постобработки.
OpenCV baseline	базовая линия на явно заданных CV-признаках; точка отсчёта для сравнения с нейросетевыми моделями.
OpenCV-триггер	триггер начала активной пайки, построенный на классических признаках компьютерного зрения.
Stable Stage	стабилизированная стадия на выходе конечного автомата; формируется из сырых предсказаний модели с учётом технологического порядка.

ВВЕДЕНИЕ

Космические аппараты связи и радиотехнические системы требуют высокого качества волноводных трактов. Через волноводные элементы передаётся электромагнитная энергия, и их характеристики должны оставаться стабильными весь срок эксплуатации. При изготовлении таких изделий волноводные элементы соединяют пайкой. Качество паяного шва зависит сразу от нескольких факторов — температурного режима, состояния флюса, момента плавления припоя, равномерности его растекания и последующей выдержки. [1] [2]

Индукционная пайка концентрирует тепло в зоне соединения за счёт электромагнитной индукции, что определяет её прикладное значение. Диапазон допустимого нагрева является ограниченным: при недогреве припой не расплавится полностью и в шве остаются дефекты, при перегреве деформируются элементы и нарушается геометрия волноводного тракта. Поэтому момент начала активной пайки и текущая стадия процесса важны технологически. [3] [4]

Контроль установки индукционной пайки традиционно основывается на трёх компонентах: показаниях термопары или пирометра, программе мощности индуктора и опыте оператора. Условия нагрева такая схема достаточно полно характеризует. Однако локального состояния флюса и припоя в зоне шва она не отражает и момент начала плавления не фиксирует. [5] [6] [7]

Значительная часть информации о ходе процесса проявляется визуально. Флюс меняет прозрачность, по поверхности расходятся блики, текстура поверхности изменяется, припой деформируется и начинает протекать в шов. Видеозапись зоны пайки фиксирует все эти признаки — их совокупность и образует отдельный канал контроля. [6] [7]

В работе видеоканал не заменяет термодатчик, а дополняет его оценкой фактического состояния зоны соединения. На основе этой оценки

формируется рекомендательный сигнал о начале активной пайки. [6] [7]

Актуальность работы связана с тем, что для индукционной пайки волноводных трактов отсутствует инженерно простое средство визуального контроля, способное в режиме, близком к реальному времени, определять стадию процесса и формировать сигнал о начале активной пайки. [8] [9]

В работе рассматривается задача анализа видеозаписей процесса индукционной пайки волноводных трактов. Процесс описан как последовательность четырёх визуально различимых стадий: подготовка и предварительный нагрев, активация флюса, активная пайка и стабилизация. Отдельно выделено событие начала активной пайки, связанное с плавлением и протеканием припоя; именно оно используется как основа рекомендательного сигнала прототипа.

Цель выпускной квалификационной работы — обеспечение высокой эффективности процесса индукционной пайки волноводных трактов космических аппаратов за счёт повышения точности определения этапов технологического процесса на основе видеoinформации из зоны пайки.

Для достижения поставленной цели необходимо решить следующие задачи:

1. Проанализировать технологический процесс индукционной пайки волноводных трактов и выделить визуально различимые стадии процесса.
2. Сформировать размеченный видеодатасет процесса пайки, выполнить преобразование интервальной разметки в покадровую выборку и определить область интереса для анализа зоны пайки.
3. Реализовать и исследовать базовый подход на основе классических методов компьютерного зрения и машинного обучения.
4. Разработать нейросетевую модель классификации стадий пайки по изображениям области интереса.
5. Реализовать алгоритм стабилизации предсказаний стадий с учётом

технологически допустимой последовательности процесса.

6. Разработать триггер начала активной пайки и оценить точность его срабатывания по времени.
7. Провести экспериментальную оценку качества моделей, задержки обработки кадра и возможности применения системы в режиме, близком к реальному времени.
8. Исследовать облегчённые варианты моделей для запуска на центральном процессоре и оценить возможность выполнения ограничения по времени обработки кадра.

Объектом исследования является процесс индукционной пайки волноводных трактов космических аппаратов.

Предметом исследования являются методы компьютерного зрения и машинного обучения для определения визуальных стадий индукционной пайки и обнаружения события начала активной пайки по видеопотоку зоны пайки.

Применяемые методы — цифровая обработка изображений, классическое компьютерное зрение, машинное обучение и глубокое обучение. Базовый подход опирается на признаки яркости, цвета, бликов, текстуры, границ и межкадрового изменения. Нейросетевой подход построен на свёрточных архитектурах ResNet18 и MobileNetV3 Small. Для постобработки покадровых предсказаний используется конечный автомат с допустимой технологической последовательностью стадий. Для оценки используется набор метрик: accuracy, macro-F1, weighted-F1, precision, recall, F1-score, абсолютная ошибка времени срабатывания триггера и показатели задержки обработки кадра. [10] [11] [12] [13] [14] [15]

Научная новизна работы заключается в разработке модели определения этапов технологического процесса индукционной пайки волноводных трактов космических аппаратов, построенной на основе свёрточных искусственных нейронных сетей и позволяющей использовать

видеоинформацию из зоны пайки для реализации процесса управления в автоматизированной системе.

На защиту выносится следующее положение: разработанная модель определения этапов технологического процесса индукционной пайки волноводных трактов космических аппаратов позволяет идентифицировать этапы активации флюса и плавления припоя по видеоинформации из зоны пайки с покласовым F1-score 87,66 % и 83,33 % соответственно для штатных видеозаписей процесса.

Практическая значимость работы состоит в создании воспроизводимого исследовательского прототипа. По видеопотоку зоны пайки он формирует устойчивую операторскую стадию и рекомендательный сигнал начала активной пайки.

В ходе работы собран датасет видеок кадров процесса индукционной пайки, сравнены классический и нейросетевой подходы, разработана логика стабилизации стадий, реализован триггер начала активной пайки, подготовлены демонстрационные видеоролики и измерена задержка обработки кадра. Дополнительно исследованы варианты моделей для запуска на центральном процессоре: ResNet18 с уменьшенным входным разрешением и MobileNetV3 Small после эволюционного подбора гиперпараметров и конфигурации классификационной головы. [15] [16]

Работа состоит из введения, трёх глав, заключения, списка использованных источников и приложений. В первой главе рассматриваются технологические особенности индукционной пайки, визуальные признаки процесса и постановка задачи машинного зрения. Во второй главе описываются архитектура разработанного решения, подготовка данных, модели, алгоритм стабилизации стадий и триггер начала активной пайки. В третьей главе приводятся результаты экспериментов, сравнение подходов, анализ задержки, оптимизация моделей для запуска на центральном процессоре и демонстрация работы прототипа.

ГЛАВА 1. АНАЛИТИЧЕСКИЙ ОБЗОР И МЕТОДОЛОГИЯ ИССЛЕДОВАНИЯ

1.1. Технологический процесс индукционной пайки волноводных трактов

Волноводные тракты являются важными элементами радиотехнических систем космических аппаратов, обеспечивающими передачу электромагнитной энергии между функциональными узлами аппаратуры. К таким изделиям предъявляются повышенные требования по геометрической точности, стабильности электродинамических характеристик и надёжности соединений. Нарушение геометрии волноводного тракта, наличие дефектов соединения или изменение формы элементов в зоне пайки могут привести к ухудшению параметров передачи сигнала и снижению эксплуатационной надёжности изделия. [1] [2]

Одним из технологических способов соединения элементов волноводных трактов является пайка. В отличие от сварки, пайка предполагает соединение деталей припоем, температура плавления которого ниже, чем у основного материала. При нагреве припой переходит в расплавленное состояние, смачивает соединяемые поверхности и заполняет технологический зазор. После охлаждения формируется паяное соединение, обеспечивающее механическую фиксацию и электрическую непрерывность конструкции. [4] [17]

Индукционная пайка основана на локальном нагреве зоны соединения электромагнитной индукцией. Тепловое воздействие концентрируется в зоне соединения, общее воздействие на изделие снижается, а разогрев соединяемых элементов остаётся управляемым. Для волноводных трактов это критично: избыточный нагрев деформирует деталь, искажает форму шва и выводит её за технологические допуски. [3] [4]

Процесс включает несколько связанных физических и технологических явлений. На первом этапе происходит предварительный нагрев зоны соединения: припой ещё не плавится, но детали, флюс и припой постепенно

прогреваются. Затем — активация флюса: он снимает оксидные плёнки, улучшает смачивание и подготавливает поверхность к растеканию припоя. По мере нагрева флюс становится прозрачнее, меняется блеск и микроструктура поверхности шва. [4] [6]

После активации флюса начинается активная пайка: припой плавится, смачивает поверхности и протекает в технологический зазор. С технологической точки зрения именно здесь формируется соединение и именно здесь критичен баланс — при недогреве шов не заполнится, при перегреве деформируется волноводный тракт. [4] [6]

Завершающим этапом является стабилизация. Активное плавление и протекание припоя уже закончены, шов выдерживается в достигнутом режиме. Недостаточная выдержка увеличивает риск дефектов: незаполнения шва, неравномерного растекания припоя, нарушения охлаждения.

В видеокадре пайка выглядит как последовательность визуальных событий: флюс просветляется, по поверхности расходятся блики, меняется её текстура, припой деформируется, начинает растекаться и затем выравнивается. Такой анализ не является измерением температуры; однако представляет собой дополнительный, независимый от термодатчика источник информации о фактическом состоянии шва. [6] [8]

При выполнении настоящей работы технологический процесс был представлен в виде четырёх визуально различимых стадий:

- «inactive_preparation» — подготовка и предварительный нагрев;
- «flux_activation» — активация флюса;
- «active_brazing» — активная пайка, плавление и протекание припоя;
- «stabilization» — стабилизация после активной пайки.

Это инженерная формализация для задачи машинного зрения, а не строгая физико-технологическая модель пайки. Непрерывный видеопоток позволяет сформулировать две связанные задачи: покадровая классификация по четырём стадиям и обнаружение момента начала активной пайки.

Технологически центральная стадия — «active_brazing»: на ней начинаются плавление и протекание припоя. Этот момент оператор или управляющий контур могут рассматривать как основание зафиксировать температуру или перейти к следующей фазе контроля. Поэтому наряду с задачей определения стадии выделяется отдельная задача — формирование события «active_brazing_started».

Индукционная пайка волноводных трактов зависит как от температурных параметров, так и от наблюдаемого визуально состояния флюса и припоя. Это обосновывает применение машинного зрения: видеопоток зоны пайки добавляет независимый от термодатчика канал контроля. [5] [6] [7]

1.2. Визуальные стадии процесса пайки и признаки их различения

Для применения методов машинного зрения технологический процесс индукционной пайки необходимо представить в виде набора наблюдаемых состояний, которые могут быть различены по видеокадрам. В реальном процессе переходы между состояниями являются непрерывными: температура изменяется постепенно, флюс и припой проходят промежуточные состояния, а визуальные признаки могут проявляться не мгновенно. Поэтому в работе стадии пайки рассматриваются как инженерная дискретизация непрерывного технологического процесса, удобная для построения модели классификации и последующей логики контроля. [4] [10]

Первая стадия — «inactive_preparation», подготовительный нагрев. Видимых изменений ещё нет: припой не растекается, флюс не демонстрирует признаков активации, кадр почти статичен. Для модели это базовое состояние, относительно которого будут оцениваться визуальные изменения.

Вторая стадия — «flux_activation». Флюс выходит на рабочий температурный режим, снимает оксиды и готовит поверхность к растеканию припоя. В кадре наблюдается несколько признаков: флюс просветляется, появляются локальные блики, изменяются текстура и яркость поверхности

шва. Сам припой при этом ещё может не плавиться явно.

Третья стадия — «active_brazing». Это наиболее значимая стадия с точки зрения управления: припой плавится, меняет форму, смачивает поверхности и заполняет зону шва. В кадре стадия проявляется через блики расплава и локальное движение материала. С её началом формируется рекомендательный сигнал фиксации температуры.

Четвёртая стадия — «stabilization», выдержка после активной пайки. Динамика в зоне шва спадает, поверхность выходит на устойчивое состояние; выполняется выдержка и завершается формирование шва. В классификаторе это финальный класс, отделяющий активное протекание припоя от устойчивого состояния зоны пайки.

Технологические стадии, визуальные признаки и классы машинного обучения сведены в таблицу 1.1. [4] [6]

Таблица 1.1 — Визуальные стадии процесса индукционной пайки

Стадия	Технологический смысл	Визуальные признаки	Класс модели
Подготовка и предварительный нагрев	Нагрев зоны пайки до выраженных изменений флюса и припоя	Относительно стабильная зона пайки, отсутствие явного протекания припоя, слабые изменения яркости и текстуры	inactive_preparation
Активация флюса	Изменение состояния флюса, подготовка поверхности к смачиванию и растеканию припоя	Изменение прозрачности флюса, появление бликов, изменение текстуры и яркости поверхности	flux_activation
Активная пайка	Плавление и протекание припоя, смачивание поверхности, заполнение зоны шва	Деформация припоя, движение или растекание материала, выраженные блики расплава, локальные изменения формы	active_brazing
Стабилизация	Завершение активной пайки, выдержка или фиксация состояния соединения	Уменьшение динамики изменений, стабилизация внешнего вида зоны пайки, отсутствие нового активного протекания	stabilization

Визуальное разделение стадий не всегда однозначно. Границы размываются из-за непрерывного нагрева, особенностей освещения, геометрии тракта, отражательной способности поверхности и нестабильной видимости флюса. Так, изменение блика или прозрачности флюса похоже на начало активной пайки, когда припой ещё не протекает. И наоборот: первые признаки деформации припоя проявляются иногда раньше размеченного начала стадии «active_brazing». [6]

Поэтому задача не сводится к покадровой классификации. Дополнительно к классификатору используются два компонента: конечный автомат стадий и событийный триггер начала активной пайки. Автомат ограничивает последовательность стадий допустимым технологическим порядком; триггер «active_brazing_started» отдельно оценивает момент начала активной пайки — по вероятности класса «active_brazing» и/или по классическим визуальным признакам.

Выделенные четыре стадии обеспечивают формализацию процесса для методов машинного зрения. Такая дискретизация позволяет построить размеченный датасет, обучить модели классификации стадий и разработать дополнительную логику формирования сигнала о начале активной пайки. Неоднозначность визуальных границ между стадиями учитывается в дальнейших разделах — через анализ ошибок, выделение сложных видеозаписей и постобработку предсказаний модели.

1.3. Существующие подходы к управлению процессом индукционной пайки

Контроль индукционной пайки традиционно основан на поддержании температурного режима: качество шва зависит от корректного нагрева и выдержки. Поэтому промышленные установки сосредоточены на измерении температуры, мощности источника, параметрах индуктора и обратной связи. [18] [19]

Основной управляющий параметр — мощность индуктора. Она задаёт

интенсивность электромагнитного поля и скорость нагрева зоны пайки. Режим задаётся либо программно, либо по обратной связи от термодатчика. В простой схеме оператор смотрит на приборы и зону пайки сам; в автоматизированной мощность корректируется системой управления по сигналам датчиков. [18] [19]

На практике температуру часто измеряют бесконтактно, пирометрией. На тонких или ответственных деталях это удобнее термопар: термопара меняет тепловой режим, иногда искажает геометрию шва или повреждает деталь. Если контактное воздействие на конструкцию нежелательно, бесконтактный канал является предпочтительным. [5] [7]

Температурная телеметрия не описывает полностью состояние. Измеряемая температура зависит от точки контроля, угла наблюдения, эмиссии и кривизны поверхности, отражательных свойств материала и его текущего состояния. К тому же одна точка не описывает локальные процессы — активацию флюса, смачивание, плавление и протекание припоя. Достижение заданной температуры ещё не гарантирует, что нужные физико-химические процессы в шве прошли корректно. [6] [7]

Программно-аппаратные системы управления удерживают целевой температурный профиль, время выдержки и предельную скорость нагрева. Процесс воспроизводится стабильнее, влияние человеческого фактора снижается. Но температурный контур характеризует тепловой режим, а не фактическое состояние зоны шва. Флюс может переходить в активное состояние раньше или позже расчётного момента, припой деформируется и начинает протекать со сдвигом по температуре. Поэтому даже автоматическому контролю нужно знать, попадает ли фактическая визуальная картина в зоне пайки в ожидаемую стадию. [18] [19] [20]

Ручной визуальный контроль остаётся традиционной практикой. Оператор отслеживает состояние флюса, появление блеска, изменение формы припоя, начало растекания и завершение активной фазы. Оценка является субъективной и зависит от опыта специалиста, освещения, качества

видеонаблюдения и темпа процесса. При требуемых задержках порядка десятков миллисекунд оператор не способен обеспечить своевременную реакцию: оперативный управляющий сигнал приходится снимать с другого источника.

Видеоканал обеспечивает независимое наблюдение за зоной пайки. Термодатчик предоставляет косвенную информацию о тепловом режиме, камера — визуальные изменения в зоне соединения. Алгоритмы компьютерного зрения извлекают признаки состояния флюса и припоя, относят кадр к одной из стадий и формируют событие начала активной пайки.

Существующие подходы к контролю процесса индукционной пайки можно разделить на несколько групп:

1. Программное управление режимом нагрева.

Процесс ведётся по заранее заданному температурно-временному профилю или режиму мощности. Такой подход прост в реализации, но индивидуальные особенности конкретной детали, локальные изменения флюса и припоя и вариации условий пайки в ней почти не учитываются.

2. Управление по температурной обратной связи.

Температуру измеряют прямо в зоне пайки или рядом и по обратной связи правят режим нагрева. Основные ограничения: точность датчика, выбор контролируемой точки, отражательные свойства поверхности, условия наблюдения.

3. Визуальный контроль оператором.

Оператор оценивает зону пайки по изображению или прямому наблюдению. Учёт визуальных признаков является преимуществом, субъективность и плохая формализуемость для автоматического управления — ограничением.

4. Интеллектуальный визуальный контроль.

Видеопоток анализируется алгоритмами компьютерного зрения и машинного обучения. Стадии процесса определяются автоматически, момент начала активной пайки — отдельно, дополнительный сигнал передаётся

оператору или управляющей системе.

В работе развивается именно четвёртый подход. Модуль машинного зрения анализирует видеопоток зоны пайки, определяет стадию процесса и формирует событие «active_brazing_started». Температурный контур управления он не вытесняет — его роль заключается в дополнении визуальной информацией о фактическом состоянии флюса и припоя.

С инженерной точки зрения такое разделение является обоснованным. Температурный контур отвечает на вопрос о тепловом состоянии, видеомодуль — о картине в зоне шва. Два канала вместе повышают надёжность контроля: температура характеризует условия нагрева, видео — фактические признаки активации флюса, плавления и протекания припоя.

Для автоматического управления существенна задержка обработки. Если визуальный модуль формирует сигнал о начале активной пайки, кадр должен обрабатываться в близком к реальному времени режиме. Поэтому в работе принято целевое ограничение задержки — не более 50 мс на кадр. Требование обусловлено тем, что рекомендательный сигнал фиксации температуры должен формироваться вовремя после обнаружения начала активной пайки. [16]

На текущий момент контроль индукционной пайки строится на температурных параметрах, программных режимах нагрева и опыте оператора. Машинное зрение дополняет эти средства контроля: автоматически анализирует визуальное состояние зоны пайки и закладывает основу интеллектуального модуля — определение стадии и сигнал о начале активной пайки по видеоданным.

1.4. Возможности компьютерного зрения в задаче контроля пайки

Компьютерное зрение — это автоматическое извлечение информации из изображений и видеопоследовательностей. На производстве его применяют для решения четырёх групп задач: контроль качества изделий, поиск дефектов, отслеживание положения объектов и поддержка решений оператора. На

индукционной пайке видеоканал ценен тем, что заметная доля информации о флюсе, припое и зоне шва проявляется в визуальных признаках. [10] [8]

Видеоканал фиксирует прямые изменения материалов в зоне соединения: прозрачность флюса, блики, деформацию припоя, сдвиг текстуры и факт протекания припоя в шов.

Анализ пайки через компьютерное зрение можно рассматривать на нескольких уровнях. Первый уровень анализа — явные числовые признаки кадра: яркость, цвет, доли светлого и бликового, плотность границ, текстурность, межкадровая разница. Эти признаки рассчитываются стандартными методами обработки изображений и используются либо в правилах, либо в классическом классификаторе. Каждый признак имеет физическую интерпретацию: блики растут с расплавом, межкадровая разница — с движением и деформацией материала. [10] [14]

Следующий уровень анализа — применение нейросетевой модели. Свёрточная архитектура учитывает не только яркость и цвет, но и пространственный рисунок: форму зоны шва, расположение бликов, контуры и их динамику. На таком уровне абстракции стадии разделяются там, где двух скалярных признаков уже не хватает. [11] [12]

Следующий уровень — временная структура. Стадии следуют в фиксированном порядке, а покадровая классификация без учета временного контекста может реагировать на шум: одиночный блик, скачок освещения или нестабильный флюс приводит к ошибочному отнесению кадра к соседнему классу. Чтобы перейти от потока решений к устойчивому представлению, нужен слой с правилами последовательности и подтверждением перехода. Этот слой — конечный автомат; из сырого покадрового потока он формирует стабилизированную стадию «Stable Stage».

Отдельной задачей является обнаружение не стадии, а значимого события. На индукционной пайке это начало активной пайки: момент, когда припой начинает плавиться и протекать. Событийная постановка отличается от покадровой классификации; интересна не точная метка каждого кадра, а

минимальная ошибка по времени относительно размеченного начала. Поэтому событийный модуль оценивается не только метриками классификации, но и временной ошибкой первого устойчивого срабатывания.

Возможности компьютерного зрения в этой задаче можно представить в виде нескольких функций:

1. Выделение области интереса.

Из полного кадра выбирается зона, содержащая волновод, флюс, припой и область шва. Это снижает влияние фона, оснастки, неизменяемых частей кадра и уменьшает вычислительную нагрузку.

2. Расчёт объяснимых визуальных признаков.

По изображению области интереса считаются признаки яркости, цвета, бликов, границ, текстуры и межкадрового изменения. На них собирается базовый подход; они позволяют оценить, какие визуальные характеристики связаны с какой стадией пайки.

3. Классификация стадии процесса.

Нейросетевая модель определяет текущую стадию по ROI-кадру. В работе таких стадий четыре: подготовка и предварительный нагрев, активация флюса, активная пайка и стабилизация.

4. Стабилизация результата во времени.

Стадии идут в фиксированном порядке, поэтому покадровый поток предсказаний обрабатывается конечным автоматом. Он подавляет обратные переходы и формирует из сырых ответов устойчивую операторскую стадию.

5. Формирование триггера начала активной пайки.

Сигнал «active_brazing_started» формируется двумя способами: по вероятности класса «active_brazing» или по классическим OpenCV-признакам. Для оператора он интерпретируется как рекомендация зафиксировать температуру или перейти к следующей фазе контроля. [10] [8] [9]

У применения компьютерного зрения на пайке есть свои ограничения. Качество анализа зависит от стабильности освещения, положения камеры, видимости зоны шва, отражательной способности поверхности и наличия

засветов. Видеоканал также фиксирует неоднозначные изменения: смена блика или прозрачности флюса похожа на начало активной пайки, когда устойчивого протекания припоя ещё нет. Поэтому видеомодуль рассматривается не как самостоятельный источник истины, а как дополнительный канал — с обязательной технологической интерпретацией и временной стабилизацией. [8] [9]

Для повышения надёжности визуального анализа в работе совмещены несколько уровней. OpenCV-признаки используются как объяснимая базовая линия и как резервный триггер начала активной пайки. Нейросетевая модель отвечает за основную классификацию стадий. Конечный автомат согласует её результат с технологически допустимой последовательностью. Отдельный событийный триггер выделяет момент начала активной пайки как самостоятельное управляющее событие.

Компьютерное зрение предоставляет инструменты автоматического анализа состояния зоны индукционной пайки — и текущей стадии, и момента начала активной пайки. В связке с температурным контролем такой канал повышает информативность наблюдения и закладывает основу для развития систем поддержки управления пайкой.

1.5. Постановка задачи машинного зрения для определения стадии пайки

После разбора технологии индукционной пайки и визуальных признаков в зоне соединения задача работы формулируется как задача машинного зрения для анализа видеопотока процесса пайки. Если классический температурный контроль ориентирован на параметры нагрева, то здесь акцент на автоматическом извлечении информации из изображения — на состоянии флюса, внешнем виде припоя, сдвиге текстуры поверхности, появлении бликов и локальной динамике в области шва.

Вход системы — видеопоследовательность процесса индукционной пайки. Помимо зоны пайки, кадр содержит фон, элементы оснастки, неизменяемые части детали и другие участки без полезной информации о ходе

процесса. Поэтому на первом шаге из кадра выделяется область интереса: зона соединения, флюс, припой и прилегающие участки волноводного тракта. Далее с выделенной областью работают и классические алгоритмы, и нейросетевые модели. [10]

В общем виде обработка видеопотока может быть представлена как последовательность преобразований, изображенных на рисунке 1.1:




Рисунок 1.1 — Общая последовательность обработки видеопотока в модуле машинного зрения

В работе рассматриваются две связанные задачи. Первая — определение текущей стадии процесса по кадру или короткой последовательности кадров. Вторая — обнаружение события начала активной пайки, то есть момента, когда припой начинает плавиться, деформироваться и протекать в шов. Эти задачи связаны между собой, но различаются по постановке: классификатор отвечает на вопрос «в каком состоянии находится процесс», триггер — на вопрос «наступил ли конкретный технологически значимый момент».

1.5.1. Задача классификации стадии процесса

Основная задача машинного зрения в этой работе формулируется как задача многоклассовой классификации кадров области интереса. Для каждого кадра видеопотока после выделения области интереса требуется определить одну из четырёх стадий процесса: [11] [12]

- «inactive_preparation» — подготовка и предварительный нагрев;
- «flux_activation» — активация флюса;
- «active_brazing» — активная пайка;

- «stabilization» — стабилизация после активной пайки.

Пусть видеопоследовательность процесса пайки представлена набором кадров:

$$X = \{x_1, x_2, \dots, x_n\}$$

где x_i — i -й кадр видеопотока, а n — общее количество кадров в видеозаписи. Для каждого кадра выделяется область интереса:

$$r_i = ROI(x_i)$$

где ROI — операция выделения заранее заданной области кадра, содержащей зону пайки. Тогда задача классификации стадии может быть представлена как построение отображения:

$$f(r_i) \rightarrow y_i$$

где y_i принадлежит множеству классов:

$$Y = \{0, 1, 2, 3\}.$$

Соответствие классов стадиям задаётся следующим образом:

0 — «inactive_preparation»;

1 — «flux_activation»;

2 — «active_brazing»;

3 — «stabilization».

На практике функция отображения f задаётся моделью машинного обучения. Рассмотрено два класса подходов: классические методы компьютерного зрения с последующей классификацией на основе извлечённых признаков и нейросетевые модели, способные автоматически извлекать признаки из изображения. Классические признаки используются как базовый и интерпретируемый уровень анализа; нейросетевые модели — как основной инструмент определения стадии процесса. [11] [21] [14]

В покадровой постановке модель получает на вход отдельное изображение области интереса и формирует распределение вероятностей по четырём классам. Результатом работы являются две сущности: наиболее вероятная стадия и сам вектор вероятностей:

$$p_i = [p_0, p_1, p_2, p_3],$$

где p_k — оценка вероятности принадлежности кадра k -й стадии. Наиболее вероятная стадия определяется как класс с максимальной вероятностью.

У покадровой постановки есть ограничение. Отдельные кадры неоднозначны: переходы между стадиями постепенные, визуальные признаки приходят с запозданием или с шумом. Блик у флюса похож на признак активации флюса, первые изменения формы припоя выражены слабо и не всегда отделимы от предыдущей стадии. Поэтому покадровый ответ модели рассматривается как сырой прогноз и требует временной стабилизации.

Чтобы получить устойчивую операторскую стадию, к покадровым решениям применяется постобработка с учётом технологического порядка. Обычного сглаживания для этого недостаточно: стадии пайки не могут произвольно меняться местами. После перехода в «active_brazing» процесс не должен возвращаться в «inactive_preparation». Поэтому к классификации добавляется логика конечного автомата с фиксированной разрешённой последовательностью переходов:

inactive_preparation → *flux_activation* → *active_brazing* → *stabilization*.

В классификации стадий выделены два уровня выхода:

- «Raw Stage» — непосредственное покадровое предсказание модели;
- «Stable Stage» — стабилизированная стадия после применения технологической логики переходов.

Такое разделение имеет прикладной смысл: по сырым ответам удобно анализировать поведение модели и распределение вероятностей, а «Stable Stage» используется для операторского отображения как устойчивое представление состояния процесса.

1.5.2. Задача обнаружения события начала активной пайки

Наряду с определением текущей стадии в работе рассматривается

отдельная задача — обнаружение события начала активной пайки. Эта задача имеет самостоятельную технологическую значимость: начало плавления и протекания припоя может использоваться как момент фиксации температурного режима или перехода к следующей фазе управления.

Событие начала активной пайки в работе обозначается как «active_brazing_started».

Здесь, в отличие от покадровой классификации, ответом служит не метка кадра, а момент времени в видеопотоке. Для каждой записи этот момент определяется по интервальной разметке — как начало стадии «active_brazing»:

$$t_{true} = start_s(active_brazing)$$

Задача алгоритма состоит в том, чтобы по видеопотоку определить момент: t_{pred} , в который система впервые устойчиво обнаруживает начало активной пайки. Ошибка срабатывания определяется как:

$$e = t_{pred} - t_{true}.$$

Отрицательное значение ошибки означает раннее срабатывание триггера, положительное — позднее. Для технологической системы критичны оба типа ошибок. Раннее срабатывание приводит к преждевременной фиксации температуры, когда припой ещё не начал устойчиво плавиться. Позднее срабатывание приводит к избыточному нагреву зоны пайки и повышает риск деформации элементов.

В работе рассматриваются два подхода к формированию события «active_brazing_started».

Первый подход опирается на вероятность класса «active_brazing», выдаваемую нейросетевым классификатором стадий. Триггер срабатывает, если эта вероятность сохраняется выше заданного порога на нужном числе подряд идущих кадров. Такой подход использует уже обученный классификатор стадий и не требует запуска отдельной модели.

Второй подход опирается на классические признаки компьютерного зрения. По области интереса рассчитывается OpenCV-оценка, в которую входят движение, сдвиг текстуры, плотность границ и появление бликов. Этот

триггер выступает как резервный или объяснимый канал — его признаки получают прямую визуальную интерпретацию.

Общая логика событийного триггера может быть описана следующим образом: если $score_i \geq threshold$ в течение M последовательных кадров, то $active_brazing_started = true$.

Здесь $score_i$ — значение нейросетевой вероятности или OpenCV-оценки на i -м кадре, $threshold$ — порог срабатывания и число кадров M , нужное для подтверждения события. Подтверждение по нескольким кадрам снижает вероятность ложных срабатываний на одиночных всплесках вероятности или шуме изображения.

В демонстрационном прототипе событие «active_brazing_started» формирует рекомендательный сигнал «Hold Temperature».

В рамках работы он интерпретируется как результат работы прототипа: визуально подтверждено наступление активной пайки, температурный режим может потребовать фиксации.

1.5.3. Требования к качеству и времени обработки

Для оценки качества решения используются несколько групп метрик. Для задачи классификации стадий применяются стандартные метрики многоклассовой классификации [21]:

- accuracy — доля верно классифицированных кадров;
- precision — точность положительных предсказаний;
- recall — полнота обнаружения объектов заданного класса;
- F1-score — гармоническое среднее precision и recall;
- macro-F1 — среднее F1-score по классам без учёта их частоты;
- weighted-F1 — среднее F1-score по классам с учётом числа объектов каждого класса.

Ассурасу отражает долю верно классифицированных кадров. Из-за дисбаланса классов одной метрики accuracy недостаточно. У стадий разная

длительность, и класс «inactive_preparation» почти всегда представлен большим числом кадров, чем короткие переходные стадии. Поэтому основной акцент сделан на macro-F1, усредняющей качество по классам без учёта их частоты, и на поклассовых метриках — особенно по классу «active_brazing».

Для задачи обнаружения события начала активной пайки используются временные метрики:

- Абсолютная ошибка времени срабатывания;
- Средняя абсолютная ошибка;
- Число ранних срабатываний;
- Число поздних срабатываний;
- Доля видео с ошибкой не более 1 секунды;
- Доля видео с ошибкой не более 2 секунд.

Такой набор метрик выбран для оценки событийного триггера: покадровой точности в этой задаче недостаточно, важен ещё и момент первого устойчивого срабатывания. На реальной установке полезность сигнала для оператора или управляющей системы определяет именно время отклика.

Отдельное требование — задержка обработки кадра. Целевое ограничение принято на уровне 50 мс на кадр.

Ограничение продиктовано режимом, близким к реальному времени. При измерении учитывается полный цикл: чтение кадра, ROI, предобработка, инференс модели, постобработка, триггер. Итоговые показатели — среднее время обработки и 95-й перцентиль задержки: p95 более устойчиво, чем среднее значение, характеризует поведение системы при редких всплесках задержки. [16]

С прикладной точки зрения различаются два режима работы:

- Качественный режим — более точная модель (ResNet18) на GPU;
- Режим запуска на центральном процессоре — облегчённая модель или уменьшенное входное разрешение для запуска на CPU.

Эти два режима позволяют оценить два аспекта: максимально достижимое качество классификации и применимость системы на менее производительном оборудовании.

1.5.4. Ограничения постановки задачи

Постановка задачи в работе ограничена несколькими условиями: набором доступных видеоданных и параметрами эксперимента.

Во-первых, видеоданные собирались в ограниченных условиях и не охватывают всё множество сценариев индукционной пайки. Смена камеры, освещения, ракурса, геометрии изделия или технологического режима может изменять итоговое качество модели. Поэтому полученные значения следует рассматривать как исследовательскую оценку прототипа, а не как промышленную метрику.

Во-вторых, разметка стадий построена на визуальном анализе видеозаписей. Переходы размыты, определение точного момента начала стадии содержит элемент субъективности разметчика. Сильнее всего это заметно на границе «flux_activation» → «active_brazing», где первые признаки деформации припоя ещё слабые.

В-третьих, синхронные физические данные — температура, мощность индуктора и другие параметры процесса — в работе не использовались. Модель обучается и оценивается только по визуальным признакам. В работе не формулируется утверждение о том, что визуальное событие точно совпадает с температурным порогом; практическая ценность видеоканала как дополнительного источника информации остаётся.

В-четвёртых, часть видеозаписей содержит сложные визуальные условия: засветы, нестабильную видимость флюса, нетипичное поведение припоя, неоднозначные блики. Такие ролики отнесены к сложным случаям и используются для анализа пределов применимости системы; разделение помогает оценивать алгоритм на штатных и сложных примерах отдельно.

В-пятых, «Hold Temperature» в работе — рекомендательный сигнал

прототипа. Он сообщает, что система зафиксировала начало активной пайки по видеоданным, но не рассматривается как управляющий сигнал промышленной установки. Для включения в реальный контур управления необходимы испытания, синхронизация с температурными измерениями и проверка на расширенном наборе видеозаписей.

В итоге постановка задачи ограничена рамками исследовательского прототипа, но одновременно позволяет проверить ключевую гипотезу работы: визуальные признаки процесса индукционной пайки могут быть использованы для автоматического определения стадии пайки и формирования события начала активной пайки в близком к реальному времени режиме.

1.6. Выводы

В первой главе рассмотрены технология индукционной пайки волноводных трактов и условия, при которых целесообразно применять машинное зрение. Качество шва не сводится к температурному режиму: оно также зависит от фактического состояния флюса, припоя и зоны соединения. Эти состояния могут быть определены по видеокадру — по прозрачности и текстуре флюса, бликам, деформации припоя, началу его плавления и протекания.

Выделены три основные схемы контроля: программа нагрева, обратная связь по температуре и ручной визуальный контроль. Температурный канал достаточно полно характеризует режим нагрева, но не всегда отражает локальное состояние шва. Видеоканал дополняет температурный контроль — фиксирует непосредственные визуальные признаки процесса.

Для формализации задачи машинного зрения процесс пайки был представлен в виде четырёх визуально различимых стадий:

inactive_preparation → *flux_activation* → *active_brazing* → *stabilization*.

Такая формализация позволяет представить непрерывный процесс пайки как задачу классификации кадров по стадиям. Отдельно поставлена

задача обнаружения события «active_brazing_started» — момента начала плавления и протекания припоя; именно по нему целесообразно формировать рекомендательный сигнал фиксации температуры.

В главе также сформулирован набор требований к разрабатываемой системе. Система выделяет область интереса из кадра, определяет текущую стадию процесса, стабилизирует покадровые предсказания во времени, формирует триггер начала активной пайки и работает в режиме, близком к реальному времени. В качестве целевого ограничения принята задержка обработки кадра не более 50 мс.

По результатам аналитического обзора была сформирована следующая постановка задачи: разработать прототип модуля машинного зрения, который по видеопотоку зоны пайки определяет стадию процесса, формирует устойчивую операторскую стадию с учётом технологической последовательности и выделяет событие начала активной пайки. В соответствии с этой постановкой во второй главе рассматриваются архитектура системы, подготовка датасета, выбор области интереса, методы извлечения признаков, нейросетевые модели, конечный автомат стадий и триггер начала активной пайки.

ГЛАВА 2. АРХИТЕКТУРА И РЕАЛИЗАЦИЯ МОДУЛЯ МАШИННОГО ЗРЕНИЯ

2.1. Общая архитектура разрабатываемой системы

На основании постановки задачи, сформулированной в первой главе, в работе разрабатывается модуль машинного зрения для анализа видеопотока процесса индукционной пайки волноводных трактов. Назначение модуля состоит в автоматическом определении текущей стадии процесса пайки, стабилизации результата во времени и формировании события начала активной пайки, которое может использоваться как рекомендательный сигнал для оператора или управляющей системы.

Разрабатываемая система ориентирована на обработку видеоданных зоны пайки. Входом системы является кадр видеопотока или последовательность кадров, полученных в процессе индукционного нагрева. На выходе формируются несколько уровней информации: сырое покадровое предсказание модели, стабилизированная стадия процесса, вероятность стадии активной пайки, событие начала активной пайки и рекомендательный сигнал фиксации температуры. Такое разделение выходов позволяет использовать систему как для анализа работы модели, так и для прикладного мониторинга технологического процесса.

Общая логика работы системы представлена на рисунке 2.1 [10] [14]:



Рисунок 2.1 — Общая последовательность работы модуля машинного зрения при обработке видеокadra

Первым этапом является выделение области интереса. Полный кадр видеопотока содержит не только зону пайки, но и фон, элементы оснастки,

неинформативные области детали и возможные визуальные помехи. Использование полного изображения может ухудшать качество классификации и увеличивать вычислительную нагрузку. Поэтому из каждого кадра выделяется область, содержащая волновод, флюс, припой и область технологического шва. В дальнейшем именно эта область используется для извлечения признаков и нейросетевого анализа.

Второй этап связан с предварительной обработкой изображения. Для нейросетевых моделей область интереса приводится к фиксированному размеру входного изображения, преобразуется в требуемый цветовой формат и нормализуется. Для классических методов компьютерного зрения дополнительно рассчитываются признаки яркости, цвета, бликов, границ, текстуры и межкадрового изменения. В результате система поддерживает два типа анализа: нейросетевой и классический OpenCV-анализ.

Основным компонентом системы является классификатор стадии пайки. В ходе работы были исследованы свёрточные нейросетевые модели ResNet18 и MobileNetV3 Small. Модель получает на вход изображение области интереса и формирует распределение вероятностей по четырём стадиям процесса: подготовка и предварительный нагрев, активация флюса, активная пайка и стабилизация. Наиболее вероятный класс рассматривается как сырое покадровое предсказание модели. [12] [15]

Однако покадровое предсказание само по себе не является достаточным для операторского применения. Из-за бликов, шумов, неоднозначных границ между стадиями и локальных изменений изображения модель может на отдельных кадрах выдавать кратковременные скачки между соседними стадиями. Для технологического процесса пайки такие скачки нежелательны, поскольку оператору требуется видеть устойчивое состояние процесса, а не последовательность независимых покадровых решений. Поэтому дополнительно к нейросетевому классификатору реализован алгоритм стабилизации на основе конечного автомата.

Конечный автомат учитывает допустимую технологическую

последовательность стадий:

inactive_preparation → *flux_activation* → *active_brazing* → *stabilization*.

В отличие от обычного сглаживания, конечный автомат не усредняет и не выбирает наиболее частый класс в окне, а запрещает обратные переходы и перескоки стадий. Переход к следующей стадии подтверждается только при достаточном числе соответствующих предсказаний в недавней истории кадров. На выходе формируется стабилизированная операторская стадия, обозначаемая в демонстрационной системе как «Stable Stage».

Отдельный компонент архитектуры — триггер начала активной пайки. Он решает не задачу классификации текущей стадии, а задачу обнаружения события «active_brazing_started». Основной вариант триггера строится на вероятности класса «active_brazing», полученной нейросетевой моделью. Если эта вероятность превышает заданный порог, система формирует событие начала активной пайки. В демонстрационном прототипе оно используется для отображения рекомендательного сигнала «Hold Temperature».

Такой подход позволяет использовать одну нейросетевую модель одновременно для двух целей: определения стадии процесса и формирования события активной пайки. Это важно с точки зрения вычислительной эффективности, поскольку отдельная модель для управляющего сигнала не требуется. В то же время в системе предусмотрен опциональный резервный триггер на основе OpenCV-признаков. Он рассчитывается по классическим визуальным признакам области интереса и может использоваться как объяснимый дополнительный канал анализа. [22] [23]

В конечном счёте финальная архитектура системы включает следующие основные компоненты:

1. Модуль чтения видеопотока;
2. Модуль выделения области интереса;
3. Модуль предварительной обработки изображения;
4. Нейросетевой классификатор стадии пайки;

5. Модуль стабилизации стадии на основе конечного автомата;
6. Нейросетевой триггер начала активной пайки;
7. Опциональный OpenCV-триггер;
8. Модуль визуализации и сохранения демонстрационного видео;
9. Модуль оценки задержки обработки кадра.

Для демонстрации работы системы был реализован режим построения видеоролика с наложением результатов анализа на исходные кадры. На каждом кадре отображаются сырая стадия модели, стабилизированная стадия, уверенность классификатора, вероятность активной пайки, состояние нейросетевого триггера, состояние OpenCV-триггера при его использовании, сигнал «Hold Temperature», время инференса и текущий момент видеозаписи. Такой формат демонстрации позволяет визуально сопоставить работу алгоритма с фактическим ходом процесса пайки.

Важной особенностью архитектуры является разделение качественного и вычислительно эффективного режимов. Для максимального качества классификации используется более точная модель ResNet18. Для запуска на центральном процессоре и выполнения ограничения по задержке исследуются облегчённые варианты: MobileNetV3 Small и ResNet18 с уменьшенным входным разрешением. Такое разделение позволяет рассматривать систему как исследовательский прототип, который может быть адаптирован под различные вычислительные условия. [15] [16]

С архитектурной точки зрения разработанная система не является полной заменой температурного контура управления. Её назначение заключается в дополнении существующих средств контроля визуальной информацией о фактическом состоянии флюса и припоя. Поэтому выход «Hold Temperature» внутри работы рассматривается как рекомендательный сигнал прототипа, а не как промышленный сертифицированный управляющий сигнал. Для перехода к промышленному применению необходима дальнейшая валидация на целевом оборудовании и синхронизация с физическими

параметрами процесса.

В дальнейшем в этой главе последовательно рассматриваются этапы реализации архитектуры: подготовка видеоданных и разметки, выбор области интереса, построение OpenCV baseline, разработка нейросетевых моделей, реализация конечного автомата, формирование триггера начала активной пайки и организация программного прототипа в репозитории.

2.2. Подготовка видеоданных и разметки

Качество модели машинного зрения во многом определяется качеством исходных данных и корректностью разметки. В качестве исходных данных используются видеозаписи процесса нагрева и пайки волноводных трактов. Видеоданные отражают изменение состояния зоны пайки во времени, поэтому подготовка датасета строится не только по отдельным изображениям, но и по временной структуре процесса.

В ходе работы исходные видеозаписи были организованы в единую структуру репозитория. Оригинальные видео размещаются в каталоге:

data/raw/

Каждой видеозаписи назначается интервальная разметка стадий. Стадии имеют длительность в несколько секунд и охватывают множество кадров; покадровая ручная разметка избыточна. Интервальная разметка является более компактной: разметчик проставляет начало и конец стадии в секундах, а покадровая выборка собирается потом автоматически.

Основным файлом интервальной разметки является:

data/annotations/stage_intervals.csv

В нём для каждого видео задаются интервалы стадий. Структура файла включает следующие поля:

- `video_id` — идентификатор видеозаписи;
- `video_path` — путь к исходному видео;
- `stage_name` — название стадии процесса;
- `start_s` — время начала стадии в секундах;

- `end_s` — время окончания стадии в секундах.

Пример структуры интервальной разметки представлен в таблице 2.1.

Таблица 2.1 — Пример интервальной разметки стадий процесса пайки

video_id	video_path	stage_name	start_s	end_s
MVI_6265	data/raw/MVI_6265.MOV	inactive_preparation	0.0	31.4
MVI_6265	data/raw/MVI_6265.MOV	flux_activation	31.4	34.0
MVI_6265	data/raw/MVI_6265.MOV	active_brazing	34.0	39.6
MVI_6265	data/raw/MVI_6265.MOV	stabilization	39.6	56.26
MVI_6266	data/raw/MVI_6266.MOV	inactive_preparation	0.0	27.8
MVI_6266	data/raw/MVI_6266.MOV	flux_activation	27.8	30.8

Такой формат отражает ход процесса: видеозапись разделяется на временные интервалы стадий, при этом сохраняется привязка к исходному видео. На основе этой разметки кадры извлекаются с нужной частотой и сразу получают метку класса.

Следующим этапом является преобразование интервальной разметки в покадровую выборку. Для этого используется скрипт:

`scripts/build_frame_dataset.py`

Скрипт считывает файл «stage_intervals.csv», проходит по исходным видео, извлекает кадры с заданной частотой и для каждого кадра определяет соответствующую стадию на основании временного интервала. В результате формируется таблица покадровой разметки, в которой каждому кадру сопоставлены путь к изображению, временная метка, идентификатор видео и стадия процесса.

В работе собраны два варианта датасета:

- 3 FPS — первичный датасет для анализа и базовых экспериментов;
- 10 FPS — финальный датасет для нейросетевого обучения и анализа коротких стадий.

Датасет на 3 FPS используется для первичного обзора данных, проверки

разметки, выбора области интереса и базовых моделей. Для коротких стадий «flux_activation» и «active_brazing» частоты 3 FPS недостаточно, поскольку число кадров на класс ограничено. Поэтому для финальных нейросетевых экспериментов собран отдельный датасет на 10 FPS. Он плотнее представляет переходные стадии и точнее воспроизводит момент начала активной пайки. Дополнительные графики, характеризующие распределение кадров по видеозаписям и длительности размеченных интервалов стадий, приведены в приложении В.1.

Покадровые разметки сохраняются в файлах:

data/annotations/frame_labels_3.csv

data/annotations/frame_labels_10.csv

Для каждого варианта также сохраняется статистика датасета:

data/annotations/frame_dataset_stats_3.json

data/annotations/frame_dataset_stats_10.json

Покадровая таблица содержит следующие основные поля:

- video_id — идентификатор исходного видео;
- video_path — путь к исходной видеозаписи;
- frame_path — путь к извлечённому кадру;
- timestamp_s — временная метка кадра;
- stage_id — числовой идентификатор стадии;
- stage_name — текстовое название стадии.

Соответствие числовых меток стадиям задаётся следующим образом:

- 0 — «inactive_preparation»;
- 1 — «flux_activation»;
- 2 — «active_brazing»;
- 3 — «stabilization».

Чтобы избежать утечки между train, val и test, разбиение выполняется на уровне видеозаписей. Видеозапись пайки — это длинная последовательность

визуально близких соседних кадров; при случайном делении на уровне отдельных кадров пары соседних кадров одного видео попадают одновременно в обучающую и тестовую выборки. Тогда в тесте оказываются изображения, почти идентичные обучающим, а оценка качества — завышена. [21]

Поэтому здесь разбиение выполняется не по кадрам, а по `video_id`. Используется скрипт:

scripts/split_frame_dataset.py

Он формирует три выборки:

- `train.csv` — обучающая выборка;
- `val.csv` — валидационная выборка;
- `test.csv` — тестовая выборка.

Файлы `split` сохраняются отдельно для датасетов 3 FPS и 10 FPS:

data/annotations/splits_3/

data/annotations/splits_10/

Такое разбиение корректнее проверяет, как модель обобщает результат на новые видеозаписи, а не на соседние кадры уже виденных роликов.

К подготовке данных добавлена логика исключения отдельных видеозаписей из штатной оценки. Часть видео содержала выраженные визуальные аномалии: засветы, нестабильную видимость флюса, нетипичное поведение припоя и другие факторы, затрудняющие однозначную интерпретацию стадий. Под такие случаи заведён файл:

data/annotations/blacklist.txt

Список исключений либо исключает запись из штатного `train/val/test`, либо отправляет её в отдельный анализ сложных случаев. Так оценка на штатных роликах и анализ устойчивости на сложных не смешиваются: ролики со спорными бликами и нестабильным флюсом нужны для исследования пределов системы и не должны исказить основную метрику на типовых сценариях.

Ещё один пункт подготовки — дисбаланс классов. Длительности у стадий разные: подготовительный нагрев и стабилизация дают основную массу кадров, «flux_activation» и «active_brazing» — заметно меньше. Без поправки модель лучше распознаёт длинные стадии и хуже различает короткие переходные. Самая чувствительная стадия — «active_brazing»: на ней начинаются плавление и протекание припоя. [11]

Для компенсации в нейросетевых экспериментах в функцию потерь введены веса классов. Вес обратен частоте: чем меньше кадров у класса в train, тем больший вклад в функцию потерь вносит ошибка по нему. Редкие стадии получают больший вес при обучении, и снижается риск их недостаточного учёта при обучении.

Сбор данных выполнялся в два этапа. Для датасета 3 FPS рассчитывалась первичная статистика классов, проверялась интервальная разметка и апробировались OpenCV-признаки. Для датасета 10 FPS собиралась финальная выборка для нейросетевой модели и анализа коротких стадий: при такой частоте у «flux_activation» и «active_brazing» формируется достаточное число кадров, что важно и для обучения, и для последующего событийного триггера.

В общем виде процесс подготовки данных можно представить в виде схемы, изображённой на рисунке 2.2.



Рисунок 2.2 — Схема подготовки набора данных для OpenCV- и нейросетевых экспериментов

Для воспроизводимости все ключевые артефакты подготовки данных размещены в репозитории: исходные интервалы стадий, покадровые таблицы, статистика датасета, списки исключённых видео и файлы разбиения train/val/test. Этого достаточно, чтобы повторить процесс обучения и

экспериментальной оценки модели без ручного восстановления структуры данных.

Подготовка видеоданных и разметки в работе охватывает полный цикл — от исходных видеозаписей процесса пайки до структурированного датасета для обучения и проверки моделей машинного зрения. Совокупность интервальной разметки, покадрового преобразования, split по video_id, blacklist-логики и сохраняемой статистики обеспечивает воспроизводимость экспериментов и снижает риск завышенной оценки качества модели.

2.3. Выбор и использование области интереса

При анализе видеопотока процесса индукционной пайки полный кадр содержит много областей, не связанных напрямую с состоянием зоны пайки. К ним относятся элементы оснастки, фон, неизменяемые участки детали, границы рабочего пространства и другие визуальные компоненты без основной информации о флюсе и припое. При подаче полного кадра на вход модели растёт вычислительная нагрузка, теряется устойчивость признаков и появляется риск обучения на нерелевантных визуальных элементах.

Поэтому в работе из кадра заранее выделяется область интереса — прямоугольник с участком волноводного тракта, зоной шва, флюсом, припоем и областью возможного протекания припоя. И классические CV-алгоритмы, и нейросетевая модель обрабатывают только ту часть, где происходят технологически значимые изменения; остальные участки кадра исключаются из обработки. [10]

ROI подбиралась экспериментальным путём — по кадрам разных видеозаписей и разных стадий процесса. Опорными требованиями были следующие:

1. ROI должна включать флюс, припой и зону технологического шва.
2. Область должна сохранять информативность на всех стадиях процесса.
3. Область не должна быть чрезмерно узкой, чтобы не потерять часть визуальных изменений.

4. Область не должна быть чрезмерно широкой, чтобы не включать лишний фон.
5. Координаты области должны быть одинаковыми для всех кадров выбранного набора видео.

Финальная область интереса была задана следующими координатами:

$$x = 470$$

$$y = 280$$

$$w = 430$$

$$h = 290$$

где x и y — координаты левого верхнего угла области, w — ширина, h — высота. Эти координаты были сохранены в конфигурационном файле:

configs/roi.yaml

Конфигурационный файл отделяет параметры области интереса от кода обработки данных. Это повышает воспроизводимость экспериментов, а смена ROI при переносе системы на другие видеозаписи, другую камеру или иной ракурс съёмки сводится к изменению одного YAML-файла.

На рисунке 2.3 показано, что выбранная область интереса охватывает зону соединения, флюс, припой и прилегающий участок волноводного тракта; большая часть фона и элементов оснастки исключается из дальнейшего анализа.



Рисунок 2.3 — Пример выделения области интереса в кадре видеозаписи процесса индукционной пайки

Дополнительные материалы, иллюстрирующие проверку положения области интереса на разных видеозаписях и сравнение делимости признаков для полного кадра и ROI, приведены в приложении В.2.

Схематично операция выделения области интереса может быть

представлена на рисунке 2.4.




Рисунок 2.4 — Схема выделения области интереса из полного кадра видеопотока

Выделение ROI решает сразу несколько прикладных задач. Размер входного изображения уменьшается: у нейросетевых моделей доля нерелевантных пикселей снижается, ограниченная выборка используется эффективнее. Снижается влияние фона и оснастки, которые могут быть стабильными или случайно коррелировать со стадиями. Повышается интерпретируемость: и признаки, и предсказания модели относятся к конкретной зоне пайки.

Для расчёта OpenCV-признаков ROI имеет принципиальное значение. Яркость, доля бликовых областей, плотность границ, межкадровое изменение — каждый из этих признаков искажается, если рассчитывать их по полному кадру: фон вносит лишние границы, блики и колебания яркости, к пайке не относящиеся. Расчёт по ROI лучше связывает признаки с реальным состоянием флюса и припоя. [14]

Для нейросетевой модели ROI также имеет важное значение. На полном кадре сеть может использовать положение камеры, фон или оснастку — стабильные подсказки, не связанные с процессом. На ROI сеть анализирует область, в которой происходят технологически значимые изменения. Обучение становится содержательнее, а риск переобучения на нерелевантные признаки падает. [11]

В ходе исследования ROI использовалась в нескольких частях конвейера обработки:

1. При извлечении OpenCV-признаков;
2. При обучении нейросетевых моделей;
3. При построении демонстрационного видео;
4. При расчёте CV-Trigger;

5. При измерении задержки обработки кадра.

В скриптах проекта ROI передаётся набором координат x , y , w , h . Так, при запуске финального демонстрационного видео подаётся параметр:

```
--roi 470,280,430,290
```

За счёт этого один и тот же режим анализа воспроизводится при обучении, тестировании, в демонстрационных роликах и при измерении задержки обработки кадра.

Отдельно стоит отметить, что фиксированная ROI является допущением текущего исследования. Оправдано оно тем, что видеозаписи получены в близких условиях, а положение зоны пайки в кадре стабильно. При переносе системы на другую камеру, иной ракурс или производственную установку понадобится повторный выбор области интереса или автоматическое обнаружение зоны пайки. В более развитой версии ROI может определяться автоматически — детектором объекта, шаблонным сопоставлением или калибровкой камеры по оснастке.

Выделение ROI используется как опорный шаг архитектуры. Анализ концентрируется на зоне пайки, посторонние участки кадра не влияют на признаки, вычислительная нагрузка снижается, повышается воспроизводимость экспериментов. Далее ROI-кадр используется всеми основными блоками проекта: OpenCV baseline, нейросетевые классификаторы, конечный автомат, триггер «active_brazing» и latency benchmark.

2.4. Базовый подход на основе OpenCV-признаков

Перед разработкой нейросетевой модели формируется классический baseline на CV-признаках. Такой этап решает три задачи. Во-первых, проверяется: разделимы ли стадии по явно заданным признакам. Также обеспечивается интерпретируемость: явно заданные признаки более интерпретируемы, чем признаки, которые нейросетевая модель формирует автоматически. И последнее: baseline закрепляет точку отсчёта для

нейросетевых экспериментов. [10] [14]

Допущение базового подхода: стадиям пайки сопутствуют изменения яркости, цвета, текстуры, доли бликовых областей и межкадровой динамики в ROI. Активация флюса меняет прозрачность и яркость зоны; активная пайка добавляет блики расплава, деформацию припоя и локальное движение; стабилизация снижает динамику изменений. Эти эффекты частично описываются набором числовых признаков по ROI-кадру.

В OpenCV baseline признаки рассчитываются не по полному кадру, а по области интереса. Анализ сосредоточен на зоне флюса, припоя и технологического шва; влияние фона и оснастки снижается. Для каждого кадра формируется вектор признаков: яркостные, цветовые, текстурные и динамические характеристики изображения.

Основные группы признаков, использованные в работе, перечислены далее.

Яркостные признаки. В эту группу входят среднее значение и стандартное отклонение яркости в области интереса. Они описывают общий уровень освещённости и сдвиг светлоты зоны пайки по мере нагрева.

Цветовые признаки считались сразу в трёх пространствах — RGB, HSV и Lab: средние значения каналов, насыщенность и яркость в HSV, компоненты Lab. Это позволяет одновременно оценивать сдвиг тона и общую картину поверхности по ходу нагрева.

Признаки бликов и светлых областей — доля светлых пикселей и доля бликовых участков. Связь с физикой процесса прямая: расплав и активный флюс сопровождаются локальной засветкой и отражениями.

Признаки тёмных и тёплых областей — доли тёмных пикселей и условно тёплых тонов. По ним можно оценить, как меняются распределение яркости и цветовой акцент в зоне пайки по ходу нагрева.

Процесс построения OpenCV baseline представлен на рисунке 2.5.




Рисунок 2.5 — Последовательность построения базового подхода на основе OpenCV-признаков

Для извлечения признаков был реализован скрипт:

scripts/analyze_cv_features.py

Он рассчитывает признаки по кадрам, сохраняет таблицу признаков и агрегированную статистику по стадиям. Результаты сохранялись в директориях:

*reports/cv_features_3/
reports/cv_features_10/
reports/cv_feature_analysis_3/*

Примеры выходных файлов:

*reports/cv_features_3/frame_features_roi.csv
reports/cv_features_3/summary_by_stage_roi.csv
reports/cv_features_10/frame_features_roi.csv
reports/cv_features_10/summary_by_stage_roi.csv*

Для построения базового подхода на основе классических методов компьютерного зрения для каждого ROI-кадра был рассчитан набор интерпретируемых признаков. Перечень признаков приведён в таблице 2.2.

Таблица 2.2 — Основные OpenCV-признаки, использованные в baseline

Группа признаков	Признаки	Интерпретация
Яркость	brightness_mean, brightness_std	Общий уровень яркости и разброс яркости в ROI
HSV	hue_mean, saturation_mean, value_mean	Цветовой тон, насыщенность и яркость
Lab	lab_l_mean, lab_a_mean, lab_b_mean	Светлота и цветовые компоненты в Lab-пространстве
RGB	red_mean, green_mean, blue_mean	Средние значения цветовых каналов

Цветовые различия	red_green_diff, red_blue_diff	Относительное изменение каналов цвета
Светлые и бликовые области	white_area_ratio, specular_highlight_ratio	Доля ярких и бликовых участков
Тёмные и тёплые области	dark_area_ratio, warm_area_ratio	Доля тёмных и условно тёплых областей
Контуры и текстура	edge_density, laplacian_var	Плотность границ и текстурность
Динамика	frame_diff_score	Межкадровое изменение ROI

Для первичной оценки разделимости стадий были рассчитаны средние значения OpenCV-признаков по каждой стадии процесса. Поскольку признаки имеют разные диапазоны значений, для совместного отображения они были нормированы. Результат представлен на рисунке 2.6. [14]




Рисунок 2.6 — Нормированные средние значения OpenCV-признаков по стадиям процесса пайки

Анализ показал: часть OpenCV-признаков действительно меняется между стадиями. Признаки, связанные с бликами, яркостью, текстурой и межкадровым изменением, отражают отдельные визуальные эффекты активации флюса и активной пайки. Но характер изменения по всем стадиям не монотонный и не однозначный — разделимость стадий в пространстве явных заданных признаков ограничена.

Соседние стадии визуально близки, и одни и те же признаки реагируют сразу на несколько факторов: освещение, блики, состояние флюса, положение припоя, локальную геометрию поверхности.

Наиболее сложными для OpenCV baseline являются переходные стадии «flux_activation» и «active_brazing». Визуально они пересекаются: флюс формирует блики и изменение прозрачности, похожие на ранние признаки активной пайки, а первые изменения припоя выражены слабо. Поэтому набор явных признаков изображения не гарантирует надёжного разделения двух состояний.

Чтобы покaдровые предсказания были устойчивее, в baseline добавлено временное сглаживание. Оно подавляет одиночные ошибочные предсказания и сглаживает последовательность. Тем не менее даже после сглаживания качество OpenCV baseline остаётся заметно ниже нейросетевого.

По итогам экспериментов OpenCV baseline после временного сглаживания показал следующие результаты:

- accuracy: 0.6296
- macro-F1: 0.5809
- weighted-F1: 0.6964

Эти результаты показывают: классические признаки фиксируют общую динамику зоны пайки, но не различают надёжно все четыре стадии. Наибольшие трудности возникают на соседних стадиях, где граница непрерывна, а визуальная картина переходная, что видно из рисунка 2.7.

Основной вывод по OpenCV baseline: классические признаки полезны для анализа визуальной структуры процесса, но не обеспечивают качества для финального модуля определения стадии пайки. При этом сами признаки остаются ценными как объяснимый дополнительный источник информации; поэтому далее они используются не как основной классификатор, а как резервный триггер.

Базовый подход на OpenCV-признаках закрыл две задачи. Первая — дать интерпретируемую точку сравнения для нейросетевых моделей. Вторая — выделить визуальные признаки, годные для резервного событийного сигнала. Ограниченность качества OpenCV baseline обосновывает

необходимость перехода к нейросетевым моделям, способным автоматически извлекать более сложные пространственные признаки изображения. [21]




Рисунок 2.7 — Матрица ошибок OpenCV baseline для классификации стадий пайки

2.5. Нейросетевая модель классификации стадий

Базовый подход на OpenCV-признаках показал: классические визуальные признаки частично описывают изменения в зоне пайки, но не обеспечивают качества, достаточного для надёжного определения всех стадий. Основная сложность — различия между соседними стадиями. Они выражены слабо и не сводятся к одному признаку яркости, цвета или текстурности. Так, активация флюса и начало активной пайки сопровождаются похожими бликами и сменой прозрачности, а первые признаки плавления припоя локальны и кратковременны.

Поэтому в работе использован нейросетевой подход на основе свёрточных сетей. Свёрточные архитектуры способны автоматически извлекать пространственные признаки изображения: локальные контуры, текстурные паттерны, форму области пайки, характер бликов, изменение

внешнего вида флюса и припоя. Модель использует более сложные комбинации признаков, чем явно заданный OpenCV-набор. [11] [12]

Задача нейросетевой модели формулируется как многоклассовая классификация ROI-кадра. На вход модели подаётся изображение области интереса, содержащее зону пайки, а на выходе формируется распределение вероятностей по четырём стадиям.

Вектор выходных вероятностей модели имеет вид:

$$p_i = [p_0, p_1, p_2, p_3],$$

где p_0 соответствует стадии «inactive_preparation», p_1 — стадии «flux_activation», p_2 — стадии «active_brazing», а p_3 — стадии «stabilization». Наиболее вероятная стадия определяется как класс с максимальным значением вероятности. При этом сама вероятность класса «active_brazing» дополнительно используется в дальнейшем для формирования триггера начала активной пайки.

В качестве нейросетевых архитектур были рассмотрены две модели — ResNet18 и MobileNetV3 Small. Выбор продиктован разными приоритетами. ResNet18 — относительно компактная, но достаточно выразительная свёрточная сеть; в задачах классификации изображений она показывает устойчивое качество. В работе она используется как основной качественный вариант. MobileNetV3 Small относится к облегчённым архитектурам, ориентированным на эффективный инференс на устройствах с ограниченными ресурсами. Для неё проверялись не только параметры обучения и размер входного изображения, но и конфигурация классификационной головы. За счёт этого MobileNetV3 Small рассматривалась не как полностью фиксированная готовая модель, а как компактная основа для дальнейшей настройки.

Она используется как вариант для центрального процессора при проверке возможности работы системы без графического процессора. Сводные характеристики обеих моделей собраны в таблице 2.3. [12] [15]

Таблица 2.3 — Нейросетевые архитектуры, исследованные в работе

Архитектура	Назначение в работе	Преимущества	Ограничения
ResNet18	Основная качественная модель классификации стадий	Хорошая выразительная способность; устойчивое качество классификации; подходит для GPU-режима	Более высокая задержка на CPU при стандартном размере входа 224×224
MobileNetV3 Small	Облегчённая CPU-friendly модель	Малый размер checkpoint; быстрый инференс на CPU; пригодна для демонстрационного CPU-режима	Может уступать ResNet18 по качеству отдельных стадий, особенно «active brazing»
ResNet18 64×64	CPU-friendly вариант ResNet18	Сохраняет архитектуру ResNet18; снижает задержку за счёт малого входного разрешения; проходит ограничение 50 мс на CPU	Может терять мелкие визуальные признаки припоя и флюса из-за малого разрешения

В результате набор исследованных архитектур позволил рассмотреть два режима применения системы: качественный режим, ориентированный на максимальную точность классификации, и вычислительно эффективный режим, ориентированный на запуск на центральном процессоре с ограничением по времени обработки кадра.

Нейросетевой подход работает на ROI-кадрах. Каждый кадр исходного видео сначала обрезается по ROI, затем приводится к фиксированному входному размеру модели. В качественном режиме это 224×224 — стандартный размер входного изображения для свёрточных архитектур, предобучаемых на ImageNet. В экспериментах для запуска на центральном процессоре дополнительно тестировались уменьшенные размеры входного изображения 128×128 , 96×96 и 64×64 .

Предобработка ROI-изображения включала следующие этапы:

1. Выделение области интереса;
2. Преобразование цветового пространства;
3. Изменение размера изображения;
4. Преобразование в тензор;

5. Нормализация по средним значениям и стандартным отклонениям каналов.

Для устойчивости модели к небольшим вариациям изображения использованы аугментации: умеренные изменения яркости, контрастности, насыщенности, лёгкие повороты и размытие. Сильные преобразования не использовались: в задаче пайки нужно сохранить тонкие различия между флюсом, расплавом припоя и стадией стабилизации. [24]

Датасет несбалансирован по длительности стадий: подготовительный нагрев и стабилизация дают больше кадров, чем активация флюса и активная пайка. В функцию потерь введены веса классов: редкие стадии получают больший вес, поэтому ошибка на коротких, но технологически важных участках процесса сильнее влияет на обучение.

Обучение модели выполнялось с функцией потерь кросс-энтропии и оптимизатором AdamW. Качество контролировалось на валидационной выборке, а финальная оценка выполнялась на тестовой выборке, сформированной по отдельным видеозаписям. Такое разбиение проверяет способность модели обобщать результат на новые видео, а не на соседние кадры уже виденных видеозаписей. [13] [25]

Нейросетевые эксперименты выполнялись в два этапа. На датасете 3 FPS проверялась принципиальная применимость свёрточных моделей и сравнивались ResNet18 и MobileNetV3 Small. Затем готовился 10 FPS датасет — он полнее представляет короткие стадии, в первую очередь «flux_activation» и «active_brazing». Финальная классификация стадий выполняется уже на 10 FPS.

Переход с 3 FPS на 10 FPS дал два эффекта. Во-первых, в обучающую выборку попадает больше кадров коротких стадий. Во-вторых, повышается временная детализация — это критично для оценки момента начала активной пайки. На 3 FPS отдельные переходные состояния представлены слишком малым числом кадров, и ухудшаются как обучение, так и последующая работа

триггера.

В качественном режиме используется ResNet18 по ROI-кадрам 10 FPS: эта конфигурация дала наиболее устойчивые метрики, а её предсказания используются как вход для конечного автомата. На выходе модели формируются вероятности четырёх стадий; по ним определяется сырая стадия, а вероятность $P(active_brazing)$ используется для триггера.

Для контроля обучения фиксировались ассигасу и macro-F1 на обучающей и валидационной выборках. Дополнительно отслеживалась метрика F1 для класса «active_brazing», поскольку именно эта стадия определяет момент формирования события начала активной пайки. Динамика обучения модели ResNet18 на датасете 10 FPS приведена на рисунке 2.8.




Рисунок 2.8 — Динамика обучения модели ResNet18 на датасете 10 FPS

Из рисунка 2.8 видно, что модель ResNet18 достигает устойчивых значений метрик на валидационной выборке и демонстрирует способность выделять признаки, связанные с различными стадиями пайки. При этом отдельные колебания метрик, особенно для класса «active_brazing», объясняются малой длительностью этой стадии и ограниченным числом видеозаписей. В связи с этим результаты покадровой классификации в дальнейшем дополняются временной постобработкой на основе конечного автомата.

MobileNetV3 Small рассматривалась как облегчённая альтернатива для

CPU. По качеству на отдельных стадиях она в ряде экспериментов уступала ResNet18, но имела меньшую задержку инференса. Далее эта архитектура используется при анализе CPU-friendly режима.

Общий процесс обучения нейросетевого классификатора приведён на рисунке 2.9.




Рисунок 2.9 — Последовательность формирования датасета, обучения CNN-модели и её итоговой оценки на test-выборке

Для каждой обученной модели сохранялся checkpoint, содержащий веса модели, параметры эксперимента, используемый размер входного изображения, порядок классов и значение лучшей валидационной метрики. Сохранение таких контрольных точек позволяет воспроизводить инференс, строить демонстрационные видеоролики и проводить повторные измерения задержки без переобучения модели.

Нейросетевой подход стал основным инструментом определения стадии пайки. По сравнению с OpenCV baseline нейросетевая модель автоматически извлекает более сложные пространственные признаки и точнее различает стадии. Покадровые ошибки на границах стадий всё же остаются, поэтому в архитектуре нейросетевой классификатор используется совместно с временной постобработкой на конечном автомате, которая описана в следующем разделе.

2.6. Алгоритм стабилизации стадии на основе конечного автомата

Нейросетевой классификатор стадий выдаёт покадровые предсказания: на каждый кадр — наиболее вероятная стадия и вектор вероятностей по классам. Для отдельного изображения этого достаточно. Но в технологическом процессе пайки есть ограничение: последовательность

независимых покадровых решений может содержать кратковременные скачки между соседними стадиями. [11]

Причины таких скачков связаны как с видеоданными, так и с особенностями процесса пайки. Во-первых, переходы между стадиями непрерывные, без резкой визуальной границы. Во-вторых, отдельный кадр может содержать блики, локальные изменения флюса, скачок освещения или слабые признаки деформации припоя. В-третьих, соседние стадии технологически близки: активация флюса и начало активной пайки выглядят похоже. В итоге модель на отдельных кадрах ошибочно возвращается к предыдущей стадии или преждевременно относит кадр к следующей стадии.

Оператору такой поток сырых предсказаний неудобен. Если на видео выводить только покадровый класс модели, последовательность может выглядеть так:

*flux_activation → active_brazing → flux_activation → active_brazing
→ stabilization.*

Технологически процесс развивается последовательно и к предыдущим стадиям не возвращается. Поэтому в работе реализован дополнительный слой постобработки — он переводит сырые предсказания модели в устойчивую операторскую стадию.

В качестве такого слоя используется конечный автомат стадий. Он описывает допустимые состояния процесса и правила перехода между ними. В работе состояниями автомата являются четыре стадии пайки.

Иначе говоря, система переходит только от текущей стадии к следующей. Обратные переходы запрещены, перескок через стадию не разрешается.

В работе используется первая версия конечного автомата — state machine v1. Логика алгоритма основана на невозвратном подтверждении перехода к следующей технологически допустимой стадии. Алгоритм хранит историю последних сырых предсказаний модели и подсчитывает, сколько раз в этой истории встречается следующая стадия. Если число таких предсказаний

превышает заданный порог, автомат переходит в новое состояние.

Основные параметры state machine v1:

- `window_size = 7`;
- `min_confirm_frames = 3`;
- `confidence_threshold = 0.0`.

Параметр «`window_size`» задаёт длину окна последних предсказаний, по которому принимается решение о переходе. Параметр «`min_confirm_frames`» — минимальное число предсказаний следующей стадии внутри окна, необходимое для подтверждения перехода. В такой конфигурации переход считается подтверждённым, если следующая стадия предсказана не менее 3 раз в последних 7 кадрах. Порог `confidence_threshold` в финальной версии не используется как ограничение: основная стабилизация выполнялась за счёт подтверждения по нескольким кадрам.

Логика работы конечного автомата может быть описана следующим образом:

1. Начальное состояние: «`inactive_preparation`».
2. Для каждого кадра получить raw-предсказание нейросетевой модели.
3. Добавить raw-предсказание в историю последних кадров.
4. Определить следующую допустимую стадию.
5. Если следующая стадия встречается в истории не менее `min_confirm_frames` раз, выполнить переход.
6. Если условие не выполнено, сохранить текущее состояние.
7. Если достигнута стадия «`stabilization`», считать её поглощающим состоянием.

Таким образом, state machine v1 — невозвратное majority-vote подтверждение перехода к следующей стадии. В отличие от обычного временного сглаживания, которое может изменять класс как в прямом, так и в обратном направлении, конечный автомат учитывает технологическую направленность процесса. Это делает результат более интерпретируемым для

оператора и более согласованным с технологической логикой пайки.

В ходе программной реализации конечный автомат вынесен в отдельный модуль:

src/brazing_sense/control/state_machine.py

За счёт этого один и тот же алгоритм работает в исследовательских ноутбуках, в финальном демонстрационном скрипте и при измерении задержки. На вход конечный автомат получает сырое предсказание модели, а на выходе формирует стабилизированную стадию, которая в демонстрационном видео отображается как «Stable Stage».

«Raw Stage» удобна при разборе поведения модели, анализе вероятностей и отладке. «Stable Stage» предназначена для оператора: учитывает технологическую последовательность и не меняется хаотично на отдельных кадрах.

В экспериментах сравнивались сырые предсказания модели, обычное majority smoothing и несколько вариантов конечного автомата. Majority smoothing показывал приемлемые покадровые метрики, но технологически корректную последовательность не гарантировал. Конечный автомат удерживал порядок стадий и подавлял обратные скачки — поэтому именно он лучше подходит для операторского отображения.

Для наглядной оценки влияния конечного автомата была построена временная диаграмма, сопоставляющая истинную разметку стадий, сырые покадровые предсказания модели, результат временного сглаживания и результат конечного автомата. Образец такого сравнения для видеозаписи MVI_6266 представлен на рисунке 2.10.

На рисунке 2.10 видно, что сырые покадровые предсказания дают кратковременные отклонения, особенно у границ стадий. Временное сглаживание подавляет часть скачков, но не гарантирует допустимый порядок стадий. Конечный автомат превращает поток предсказаний в более устойчивую траекторию и блокирует обратные переходы и перескоки. Полученный результат пригоден для операторского отображения и для

дальнейшего формирования технологических событий.




Рисунок 2.10 — Сравнение кадровых предсказаний и результата конечного автомата на примере видеозаписи MVI_6266

Видеозаписи с засветами и неоднозначным флюсом анализировались отдельно. На них раннее ложное предсказание может подтвердиться и сдвинуть автомат на следующую стадию; невозвратная логика конечного автомата не предусматривает обратного перехода. Такие записи отнесены к сложным случаям, а не к типовым примерам.

На штатных видеозаписях конечный автомат работает корректно: операторская стадия устойчива, порядок соблюден. Поэтому в финальной демонстрационной системе и осталась state machine v1 — компромисс между кадровыми метриками и операторской логикой.

В итоговой архитектуре конечный автомат располагается между нейросетевой моделью и интерфейсом оператора. Нейросетевая модель обрабатывает ROI и формирует вероятности классов; конечный автомат согласует их с технологическим порядком стадий. На стороне оператора получается предсказуемое поведение системы без скачков.

Конечный автомат — несущий элемент модуля стабилизации: подавляет кадровые скачки, удерживает порядок стадий в технологически допустимом виде и формирует «Stable Stage». Следующий блок архитектуры — триггер начала активной пайки: он выделяет «active_brazing_started» и формирует рекомендательный «Hold Temperature».

2.7. Триггер начала активной пайки

Архитектура наряду с классификатором стадии содержит отдельный блок для обнаружения события начала активной пайки. Эти задачи различаются по постановке: классификатор определяет текущую стадию процесса, триггер должен зафиксировать момент наступления события — момент начала плавления и протекания припоя.

Событие обозначается как «active_brazing_started». Оно соответствует моменту, когда в зоне пайки устойчиво проявляются визуальные признаки активного плавления припоя — сдвиг формы, блики расплава, локальное движение или протекание материала в область шва. На его основе формируется рекомендательный сигнал «Hold Temperature». [4] [6]

«active_brazing_started» — не вся стадия «active_brazing». Стадия длится секунды; триггер должен определить именно её начало. Поэтому качество триггера оценивается не только покадровыми метриками классификации, но и временной ошибкой первого устойчивого срабатывания относительно размеченного начала стадии.

В разработанной системе были исследованы два варианта триггера:

1. Нейросетевой триггер на основе вероятности класса «active_brazing».
2. Резервный OpenCV-триггер на основе классических визуальных признаков.

Основным вариантом является нейросетевой триггер. Алгоритм использует вероятности, формируемые классификатором стадий. После обработки ROI-кадра нейросетевая модель выдаёт распределение вероятностей по четырём стадиям. Одна из этих вероятностей соответствует классу «active_brazing».

Если эта вероятность сохраняется выше заданного порога на нужном числе подряд идущих кадров, событие начала активной пайки считается подтверждённым. Общая логика нейросетевого триггера: если $P(\text{active_brazing}) \geq \text{threshold}$ в течение M последовательных кадров, то

active_brazing_started = true.

Здесь *threshold* — порог вероятности, *M* — число подряд идущих кадров для подтверждения. Подтверждение по нескольким кадрам снижает вероятность ложных срабатываний на одиночных всплесках вероятности. Чем больше *M*, тем выше устойчивость и тем больше потенциальная задержка. Поэтому параметры триггера выбираются как компромисс между скоростью реакции и устойчивостью к шуму.

Нейросетевой триггер тестировался в нескольких режимах. Для экспериментальной оценки устойчивости использовался режим с порогом 0,4 и подтверждением 1 кадром. На тестовых видеозаписях он обеспечивал устойчивое обнаружение начала активной пайки и использовался для анализа временной ошибки срабатывания.

Для проверки работы нейросетевого триггера была построена временная диаграмма, на которой сопоставляются вероятность класса «active_brazing», порог срабатывания, размеченный момент начала активной пайки и момент первого срабатывания триггера. Пример такой диаграммы для видеозаписи MVI_6266 представлен на рисунке 2.11.




Рисунок 2.11 — Временная диаграмма работы нейросетевого триггера начала активной пайки на примере видеозаписи MVI_6266 (*threshold=0.2*, *confirm_frames=7*)

На рисунке 2.11 вероятность класса «active_brazing» возрастает в районе перехода к активной пайке; как только она пересекает порог и сохраняется в течение заданного числа кадров, триггер формирует «active_brazing_started». Таким образом, вероятностный выход классификатора служит сразу двум

целям — определению стадии и фиксации технологически значимого момента.

Второй вариант — OpenCV-триггер. Он не заменяет нейросетевой триггер, а используется параллельно. Триггер опирается на признаки межкадрового изменения, текстурности, плотности границ и долю бликов — те эффекты, что сопровождают начало плавления и протекания припоя. [14]

В работе рассчитывался интегральный OpenCV-score, в который входили признаки:

- `frame_diff_score`;
- `laplacian_var`;
- `edge_density`;
- `specular_highlight_ratio`.

где `frame_diff_score` отражает изменение ROI между соседними кадрами; `laplacian_var` — локальную текстурность и резкость; `edge_density` — плотность границ в ROI; `specular_highlight_ratio` — долю бликов. В совокупности они формируют простой интерпретируемый индикатор визуальной активности в зоне пайки.

Логика OpenCV-триггера аналогична логике нейросетевого триггера: если $CV\ Score \geq threshold$ в течение M последовательных кадров, то $CV\ Trigger = true$.

В финальной архитектуре OpenCV-триггер не является основным источником сигнала «Hold Temperature». Он используется как дополнительный диагностический индикатор: подходит для разбора работы системы и как резервный explainable-сигнал. Временная диаграмма этого триггера приведена на рисунке 2.12.

На рисунке 2.12 видно, что OpenCV-score также возрастает в области активной пайки и может использоваться как дополнительный объяснимый индикатор. Но этот сигнал зависит от нормировки признаков, освещения и стабильности видеоряда — поэтому в финальной архитектуре его роль

остаётся резервной.




Рисунок 2.12 — Временная диаграмма работы OpenCV-триггера начала активной пайки

С архитектурной точки зрения в финальном прототипе различаются три логических выхода:

- Neural Trigger — основной триггер начала активной пайки на основе $P(\text{active_brazing})$;
- CV-Trigger — дополнительный OpenCV-триггер на основе визуальных признаков;
- «Hold Temperature» — рекомендательный сигнал фиксации температуры.

В текущей реализации сигнал «Hold Temperature» формирует именно нейросетевой триггер. Иначе говоря, как только Neural Trigger переходит в состояние ON, в демонстрационном интерфейсе отображается «Hold Temperature»: ON. OpenCV-триггер при этом отображается параллельно и используется как вспомогательный канал контроля.

Такое разделение сохраняет простоту и эффективность финальной системы. Нейросетевая модель уже используется для определения стадии процесса, поэтому $P(\text{active_brazing})$ может быть получена без запуска отдельной модели. Вычислительная нагрузка снижается, а один классификатор решает две задачи: стадию процесса и событие начала активной пайки. OpenCV-триггер при необходимости включают опционально

как дополнительный объяснимый сигнал.

Для оценки качества триггера используются временные метрики. Для каждой видеозаписи известно размеченное время начала стадии «active_brazing», обозначаемое как t_{true} . Алгоритм формирует предсказанное время первого срабатывания t_{pred} . Ошибка срабатывания определяется как:

$$e = t_{pred} - t_{true}.$$

Если $e < 0$, триггер сработал раньше размеченного момента. Если $e > 0$, срабатывание произошло позже. В экспериментальной оценке дополнительно рассчитываются абсолютная ошибка, средняя абсолютная ошибка по видеозаписям, число ранних и поздних срабатываний, а также доля видео, для которых ошибка не превышает 1 и 2 секунды.

На практике опасны две крайности. Раннее срабатывание формирует сигнал «Hold Temperature» до того, как припой устойчиво начал плавиться. Позднее — приводит к избыточному нагреву после фактического начала активной пайки. Параметры триггера подбираются как компромисс между этими двумя ошибками.

Триггер начала активной пайки — самостоятельный блок архитектуры наряду с классификатором. Из вероятностного или признакового сигнала он формирует событие «active_brazing_started», и уже на основе этого события формируется сигнал «Hold Temperature». С таким блоком система выходит за рамки покадрового классификатора и может рассматриваться как инструмент технологического мониторинга.

2.8. Реализация прототипа и структура репозитория

Разработанная система реализована как воспроизводимый программный прототип. В него входят исследовательские ноутбуки, командные скрипты, конфигурационные файлы, сохранённые модели, отчёты экспериментов и демонстрационные видеоролики. Такая структура позволяет не только получить итоговый результат, но и воспроизвести основные этапы

исследования: подготовку данных, построение baseline, обучение нейросетевых моделей, стабилизацию стадий, формирование триггера активной пайки и оценку задержки обработки кадра. Обобщённая структура репозитория проекта приведена в приложении А.

Репозиторий проекта организован вокруг нескольких основных каталогов:

```
BrazingSense/  
├── configs/  
├── data/  
├── models/  
├── notebooks/  
├── reports/  
├── scripts/  
└── src/
```

Каталог `data/` содержит исходные видеозаписи, извлечённые кадры и файлы разметки. В `data/raw/` размещаются исходные .MOV-видеозаписи процесса пайки. В `data/processed/` — извлечённые кадры. В `data/annotations/` — интервальная и покадровая разметка, статистика датасета, список исключённых видеозаписей и файлы разбиения `train/val/test`.

Каталог `configs/` хранит конфигурационные файлы с параметрами обработки и логики системы. Например, `«roi.yaml»` — координаты области интереса; `«stages.yaml»` — описание стадий процесса; `«state_machine.yaml»` — параметры конечного автомата для стабилизации стадии.

Каталог `scripts/` содержит командные скрипты для основных этапов работы. С их помощью извлекаются кадры из видео, собирается датасет, формируется разбиение `train/val/test`, рассчитываются OpenCV-признаки, запускается финальный инференс на видео и измеряется задержка обработки кадра. Наличие таких скриптов позволяет использовать проект не только как набор исследовательских ноутбуков, но и как воспроизводимый программный конвейер обработки.

Каталог `notebooks/` содержит исследовательские ноутбуки по основным этапам разработки. В них выполнялись анализ данных, выбор области интереса, построение OpenCV baseline, обучение нейросетевых моделей, анализ конечного автомата, настройка триггера «active_brazing» и CV-Trigger, эксперименты для запуска на центральном процессоре.

Каталог `models/checkpoints/` содержит сохранённые веса обученных моделей. На их основе демонстрационные видео и измерения задержки запускаются повторно без переобучения. Среди ключевых контрольных точек представлены финальная ResNet18 для качественного режима, CPU-friendly ResNet18 64×64, MobileNetV3 Small после эволюционного подбора гиперпараметров и MobileNetV3 Small с эволюционно подобранной классификационной головой.

Каталог `reports/` содержит экспериментальные артефакты: таблицы метрик, предсказания моделей, графики, матрицы ошибок, временные графики, результаты измерения задержки и демонстрационные видеоролики. Такой набор отчётов позволяет проследить весь путь исследования от базового подхода до финальной системы.

Важной частью реализации является выделение переиспользуемого кода в каталог `src/`. В частности, модуль

`src/brazing_sense/control/state_machine.py`

содержит реализацию конечного автомата стадий. Этот модуль используется как в исследовательских ноутбуках, так и в финальных скриптах инференса и измерения задержки. Такой подход снижает дублирование кода и обеспечивает единообразное поведение конечного автомата в разных режимах работы.

Основные скрипты проекта представлены в таблице 2.4. Полный перечень команд запуска программного прототипа приведён в приложении Б.

Таблица 2.4 — Основные скрипты программного прототипа

Скрипт	Назначение
--------	------------

scripts/video_info.py	Получение технической информации о видеозаписях
scripts/build_frame_dataset.py	Извлечение кадров из видео и формирование покадровой разметки
scripts/split_frame_dataset.py	Разбиение датасета на train/val/test по video id
scripts/analyze_cv_features.py	Расчёт OpenCV-признаков по кадрам и формирование таблицы признаков
scripts/run_neural_inference_video.py	Запуск финальной системы на видео и сохранение demo-video с overlay
scripts/benchmark_neural_latency.py	Измерение задержки полного цикла обработки кадра
scripts/make_time_grid.py	Формирование временной сетки для разметки одного видео
scripts/make_time_grid_all.py	Формирование временных сеток для набора видео
scripts/create_empty_stage_annotations.py	Создание шаблона интервальной разметки стадий

Финальный скрипт инференса `run_neural_inference_video.py` реализует полный конвейер работы системы. На вход подаются путь к видео, контрольная точка модели, архитектура модели, координаты ROI, размер входного изображения, режим постобработки, параметры нейросетевого триггера и при необходимости параметры CV-триггера. На выходе формируется видеоролик с нанесёнными на каждый кадр результатами работы системы.

Пример запуска финального качественного режима на ResNet18:

```
PYTHONPATH=src python3 scripts/run_neural_inference_video.py \
  --video data/raw/MVI_6266.MOV \
  --checkpoint
models/checkpoints/final_neural_stage_classification_10/resnet18_10fps_balanc
ed_best_10fps.pt \
  --output reports/demo/MVI_6266_final_system_demo.mp4 \
  --model resnet18 \
  --roi 470,280,430,290 \
  --image-size 224 \
  --postprocess state_machine \
  --trigger-threshold 0.4 \
  --trigger-confirm-frames 1 \
  --device auto
```

При запуске демонстрационного видео на кадры наносится область интереса и значения:

- Raw Stage
- Stable Stage
- Confidence
- $P(\text{active_brazing})$
- Neural Trigger
- CV Score
- CV Trigger
- Hold Temperature
- Inference
- Time

Такой формат отображения позволяет одновременно анализировать сырое решение модели, стабилизированную стадию, вероятность активной пайки, состояние триггера и задержку обработки кадра.

Отдельный скрипт `benchmark_neural_latency.py` измеряет задержку полного конвейера обработки. В отличие от простого замера времени инференса модели, это измерение учитывает чтение кадра, выделение области интереса, предобработку изображения, прямой проход модели, работу триггеров и постобработку результата. Это позволяет получить более реалистичную оценку пригодности системы к работе в режиме, близком к реальному времени.

Результаты измерения сохраняются в CSV-файлах с покадровыми задержками и JSON-файлах со сводной статистикой. Для анализа используются среднее время обработки, p95 задержки и проверка выполнения лимита 50 мс на кадр.

Реализация проекта организована как воспроизводимый исследовательский конвейер обработки. Наличие структурированных данных, конфигурационных файлов, скриптов, ноутбуков, контрольных точек моделей и отчётов позволяет повторить основные эксперименты, запустить финальную демонстрацию и проверить задержку работы системы на разных вариантах

моделей и вычислительного оборудования.

2.9. Выводы

Вторая глава описывает архитектуру и реализацию разработанного модуля машинного зрения для анализа процесса индукционной пайки волноводных трактов [26]. Система собрана как последовательный конвейер обработки видеокadra: выделение области интереса, предварительная обработка изображения, классификация стадии нейросетевой моделью, стабилизация результата конечным автоматом и формирование триггера начала активной пайки.

Подготовка данных строилась на интервальной разметке видеозаписей: на её основе собраны покадровые датасеты 3 FPS и 10 FPS. Разбиение на train/val/test выполнено по идентификатору видеозаписи — это снижает риск утечки соседних кадров между выборками. Дополнительно введена логика списка исключений для отдельной работы с видео в сложных визуальных условиях.

На вход алгоритмам подавался не полный кадр, а ROI с зоной пайки, флюсом, припоем и швом. После обрезки фон и элементы оснастки исключались из рассмотрения, анализ был сосредоточен на технологически значимой области, а объём вычислений сокращался.

В главе рассмотрены два уровня анализа изображения. Первый — явные OpenCV-признаки яркости, цвета, бликов, текстуры, контуров и межкадровой динамики; они формируют интерпретируемую базовую линию и используются в резервном CV-триггере. Второй — свёрточные модели ResNet18 и MobileNetV3 Small, классифицирующие ROI по стадиям пайки.

Для повышения устойчивости результата в работе разработан конечный автомат стадий — он учитывает технологически допустимую последовательность процесса. Конечный автомат запрещает обратные переходы и перескоки стадий и формирует «Stable Stage» из сырых покадровых предсказаний модели.

Отдельный компонент архитектуры — триггер начала активной пайки. Основной триггер основан на вероятности класса «active_brazing» у нейросетевой модели; параллельно предусмотрен резервный OpenCV-триггер на признаках межкадрового изменения, текстурности, границ и бликов. В демонстрационном прототипе событие «active_brazing_started» формирует рекомендательный «Hold Temperature».

Программная реализация проекта организована как воспроизводимый репозиторий: исходные видео, разметка, конфигурационные файлы, исследовательские ноутбуки, командные скрипты, сохранённые модели, отчёты экспериментов и демонстрационные видеоролики. Основные сценарии — подготовка датасета, извлечение OpenCV-признаков, запуск финального инференса и измерение задержки — вынесены в отдельные CLI-скрипты.

Во второй главе была сформирована полная архитектура исследовательского прототипа: от подготовки видеоданных и выделения области интереса до нейросетевой классификации стадий, стабилизации предсказаний, события начала активной пайки и программной реализации демонстрационной системы. В третьей главе будет проведена экспериментальная оценка качества разработанных подходов, анализ ошибок, исследование задержки обработки кадра и сравнение CPU/GPU-вариантов модели.

ГЛАВА 3. ЭКСПЕРИМЕНТАЛЬНАЯ ОЦЕНКА МОДЕЛИ И ПРОТОТИПА

3.1. Экспериментальный стенд и протокол оценки

Экспериментальная оценка разработанного модуля машинного зрения выполнялась для проверки трёх основных аспектов: качества определения стадии индукционной пайки, точности формирования события начала активной пайки и времени обработки кадра. Такой подход обусловлен тем, что разрабатываемая система должна не только корректно классифицировать визуальные стадии процесса, но и работать в режиме, близком к реальному времени.

В качестве исходных данных использовались видеозаписи процесса индукционной пайки волноводных трактов. По каждой записи выполнена интервальная разметка стадий, на её основе собраны покадровые датасеты. Частоты извлечения кадров — две: 3 FPS и 10 FPS. Датасет 3 FPS применялся для первичного анализа, выбора области интереса, построения OpenCV baseline и первых нейросетевых экспериментов. Датасет 10 FPS использовался для финального обучения нейросетевых моделей и оценки события начала активной пайки, поскольку переходные стадии в нём представлены полнее.

Разбиение на train/val/test выполнялось по идентификатору видеозаписи. Так снижается риск утечки соседних кадров между выборками. При случайном делении по отдельным кадрам визуально почти одинаковые кадры одного видео могли бы попасть одновременно в обучающую и тестовую выборки — оценка качества тогда была бы завышена. Разбиение по video_id обеспечивает более корректную проверку, как модель обобщает результат на новые видеозаписи.

Для экспериментальной оценки использовались следующие группы методов:

1. Базовый подход на базе OpenCV-признаков и классических моделей машинного обучения.

2. Нейросетевые модели классификации стадий: ResNet18 и MobileNetV3 Small.
3. Алгоритмы постобработки последовательности предсказаний: majority smoothing и конечный автомат стадий.
4. Триггеры начала активной пайки: нейросетевой триггер на основе P(active_brazing) и резервный OpenCV-Trigger.
5. Варианты моделей для запуска на центральном процессоре: MobileNetV3 Small и ResNet18 с уменьшенным входным разрешением.

Качество классификации оценивается многоклассовыми метриками: accuracy, macro-F1, weighted-F1, а также precision, recall и F1-score по отдельным классам. Отдельно — F1 и recall для «active_brazing»: на этой стадии начинается плавление и протекание припоя, и качество сигнала «Hold Temperature» напрямую связано с её распознаванием. [11]

Accuracy — общая доля корректных кадров. Использовать только эту метрику недостаточно: подготовительный нагрев почти всегда длиннее активации флюса и активной пайки, и одна accuracy может скрывать снижение качества на коротких стадиях. Поэтому ведущая агрегированная метрика — macro-F1, усреднённая по классам без учёта их частоты; дополнительно используется weighted-F1, учитывающий число кадров каждого класса.

Для анализа ошибок строились матрицы ошибок и таблицы наиболее частых пар. По ним определяется, какие стадии модель чаще смешивает. Основные ошибки приходятся на соседние стадии: «flux_activation» с «active_brazing», «active_brazing» со «stabilization». Это согласуется с непрерывным характером процесса и размытыми визуальными границами между стадиями.

Для задачи обнаружения события начала активной пайки применялись временные метрики. Для каждой тестовой видеозаписи из интервальной разметки определялся истинный момент начала стадии «active_brazing». Алгоритм триггера формировал предсказанный момент первого устойчивого

срабатывания. Далее рассчитывалась ошибка срабатывания:

$$e = t_{pred} - t_{true},$$

где t_{true} — размеченный момент начала активной пайки, а t_{pred} — момент первого срабатывания триггера. Если значение отрицательно, триггер сработал раньше размеченного момента; если положительно — позже. Для оценки использовались средняя абсолютная ошибка, медианная абсолютная ошибка, максимальная абсолютная ошибка, число ранних и поздних срабатываний, а также доля видеозаписей, для которых ошибка не превышала 1 и 2 секунды.

Отдельной частью оценки являлось измерение задержки обработки кадра. Для прикладного применения системы важно, чтобы полный цикл укладывался в режим, близкий к реальному времени. Целевое ограничение принято на уровне 50 мс на кадр. При оценке учитывался не только прямой проход модели, а весь конвейер обработки: чтение кадра, выделение области интереса, предобработка изображения, инференс модели, работа триггеров и постобработка предсказаний.

При измерении задержки учитывались следующие компоненты:

- `frame_read_ms` — время чтения кадра;
- `preprocess_ms` — время выделения ROI и предобработки изображения;
- `model_ms` — время прямого прохода модели;
- `neural_trigger_ms` — время работы нейросетевого триггера;
- `cv_trigger_ms` — время расчёта OpenCV-триггера;
- `postprocess_ms` — время работы конечного автомата и другой постобработки;
- `total_ms` — полное время обработки кадра.

Итоговые показатели задержки — среднее значение и 95-й перцентиль. Использование `p95` важно, поскольку среднее значение может скрывать редкие, но значимые всплески задержки. Если `p95` полного времени обработки кадра ниже 50 мс, в подавляющем большинстве кадров система удовлетворяет

целевому ограничению. [16]

В работе отдельно оценивались два режима — качественный и вычислительно эффективный. Качественный ориентирован на максимальную точность определения стадии: ResNet18 при наличии GPU. Вычислительно эффективный режим ориентирован на запуск на центральном процессоре: облегчённая MobileNetV3 Small и ResNet18 с уменьшенным входным разрешением. Такое разделение позволило оценить не только наилучшее качество, но и возможность применения прототипа на менее производительном оборудовании.

Все эксперименты сохранялись в воспроизводимых артефактах: CSV-файлы с предсказаниями, JSON-файлы с метриками, графики, матрицы ошибок, временные диаграммы, контрольные точки моделей и демонстрационные видео. Это позволило сопоставлять результаты разных этапов исследования и проводить повторную оценку без переобучения моделей.

Протокол в таблице 3.1 отражает логику исследования: от интерпретируемого базового подхода к нейросетевой модели, затем к временной стабилизации, событийному триггеру и проверке вычислительной применимости системы.

Таблица 3.1 — Протокол экспериментальной оценки разработанного модуля

Этап	Метод / модель	Данные	Основные метрики	Назначение
OpenCV baseline	OpenCV-признаки + классические ML-модели	3 FPS, ROI	accuracy, macro-F1, confusion matrix	Проверка интерпретируемых признаков
Neural baseline	ResNet18, MobileNetV3 Small	3 FPS, ROI	accuracy, macro-F1, weighted-F1	Первичная проверка нейросетевого подхода
Final stage classification	ResNet18, MobileNetV3 Small	10 FPS, ROI	accuracy, macro-F1, active_brazing $\bar{F1}$	Финальная классификация стадий

State machine	Majority smoothing, state machine v1–v4	Предсказания ResNet18	macro-F1, timeline, error pairs	Стабилизация операторской стадии
Active brazing trigger	P(active_brazing), CV-score	Test-видео	MAE времени, early/late, within 1s/2s	Обнаружение начала активной пайки
Latency benchmark	ResNet18, MobileNetV3, ResNet18 64×64	Видео MVI_6266	mean, p95, total_ms	Проверка ограничения 50 мс/кадр
CPU-friendly study	ResNet input size, MobileNet evolution	10 FPS, ROI	quality vs latency	Подбор модели для CPU-режима

3.2. Оценка базового OpenCV-подхода

Первым экспериментальным этапом стала оценка базового подхода на основе классических признаков компьютерного зрения. Цель этого эксперимента состояла не только в получении начального уровня качества классификации, но и в проверке того, насколько визуальные стадии процесса пайки различимы с помощью явно заданных признаков изображения.

В качестве входных данных для базового подхода использовались ROI-кадры, извлечённые из видеозаписей процесса пайки. Для каждого кадра рассчитывался набор признаков, описывающих яркость, цвет, текстурность, наличие бликов, плотность границ и межкадровое изменение. На основе этих признаков формировалась табличная выборка, которая далее использовалась для обучения классических моделей машинного обучения. [14]

В ходе OpenCV baseline рассматривались следующие модели:

- Logistic Regression;
- Random Forest;
- Gradient Boosting.

Такой набор моделей позволил проверить как линейный классификатор, так и нелинейные методы, способные учитывать более сложные зависимости между признаками. В качестве основной агрегированной метрики использовалась macro-F1, поскольку классы стадий имеют разную представленность в датасете, а короткие стадии, такие как «flux_activation» и

«active_brazing», имеют особую технологическую значимость. [21]

Наиболее показательный результат среди базовых моделей был получен для Logistic Regression с временным сглаживанием предсказаний. Итоговые метрики OpenCV baseline приведены далее:

Таблица 3.2 — Метрики OpenCV baseline

Модель	Accuracy	Macro-F1	Weighted-F1
LogisticRegression	0.6219	0.5740	0.6904
Logistic Regression + temporal smoothing	0.6296	0.5809	0.6964

По таблице 3.2 OpenCV baseline даже с временным сглаживанием не достигает уровня надёжной классификации стадий. Явно заданные признаки пригодны для первичного анализа, но сложные пространственные изменения в зоне шва описать ими не удаётся. Сильнее всего метрики снижаются на переходах, где визуальные признаки перекрываются.

По матрице ошибок, изображённой на рисунке 3.1, у OpenCV baseline ошибки сосредоточены на переходах. Чаще всего смешиваются «inactive_preparation» и «flux_activation», а кадры «active_brazing» относятся к «flux_activation». Ранняя активная пайка и активация флюса визуально близки: для обеих характерны рост яркости, появление бликов и сдвиг текстуры.

Наиболее характерные ошибки OpenCV baseline можно описать следующим образом:

- «inactive_preparation» → «flux_activation»;
- «active_brazing» → «flux_activation»;
- «stabilization» → «flux_activation»;
- «stabilization» → «active_brazing».

Из этих ошибок видно основное ограничение: OpenCV-признаки фиксируют, что в ROI происходят изменения, но не отвечают, что именно. Блик может быть и от флюса, и от расплава припоя; межкадровая разница появляется и при протекании припоя, и при небольшом сдвиге яркости или текстуры поверхности. Дополнительные результаты анализа OpenCV baseline

приведены в приложении В.3.




Рисунок 3.1 — Матрица ошибок OpenCV baseline для классификации стадий пайки

Главная слабость OpenCV baseline — слабое разделение «flux_activation» и «active_brazing». Технологически стадии различны: на первой — активация флюса и подготовка поверхности, на второй — плавление и протекание припоя. Визуально же граница размыта, и часть признаков ведёт себя одинаково. Одних явно заданных признаков для надёжной фиксации начала активной пайки уже не хватает.

При этом OpenCV baseline сохраняет исследовательскую ценность. В исследовании он выполняет две роли. Первая — интерпретируемая базовая линия для сравнения с нейросетевыми моделями. Вторая — разбор признаков: он позволил определить, какие визуальные характеристики связаны с ходом пайки; эти признаки затем были использованы в резервном CV-триггере.

По результатам оценки OpenCV baseline можно сделать следующий вывод: классические признаки частично описывают визуальную динамику процесса, но не обеспечивают качества, необходимого для финального модуля определения стадии. Это обосновывает переход к нейросетевым моделям,

которые сами строят сложные пространственные признаки на ROI.

3.3. Оценка нейросетевого baseline на 3 FPS

Следующим шагом после OpenCV baseline был первичный нейросетевой эксперимент на датасете 3 FPS. Задача этапа — проверить, превосходит ли свёрточная сеть на ROI классический подход с явно заданными признаками.

Сравнивались две архитектуры — ResNet18 и MobileNetV3 Small, обе применялись к ROI-кадрам четырёх стадий. Дисбаланс классов компенсировался весами в функции потерь. Тестовая выборка формировалась по отдельным видеозаписям, чтобы исключить утечку соседних кадров. [12] [15]

По результатам эксперимента ResNet18 показала более высокое качество, чем OpenCV baseline. Метрики ResNet18 на тестовой выборке сведены в таблицу 3.3.

Таблица 3.3 — Результаты ResNet18 и MobileNetV3 Small baseline на датасете 3 FPS

Модель	Выборка	Accuracy	Macro-F1	Weighted-F1
ResNet18	validation	0.9482	0.8902	-
MobileNetV3 Small	validation	0.9360	0.8579	-
ResNet18	test	0.9347	0.8489	0.9307
ResNet18 + temporal smoothing	test	0.9367	0.8477	0.9315

Метрики показывают: и при 3 FPS свёрточная сеть выделяет более информативные признаки изображения, чем классический OpenCV-подход. Значительно выросло значение macro-F1 — это особенно важно при несбалансированном наборе стадий.

По поклассовому отчёту «inactive_preparation» и «stabilization» распознаются уверенно, а «active_brazing» остаётся самой проблемной стадией. У неё снижается recall — стадия короткая и визуально близка к соседним.

Для анализа распределения ошибок была построена матрица ошибок модели ResNet18 на тестовой выборке. Матрица ошибок представлена на рисунке 3.2. Дополнительные временные диаграммы предсказаний

нейросетевого baseline приведены в приложении В.4.

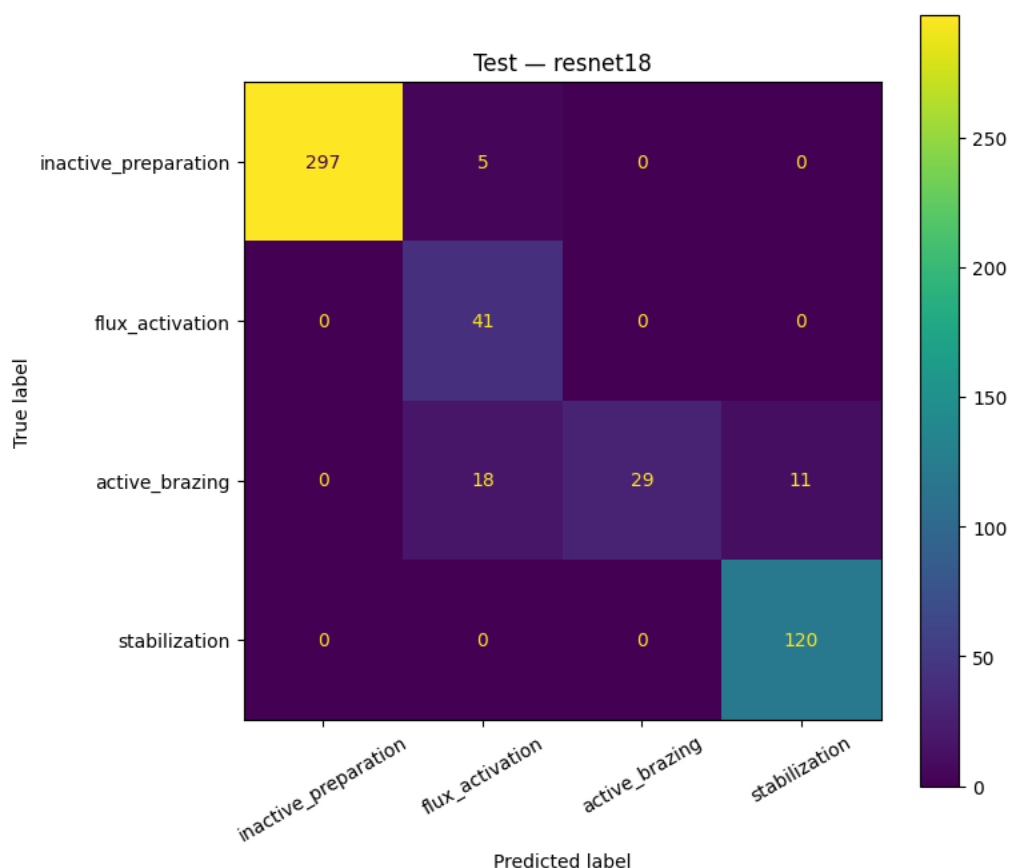


Рисунок 3.2 — Матрица ошибок ResNet18 baseline на датасете 3 FPS

По матрице ошибок «inactive_preparation» и «stabilization» классифицируются корректно почти всегда. Основные ошибки приходятся на переходные кадры, в первую очередь у «active_brazing». Из этого следуют два вывода: повышать временную детализацию датасета и отдельно анализировать событие начала активной пайки.

MobileNetV3 Small на этом шаге выступала как облегчённая альтернатива для будущего режима запуска на центральном процессоре. Цель — проверить, что компактная архитектура применима к данной задаче; в качестве финальной качественной модели она не использовалась. В дальнейших экспериментах MobileNetV3 Small включается уже в разделах про задержку и CPU-оптимизацию.

Прямое сравнение показывает масштаб различий: OpenCV baseline после temporal smoothing показывает macro-F1 около 0,58, ResNet18 на 3 FPS

достигает значения около 0,85. Задача действительно требует автоматического извлечения сложных пространственных признаков ROI.

Также эксперимент на 3 FPS показал ограничение низкой частоты кадров. Короткие стадии — «flux_activation» и «active_brazing» — представлены в обучающей выборке меньшим числом кадров, поэтому переходные состояния модель распознаёт хуже, а время начала активной пайки оценивается грубее. Это и стало основанием для перехода к 10 FPS, который рассматривается ниже.

3.4. Финальная нейросетевая классификация стадий на 10 FPS

Первичный нейросетевой эксперимент на 3 FPS показал, что свёрточные модели обеспечивают более высокое качество, чем OpenCV baseline. Однако для переходных стадий — прежде всего «flux_activation» и «active_brazing» — частота 3 FPS ограничивает число обучающих примеров и временную детализацию. Поэтому для финального этапа классификации собран отдельный датасет с частотой 10 FPS.

Переход на 10 FPS дал два эффекта. Короткие стадии получили больше обучающих кадров, моменты переходов стали определяться по времени точнее. Особенно это важно для «active_brazing»: на ней начинается плавление и протекание припоя, и на её вероятности строится триггер.

В финальном эксперименте сравнивались следующие варианты нейросетевых моделей:

- ResNet18 base;
- ResNet18 с усилением веса класса «active_brazing»;
- MobileNetV3 Small.

ResNet18 base использовалась как основной качественный вариант. Конфигурация с усилением веса класса «active_brazing» проверяла гипотезу, что так можно точнее распознавать наиболее значимую стадию. MobileNetV3 Small — облегчённая модель для потенциального запуска на центральном

процессоре. [12] [15]

Лучшая модель выбиралась по валидационной выборке. Основная метрика — macro-F1: она учитывает качество по всем классам независимо от их представленности. Дополнительно отслеживались F1 и recall для класса «active_brazing».

По таблице 3.4 наилучшее значение macro-F1 у ResNet18 base. Вариант с усилением класса «active_brazing» повысил полноту этой стадии, но уступил базовой ResNet18 по общей сбалансированной метрике. MobileNetV3 Small уступила в точности классификации, но сохранила интерес как вычислительно эффективная модель для режима запуска на центральном процессоре.

Таблица 3.4 — Сравнение нейросетевых моделей на валидационной выборке 10 FPS

Модель	Best val macro-F1	Best val accuracy	Active brazing F1	Active brazing recall
ResNet18 base	0.9199	0.9533	0.9063	0.8406
ResNet18 active brazing boost	0.9005	0.9478	0.8652	0.8841
MobileNetV3 Small	0.7952	0.8983	0.7378	0.9275

После выбора лучшей модели была выполнена финальная оценка ResNet18 base на тестовой выборке. Результаты сведены в таблицу 3.5.

Таблица 3.5 — Результаты ResNet18 base на тестовой выборке 10 FPS

Метрика	Значение
Accuracy	0.8747
Macro-F1	0.8209
Weighted-F1	0.8895
Active brazing F1	0.8097
Active brazing recall	0.6837

Поклассовый отчёт показал: модель уверенно распознаёт «inactive_preparation» и «stabilization» и достигает высокой точности на «active_brazing». Полнота класса «active_brazing» при этом ниже, чем у некоторых других классов, что связано с визуальной близостью активной пайки к соседним стадиям и неоднозначностью границ перехода.

Для оценки влияния временного сглаживания была дополнительно применена постобработка majority smoothing. Результаты после сглаживания

представлены в таблице 3.6.

Таблица 3.6 — Результаты ResNet18 base после temporal smoothing

Метрика	Значение
Accuracy	0.8776
Macro-F1	0.8290
Weighted-F1	0.8926
Active brazing F1	0.8368
Active brazing recall	0.7194

Сглаживание немного повысило общие метрики и улучшило F1 класса «active_brazing». Это показывает, что часть ошибок модели имеет кратковременный характер и может быть уменьшена за счёт учёта временного контекста. Однако обычное сглаживание не учитывает технологическую последовательность стадий; поэтому в дальнейшем для финальной операторской стадии используется конечный автомат.

Для анализа распределения ошибок была построена матрица ошибок финальной модели ResNet18 base на тестовой выборке. Матрица ошибок представлена на рисунке 3.3.




Рисунок 3.3 — Матрица ошибок модели ResNet18 base на тестовой выборке 10 FPS

Ошибки сосредоточены на переходных стадиях. Чаще всего кадры «active_brazing» относятся к «flux_activation» и «stabilization»; отдельные кадры «inactive_preparation» — в «flux_activation». Это согласуется с физикой: границы стадий непрерывны, а первые признаки плавления припоя визуально близки к признакам активации флюса.

Дополнительно были собраны таблицы наиболее частых ошибок. Основные пары ошибок финальной модели:

- «inactive_preparation» → «flux_activation»;
- «active_brazing» → «flux_activation»;
- «active_brazing» → «stabilization»;

Таким образом, основная трудность задачи связана не с устойчивыми состояниями, а с окрестностями границ между стадиями. Поэтому покадрового выхода модели недостаточно: архитектура дополнительно включает конечный автомат и отдельный событийный триггер.

Дополнительно была проведена оценка модели без учёта сложной видеозаписи MVI_6265, содержащей сложные визуальные условия. В этом режиме качество существенно возрастает:

Необработанные нейронные предсказания без MVI_6265:

- accuracy: 0.9598;
- macro-F1: 0.9175;
- weighted-F1: 0.9573;

Мажоритарное сглаживание без MVI_6265:

- accuracy: 0.9624;
- macro-F1: 0.9234;
- weighted-F1: 0.9601;

Эти результаты показывают: на штатных видеозаписях модель работает заметно устойчивее, а основное снижение качества связано с отдельными сложными сценариями. Поэтому MVI_6265 далее рассматривается как

сложный случай для анализа ограничений системы, а не как типичный пример работы алгоритма.

Для наглядной оценки поведения модели во времени была построена диаграмма истинных и предсказанных стадий для отдельной видеозаписи. Образец такой диаграммы представлен на рисунке 3.4.




Рисунок 3.4 — Сравнение истинных и предсказанных стадий модели ResNet18 base на примере видеозаписи MVI_6266

На временной диаграмме видно, что общая последовательность стадий воспроизводится корректно, но рядом с границами переходов появляются локальные ошибки. Это обосновывает применение конечного автомата, к которому переходит следующий раздел.

Финальный эксперимент на 10 FPS подтвердил применимость ResNet18 для определения стадий индукционной пайки. Качество заметно выше, чем у OpenCV baseline; вероятности классов на выходе модели используются как для выбора сырой стадии, так и для триггера. Ошибки на границах стадий остаются и делают необходимой временную постобработку через конечный автомат.

3.5. Оценка алгоритма стабилизации стадий

После получения покадровых предсказаний нейросетевой модели был проведён отдельный эксперимент по стабилизации последовательности стадий. Задача этого этапа заключалась в том, чтобы преобразовать сырые предсказания модели в технологически согласованную последовательность, пригодную для отображения оператору.

Сырые предсказания ResNet18 base на 10 FPS показали высокое общее качество, но у границ стадий встречаются кратковременные ошибки. Чаще всего они приходятся на переходы «flux_activation» ↔ «active_brazing» ↔ «stabilization», где визуальные признаки сменяются плавно и частично перекрываются.

Для стабилизации были рассмотрены три варианта обработки последовательности предсказаний:

1. Raw predictions — сырые покадровые предсказания модели.
2. Majority smoothing — временное сглаживание по окну последних кадров.
3. State machine — конечный автомат с технологически допустимой последовательностью стадий.

Raw predictions служат отправной точкой без постобработки. Majority smoothing подавляет одиночные ошибки, выбирая самый частый класс в окне последних кадров; но технологический порядок при этом не учитывается, и обратный переход формально разрешён. State machine реализован как конечный автомат с фиксированной разрешённой последовательностью стадий.

inactive_preparation → flux_activation → active_brazing → stabilization.

В эксперименте оценивались как общие метрики классификации, так и поведение моделей на временных диаграммах. Сравнение основных вариантов постобработки представлено в таблице 3.7.

Таблица 3.7 — Сравнение вариантов постобработки предсказаний ResNet18 base

Метод	Accuracy	Macro-F1	Weighted-F1
Raw predictions	0.8747	0.8209	0.8895
Majority smoothing, window = 5	0.8776	0.8290	0.8926
State machine v1	0.8493	0.8083	0.8714

По таблице 3.7 в покадровых метриках majority smoothing немного превосходит сырые предсказания и конечный автомат — он оптимизирует

именно локальную согласованность с разметкой. Для операторского отображения этого недостаточно: важна корректность всей последовательности стадий, а не только метка отдельного кадра.

State machine v1 уступает по покадровым метрикам, зато добавляет важное свойство — запрет обратных переходов и перескоков стадий. Последовательность становится согласованной с физикой процесса: после подтверждённого перехода к «active_brazing» система не вернётся обратно к «flux_activation», даже если отдельный кадр будет ошибочно классифицирован как «flux_activation».

Для подбора параметров state machine был проведён поиск по сетке значений min_confirm_frames и window_size. В ходе эксперимента оценивались accuracy, macro-F1, weighted-F1, F1 для «flux_activation», F1 для «active_brazing» и recall для «active_brazing». Лучшие результаты представлены в таблице 3.8.

Таблица 3.8 — Результаты подбора параметров state machine

min_confirm_frames	window_size	Accuracy	Macro-F1	Weighted-F1	Active brazing F1	Active brazing recall
3	7	0.8493	0.8083	0.8714	0.8504	0.7398
3	10	0.8493	0.8083	0.8714	0.8504	0.7398
3	15	0.8493	0.8083	0.8714	0.8504	0.7398
5	7	0.8441	0.7988	0.8674	0.8304	0.7245
7	15	0.8412	0.7916	0.8654	0.8131	0.6990

Поиск по сетке показал: для финальной демонстрационной системы наиболее подходящие параметры — min_confirm_frames = 3 и window_size = 7. Такой выбор обусловлен стремлением получить более устойчивое операторское отображение и снизить вероятность преждевременного перехода из-за одиночных всплесков предсказаний. Расширенные результаты подбора параметров конечного автомата приведены в приложении В.5.

Для качественного анализа поведения алгоритмов постобработки была построена временная диаграмма, сопоставляющая истинные стадии, сырые предсказания модели, результат majority smoothing и результат конечного

автомата. Образец такой диаграммы представлен на рисунке 3.5.




Рисунок 3.5 — Сравнение сырых предсказаний, временного сглаживания и конечного автомата на видеозаписи MVI_6266

Из временной диаграммы видно: конечный автомат формирует более технологически согласованную последовательность стадий. Когда сырые предсказания модели кратковременно отклоняются, стабилизированная стадия сменяется только после подтверждения перехода. Это соответствует требованиям операторского отображения.

Отдельно проведена оценка модели и постобработки без учёта сложной видеозаписи MVI_6265. Это видео содержит сложные визуальные условия и неоднозначные изменения флюса, что приводит к большому числу ранних ложных переходов. При исключении этого видео качество существенно возрастает.

По таблице 3.9 на штатных видео без сложной видеозаписи MVI_6265 state machine v1 по покадровым метрикам сопоставима с raw predictions и majority smoothing — и при этом сохраняет технологически корректный порядок стадий. F1 для «active_brazing» у state machine v1 выше, чем у raw predictions и majority smoothing.

Таблица 3.9 — Оценка модели и постобработки без hard-case MVI_6265

Метод	Accuracy	Macro-F1	Weighted-F1	Active brazing F1	Flux activation F1
Raw predictions	0.9598	0.9175	0.9573	0.8051	0.9250
Majority smoothing, window = 5	0.9624	0.9234	0.9601	0.8186	0.9328
State machine v1	0.9581	0.9155	0.9562	0.8333	0.8766

Несмотря на лёгкое снижение общих покадровых метрик на полном тестовом наборе, в финальной стабилизации операторской стадии оставлена конфигурация *state machine v1*. Выбор продиктован не только числовыми метриками: оператору должно показываться последовательное представление процесса пайки, а не набор независимых покадровых решений.

Главный вывод эксперимента: временная постобработка — необходимый компонент. Сырые предсказания сети показывают высокие средние метрики, но дают локальные ошибки у границ стадий. *Majority smoothing* улучшает покадровые метрики, но не гарантирует технологически корректный порядок. Конечный автомат удерживает порядок и поэтому формирует «*Stable Stage*» в финальной демонстрационной системе.

3.6. Оценка триггера начала активной пайки

После оценки классификатора стадий и алгоритма стабилизации отдельно проверена задача обнаружения события начала активной пайки. Здесь акцент смещён на другую задачу: интересна не точность класса каждого кадра, а момент первого устойчивого срабатывания триггера относительно размеченного начала стадии «*active_brazing*».

Событие начала активной пайки технологически значимо: оно совпадает с началом плавления и протекания припоя. В демонстрационном прототипе именно оно формирует рекомендательный сигнал «*Hold Temperature*», поэтому для этого блока проведена отдельная событийная оценка.

В работе были проверены три варианта триггера:

1. Нейросетевой триггер на основе вероятности $P(\text{active_brazing})$.
2. OpenCV-триггер на основе правил и интерпретируемого CV-score. [14]
3. Бинарный триггер на основе классической ML-модели на OpenCV-признаках.

Основной вариант — нейросетевой триггер. Алгоритм опирается на вероятность класса «*active_brazing*» из финальной модели классификации стадий. Если она превышает заданный порог на нужном числе подряд идущих

кадров, событие «active_brazing_started» считается подтверждённым. [22] [23]

Для оценки работы триггера для каждого тестового видео определялся истинный момент начала стадии «active_brazing», заданный в интервальной разметке. Затем определялся момент первого устойчивого срабатывания триггера. Ошибка срабатывания рассчитывалась как:

$$e = t_{pred} - t_{true},$$

где t_{true} — размеченное время начала активной пайки, а t_{pred} — время первого срабатывания триггера. Положительное значение ошибки означает позднее срабатывание, отрицательное — раннее.

Для сравнения триггеров использовались следующие показатели:

- num_detected — число видео, на которых событие обнаружено;
- num_missed — число пропущенных видео;
- num_early — число ранних срабатываний;
- num_late — число поздних срабатываний;
- MAE — средняя абсолютная ошибка времени срабатывания;
- max_abs_error — максимальная абсолютная ошибка;
- within_1.0s — доля видео с ошибкой не более 1 секунды;
- within_2.0s — доля видео с ошибкой не более 2 секунд.

Результаты сравнения основных вариантов триггера представлены в таблице 3.10.

Таблица 3.10 — Сравнение вариантов триггера начала активной пайки

Метод	Thresh old	Confir m frame s	Detect ed	Miss ed	Ear ly	Lat e	MA E, c	Max erro r, c	With in 1 s	With in 2 s
P(active_braz ing) trigger	0.2	7	3/3	0	0	3	0.70	1.0	1.000	1.000
CV rule trigger	0.5	5	3/3	0	1	2	0.60	1.8	0.667	1.000
CV binary ML trigger	0.6	7	2/3	1	0	2	0.95	1.5	0.500	1.000

По таблице 3.10 событие фиксируется всеми тремя подходами, но

устойчивее остальных — нейросетевой триггер на $P(\text{active_brazing})$. OpenCV-триггер на основе правил тоже сработал на всех тестовых видео, но сформировал одно раннее срабатывание.

OpenCV-триггер на основе правил остаётся работоспособным: начало активной пайки он обнаружил на всех тестовых видео и удержал ошибку в пределах 2 секунд. Доля срабатываний с ошибкой не более 1 секунды у него ниже, чем у нейросетевого, — CV-score опирается на фиксированный набор признаков и чувствителен к нормировке, освещению и локальной структуре кадра.

Бинарный триггер на основе классической ML-модели на OpenCV-признаках оказался менее устойчивым: пропустил одно из трёх тестовых видео. Поэтому в качестве основного источника сигнала он не рассматривался — но как дополнительная проверка возможностей классических признаков сохраняет практическую ценность.

Для визуальной проверки построена временная диаграмма работы нейросетевого триггера, отображённая на рисунке 3.6: на ней показаны рост $P(\text{active_brazing})$, размеченный момент начала активной пайки и момент первого срабатывания триггера.




Рисунок 3.6 — Временная диаграмма срабатывания нейросетевого триггера начала активной пайки

Также было установлено, что сложные случаи с неоднозначными бликами и нестабильным флюсом провоцируют ранние или неточные срабатывания отдельных вариантов триггера. Однако и в таких случаях

P(active_brazing) сохраняет информативность — модель оценивает её по всему ROI, а не по одному локальному признаку.

Поиск по сетке показал, что триггер имеет несколько равнозначных с точки зрения метрик конфигураций. Для финальной демонстрации был выбран порог 0,4 и подтверждение 1 кадром для достижения наиболее быстрого отклика. Расширенные результаты подбора параметров нейросетевого триггера приведены в приложении В.6.

В финальную архитектуру заложен следующий принцип:

- Основной сигнал «active_brazing_started» формируется нейросетевым триггером;
- CV-Trigger используется как дополнительный интерпретируемый резервный сигнал;
- «Hold Temperature» формируется на основе Neural Trigger.

Так в системе остаётся одна нейросетевая модель и отпадает необходимость во втором классификаторе для управляющего сигнала. Архитектура остаётся единой и менее затратной по вычислениям: одна модель формирует и стадию процесса, и вероятность «active_brazing», из которой формируется событие начала активной пайки.

Эксперимент подтвердил: задача обнаружения начала активной пайки решается событийной надстройкой над классификатором стадий. Нейросетевой триггер на P(active_brazing) показывает наиболее устойчивый результат и формирует «Hold Temperature». OpenCV-Trigger остаётся резервным интерпретируемым каналом — удобен для проверки устойчивости и анализа сложных сценариев.

3.7. Демонстрация работы финальной системы

Для проверки работоспособности разработанного модуля в прикладном сценарии был реализован режим построения демонстрационного видеоролика. В этом режиме система обрабатывает исходную видеозапись процесса

индукционной пайки, выполняет инференс модели для каждого кадра, применяет постобработку результатов и сохраняет новое видео с наложением служебной информации поверх исходного кадра.

Демонстрационный режим предназначен для наглядной проверки работы всех ключевых компонентов архитектуры:

- Выделение области интереса;
- Нейросетевая классификация стадии;
- Стабилизация стадии через конечный автомат;
- Формирование триггера начала активной пайки;
- Отображение сигнала «Hold Temperature»;
- Измерение времени инференса.

Для построения демонстрационного видео использовался скрипт:

scripts/run_neural_inference_video.py

Скрипт принимает на вход путь к исходному видео, контрольную точку обученной модели, архитектуру модели, координаты области интереса, размер входного изображения, режим постобработки и параметры триггера начала активной пайки. На выходе формируется видеоролик, в котором каждый кадр содержит как исходное изображение зоны пайки, так и результаты работы системы.

В финальной демонстрационной системе поверх кадра отображается набор показателей:

- Raw Stage — сырое покадровое предсказание модели;
- Stable Stage — стабилизированная стадия после применения конечного автомата;
- Confidence — уверенность модели в выбранной сырой стадии;
- $P(active_brazing)$ — вероятность класса активной пайки;
- Neural Trigger — состояние нейросетевого триггера начала активной пайки;

- CV Score — значение резервного OpenCV-score при включённом CV-триггере;
- CV Trigger — состояние резервного OpenCV-триггера;
- Hold Temperature — рекомендательный сигнал фиксации температуры;
- Inference — время инференса модели;
- Time — текущий момент видеозаписи;
- ROI rectangle — прямоугольник области интереса.

В интерфейсе одновременно отображаются два результата: предсказание нейросетевой модели на отдельном кадре («Raw Stage») и результат технологической стабилизации («Stable Stage»). По $P(active_brazing)$ оценивается приближение активной пайки; Neural Trigger фиксирует момент подтверждения события.

В демонстрационном видео «Hold Temperature» формируется после срабатывания нейросетевого триггера. Это не промышленный управляющий сигнал, а визуализация результата прототипа: система зафиксировала начало активной пайки и сформировала рекомендацию зафиксировать температуру или перейти к следующей фазе контроля.

Пример кадра демонстрационного видео с наложенной служебной информацией представлен на рисунке 3.7.

На рисунке 3.7 в кадре одновременно присутствуют сырое предсказание модели и стабилизированная стадия. Рядом — вероятность «active_brazing», состояния триггеров и рекомендательный «Hold Temperature». Это даёт возможность сопоставлять работу алгоритма с тем, что происходит в зоне пайки.

Для демонстрации подготовлены видеоролики по нескольким тестовым записям. Основной пример построен на видеозаписи MVI_6266 — она содержит достаточно чистую и последовательную визуальную картину процесса. На этом видео система проходит стадии подготовки, активации флюса, активной пайки и стабилизации и формирует «Hold Temperature» в

области начала активной пайки.



Рисунок 3.7 — Пример кадра демонстрационного видео с результатами работы системы

Отдельно подготовлены демонстрации для режима запуска на центральном процессоре. Для них использована облегчённая модель MobileNetV3 Small, отобранная при оптимизации под центральный процессор. В этом режиме качество распознавания отдельных стадий уступает ResNet18, но система сохраняет возможность сформировать сигнал начала активной пайки и работает без GPU.

Демонстрационный режим также позволил проверить читаемость результата. Разделение «Raw Stage» и «Stable Stage» оказалось удобным: первое — покадровая реакция нейросетевой модели, второе — технологически согласованное состояние процесса. Наиболее заметна польза такого разделения у границ стадий, где отдельный кадр сам по себе неоднозначен.

Строка Inference на демонстрационном видео — это визуальный контроль скорости. Данные собираются отдельным скриптом измерения задержки; вывод времени на кадре используется для быстрой проверки того, обеспечивает ли система режим, близкий к реальному времени.

Демонстрационный режим подтвердил: прототип работает как единая система. Видео объединяет в одном представлении ROI, нейросетевой классификатор, конечный автомат, триггер начала активной пайки, резервный CV-сигнал и визуализацию. Прототип может рассматриваться не только как исследовательская модель, но и как основа для прикладного модуля визуального контроля пайки.

3.8. Оценка задержки обработки кадра

Для прикладного применения разработанного модуля машинного зрения важно не только качество определения стадии пайки, но и время обработки кадра. Если система ведёт мониторинг процесса в режиме, близком к реальному времени, задержка между поступлением кадра и формированием результата должна быть ограничена. При выполнении работы в качестве целевого ограничения рассматривалась задержка не более 50 мс на кадр. [16]

Оценка задержки проводилась не только для прямого прохода нейросетевой модели, но и для полного цикла обработки кадра. Такой подход позволяет получить более реалистичную оценку производительности: в прикладной системе время уходит не только на инференс, но и на чтение кадра, выделение области интереса, предобработку изображения, постобработку предсказаний и работу триггера начала активной пайки.

Для измерения задержки был реализован скрипт:

scripts/benchmark_neural_latency.py

При измерении задержки учитывались следующие компоненты:

- `frame_read_ms` — время чтения кадра;
- `preprocess_ms` — время выделения ROI и предобработки изображения;
- `model_ms` — время прямого прохода модели;
- `neural_trigger_ms` — время работы нейросетевого триггера;
- `cv_trigger_ms` — время расчёта OpenCV-триггера;
- `postprocess_ms` — время работы конечного автомата и другой постобработки;

- `total_ms` — полное время обработки кадра.

Итоговые показатели — среднее время обработки кадра и 95-й перцентиль задержки. Среднее описывает типичное время обработки; p95 характеризует устойчивость системы с учётом редких всплесков задержки. Для прикладного применения важно, чтобы и среднее, и p95 полного времени обработки кадра оставались ниже целевого ограничения.

Результат ResNet18 на CPU при стандартном размере входа показывает, что высокая точность модели сама по себе недостаточна для практического применения без учёта вычислительных ограничений. В этом режиме среднее полное время обработки кадра — около 117 мс, p95 — около 165 мс. Иначе говоря, модель не может обеспечить требуемую частоту реакции при запуске на центральном процессоре без дополнительной оптимизации.

Для MobileNetV3 Small результат отличается. Архитектура изначально ориентирована на эффективный инференс: среднее полное время цикла обработки — около 25 мс, p95 — около 39 мс. По итогам MobileNetV3 Small удовлетворяет целевому ограничению 50 мс на кадр и может быть использована в режиме запуска на центральном процессоре. [15] [16]

Дополнительно проверено ускорение ResNet18 за счёт уменьшения входного разрешения. При входе 64×64 среднее полное время цикла обработки — около 26 мс, p95 — около 40 мс. Такой результат показывает, что даже более ресурсоёмкая архитектура адаптируется к CPU-режиму через уменьшение входного изображения. Тем не менее уменьшение разрешения может приводить к потере мелких визуальных признаков, поэтому такой вариант требует отдельной оценки качества классификации.

По таблице 3.11 видно: стандартная ResNet18 при входе 224×224 не укладывается в 50 мс на кадр при запуске на CPU — основная часть времени приходится на прямой проход модели. Облегчённая MobileNetV3 Small и вариант ResNet18 с входом 64×64 удовлетворяют ограничению по p95 и могут рассматриваться как варианты системы для запуска на центральном

процессоре.

Таблица 3.11 — Результаты оценки задержки обработки кадра для различных вариантов модели

Модель и режим	Устройство	Image size	Total mean, мс	Total p95, мс	Model mean, мс	Выполнение p95 < 50 мс
ResNet18	CPU	224×224	117.40	164.98	109.60	Нет
ResNet18	CPU	64×64	26.16	39.77	20.49	Да
ResNet18	GPU/CUDA	224×224	6.5	7.85	2.95	Да
MobileNetV3 Small	CPU	224×224	25.04	38.92	16.95	Да

Компонентный анализ показывает: время нейросетевого триггера, конечного автомата и прочей логической постобработки пренебрежимо мало по сравнению со временем прямого прохода модели. Нейросетевой триггер измеряется тысячными долями миллисекунды, время работы конечного автомата также незначительно на фоне инференса. Главный фактор производительности — выбранная архитектура и размер входного изображения.

Включение OpenCV-Trigger остаётся опциональным. При измерении задержки его вклад в общее время обработки кадра оказался малым по сравнению с нейросетевым инференсом. Тем не менее в финальной архитектуре CV-Trigger рассматривается как дополнительный канал и не включается в обязательный контур, если требуется минимизировать задержку обработки.

При интерпретации результатов benchmark необходимо учитывать, что задержка зависит от конкретного вычислительного оборудования, версии библиотек, способа чтения видео и других параметров среды выполнения. Поэтому полученные значения следует рассматривать как экспериментальную оценку прототипа в использованной среде, а не как универсальную характеристику системы. Перенос на целевой промышленный компьютер требует повторной проверки задержки.

С точки зрения требований к системе можно выделить два режима применения:

1. Качественный режим — ResNet18 при наличии GPU.
2. Режим запуска на центральном процессоре — MobileNetV3 Small или ResNet18 64×64 при запуске на CPU.

Качественный режим ориентирован на максимальное качество определения стадии и работает на оборудовании с графическим процессором. Режим запуска на центральном процессоре ориентирован на выполнение ограничения 50 мс на кадр без GPU, что важно для более простого внедрения на типовом промышленном или лабораторном компьютере.

Экспериментальная оценка задержки показала, что разработанная система может работать в режиме, близком к реальному времени, при выборе соответствующей модели и режима инференса. ResNet18 224×224 требует GPU или дополнительной оптимизации для выполнения ограничения 50 мс на кадр, тогда как MobileNetV3 Small и ResNet18 64×64 удовлетворяют этому ограничению при запуске на CPU.

3.9. Оптимизация моделей для запуска на центральном процессоре

По итогам оценки задержки архитектура и размер входного изображения напрямую определяют, способна ли система работать в режиме, близком к реальному времени. ResNet18 на стандартном входе 224×224 даёт высокое качество классификации, но на CPU не укладывается в ограничение 50 мс на кадр. Поэтому отдельно разобраны варианты адаптации архитектуры для режима запуска на центральном процессоре. [16]

Оптимизация для запуска на центральном процессоре в этой работе рассматривалась в двух направлениях:

1. Уменьшение входного разрешения для ResNet18.
2. Использование и настройка облегчённой архитектуры MobileNetV3 Small.

Первое направление связано с тем, что время прямого прохода свёрточной модели напрямую зависит от размера входа. При меньшем

разрешении уменьшается число операций в свёрточных слоях и ускоряется инференс. Ограничением такого решения является возможная потеря мелких визуальных признаков флюса, бликов, текстуры и деформации припоя при слишком сильном сжатии.

В ходе эксперимента были обучены и оценены варианты ResNet18 с размерами входа:

- 128×128;
- 96×96;
- 64×64.

Среди ResNet-моделей наиболее удачным вариантом для запуска на центральном процессоре оказалась ResNet18 с входом 64×64. После дополнительного дообучения она показала приемлемое качество классификации и выполнила ограничение по задержке обработки кадра.

По таблице 3.12 прослеживается ожидаемая закономерность: чем меньше входное разрешение, тем ниже задержка. Самый удачный баланс — у ResNet18 64×64 после дообучения: обеспечивает $p95 < 50$ мс и сохраняет macro-F1 выше 0,83. F1 по «active_brazing» снижается — мелкие визуальные признаки активной пайки на сниженном разрешении различаются хуже. Дополнительные материалы по модели ResNet18 64×64 после дообучения приведены в приложении В.7.

Таблица 3.12 — Сравнение качества и задержки ResNet18 при различных размерах входного изображения

Модель	fine-tune d	size	Accuracy	Macro-F1	Weighted-F1	Active brazing F1	Total mean, мс	Total p95, мс	p95 < 50 мс
ResNet18	Нет	64×64	0.8990	0.7967	0.9033	0.6534	26.16	39.8	Да
ResNet18	Нет	96×96	0.8580	0.7739	0.8715	0.6576	36.22	53.8	Нет
ResNet18	Нет	128×128	0.8331	0.7559	0.8500	0.6158	43.76	65.3	Нет
ResNet18	Да	64×64	0.9174	0.8328	0.9128	0.6410	26.16	39.8	Да
ResNet18	Да	96×96	0.8458	0.7484	0.8584	0.5811	36.22	53.8	Нет

Второе направление оптимизации для запуска на центральном

процессоре — MobileNetV3 Small. Архитектура изначально ориентирована на эффективный инференс и имеет существенно меньшую контрольную точку модели, чем ResNet18. В первых экспериментах MobileNetV3 Small показала более низкое качество классификации отдельных стадий, но обеспечила существенно меньшую задержку на CPU. Поэтому для неё дополнительно проведён упрощённый эволюционный подбор гиперпараметров. [15]

В ходе эволюционного поиска варьировались следующие параметры:

- Размер входного изображения;
- learning rate;
- weight decay;
- Коэффициент усиления класса «active_brazing»;
- Уровень аугментаций.

В качестве fitness-функции использовалась комбинация macro-F1 и качества распознавания стадии «active_brazing». Такой критерий учитывает и общее качество классификации, и качество самой значимой стадии для формирования события начала активной пайки.

Эволюционный поиск здесь — не полноценный нейроархитектурный поиск. Архитектура MobileNetV3 Small оставалась фиксированной, а оптимизация выполнялась по гиперпараметрам обучения и размеру входного изображения. Такой подход быстро проверил несколько конфигураций и выделил варианты, наиболее подходящие для режима запуска на центральном процессоре.

Результаты эволюционного поиска представлены в таблице 3.13: лучшие конфигурации MobileNetV3 Small получаются при умеренном learning rate, регуляризации weight decay и умеренном усилении класса «active_brazing». Сильное усиление этого класса не дало устойчивого улучшения — наоборот, повышало риск смещения модели в сторону активной пайки.

Таблица 3.13 — Результаты эволюционного подбора гиперпараметров MobileNetV3 Small

Кандидат	Image size	LR	Weight decay	Active brazing boost	Augmentation	Val macro-F1	Val active brazing F1
mobilenet evo 005	224	1e-4	3e-4	1.2	low	0.9274	0.9104
mobilenet evo 002	192	1e-4	3e-4	1.0	medium	0.9145	0.8951
mobilenet evo 015	128	3e-4	3e-4	1.2	low	0.8877	0.9278

Отобранные кандидаты повторно оценивались на тестовой выборке. Часть конфигураций показала расхождение между валидацией и тестом — следствие небольшого числа видеозаписей и сильной зависимости валидационного разбиения от конкретных видео. Отсюда практический вывод эксперимента: оценку необходимо выполнять по отдельным тестовым видео, а не только по валидации.

В сравнении кандидатов для запуска на центральном процессоре (таблица 3.14) лучший баланс macro-F1 и задержки среди ResNet-вариантов остаётся за ResNet18 64×64 после дообучения. MobileNetV3 Small сопоставима по задержке или быстрее, но в части экспериментов уступает ему по «active_brazing». MobileNet всё равно сохраняется в наборе моделей для демонстрационного режима на CPU — за счёт компактной контрольной точки модели и быстрого инференса.

Таблица 3.14 — Сравнение CPU-friendly моделей на тестовой выборке

Модель	Image size	Accuracy	Macro-F1	Weighted-F1	Active brazing F1	Total mean, мс	Total p95, мс
ResNet18 64 fine-tuned	64×64	0.9174	0.8328	0.9128	0.6410	26.16	39.77
MobileNetV3 evo best-1	224×224	0.8822	0.7820	0.8803	0.5714	21.69	34.75
MobileNetV3 evo best-2	192×192	0.8274	0.7044	0.8397	0.4752	-	-
MobileNetV3 evo best-3	128×128	0.9221	0.8239	0.9140	0.6133	-	-

После первичного подбора параметров MobileNetV3 Small была проверена ещё одна степень свободы компактной модели — конфигурация

классификационной головы и режим дообучения backbone-части. В этом эксперименте параметры обучения и входное разрешение фиксировались, а изменялась верхняя часть модели: тип классификационной головы, размер скрытого слоя, bottleneck ratio, dropout, функция активации, pooling, нормализация и режим дообучения. Backbone MobileNetV3 Small при этом оставался стандартным и загружался с предобученными весами, поэтому эксперимент корректнее рассматривать как легковесный NAS-like поиск по классификационной голове, а не как полноценный поиск всей архитектуры сети.

Для проверки поведения эволюционного поиска были сопоставлены валидационные метрики двадцати лучших кандидатов. На рисунке 3.8 показаны macro-F1, F1 и recall класса «active_brazing». Видно, что лучшие конфигурации отличаются не только общей macro-F1, но и балансом между качеством распознавания всех стадий и полнотой технологически важного класса «active_brazing».




Рисунок 3.8 — Метрики top-20 кандидатов эволюционного поиска классификационной головы MobileNetV3 Small

По результатам поиска лучшей конфигурацией стала mobilenet_arch_evo_039. Модель использовала двухслойную MLP-голову, hidden=256, bottleneck=0.5, dropout=0.1, активацию hardswish, объединённый

avg_max pooling, отсутствие нормализации в голове и полное дообучение backbone-части. На валидационной выборке она достигла macro-F1 = 0,9098, «active_brazing» F1 = 0,8812 и «active_brazing» recall = 0,8333. Она не была максимальной по recall «active_brazing», но дала наиболее удачный общий баланс: высокий валидационный macro-F1, высокий F1 для «active_brazing» и отсутствие явного перекоса в один класс. Именно поэтому эта конфигурация была выбрана для отдельной проверки на тестовом разбиении.

На тестовом разбиении выбранная модель показала хорошее общее качество (таблица 3.15): accuracy = 0,9013, macro-F1 = 0,7792 и weighted-F1 = 0,8942. Основное ограничение — осторожное распознавание «active_brazing». Из 196 кадров этой стадии модель правильно определила 97, ещё 31 кадр был отнесён к «flux_activation», а 68 — к «stabilization». То есть модель чаще не распознаёт активную пайку, чем ошибочно относит к ней другие стадии. При этом по задержке модель удовлетворяет целевому ограничению 50 мс на кадр на CPU: среднее время полного цикла обработки составило 23,94 мс, p95 — 38,27 мс.

Таблица 3.15 — Результаты MobileNetV3 Small с эволюционно подобранной классификационной головой (mobilenet_arch_evo_039)

Конфигурация	Test accuracy	Test macro-F1	Test weighted-F1	Active brazing F1	Active brazing recall	CPU total mean / p95, ms
mlp_2, hidden=256, bottleneck=0.5, dropout=0.1, hardswish, avg_max, full	0,9013	0,7792	0,8942	0,5988	0,4949	23,94 / 38,27

По матрице ошибок на рисунке 3.9 видно, что «stabilization» распознаётся без ошибок: все 398 кадров этой стадии отнесены к правильному классу. Стадия «inactive_preparation» также определяется устойчиво: 983 из 1000 кадров классифицированы верно. Основная проблема связана с центральной частью процесса: «active_brazing» частично смешивается с «flux_activation» и «stabilization». Для покадровой классификации это снижает

масро-F1 и recall активной пайки, но для демонстрационного режима такая ошибка менее опасна, чем поздние ложные предсказания «active_brazing» после завершения активной пайки.




Рисунок 3.9 — Матрица ошибок модели mobilenet_arch_evo_039 на test split

Таблица 3.16 подтверждает, что самая частая ошибка — отнесение «active_brazing» к «stabilization». С точки зрения логики триггера это слабое место: модель может позже достичь достаточной уверенности в «active_brazing». Но при этом поведение модели остаётся достаточно устойчивым во времени — она не начинает часто предсказывать «active_brazing» там, где процесс уже явно находится в стабилизации.

Таблица 3.16 — Основные пары ошибок модели mobilenet_arch_evo_039

Истинная стадия	Предсказанная стадия	Число ошибок
active brazing	stabilization	68
active brazing	flux activation	31
flux activation	active brazing	31
flux activation	inactive preparation	24
inactive preparation	flux activation	17

Дополнительно были дообучены пять лучших конфигураций на 30 эпох. Этот шаг проверял, можно ли улучшить найденные конфигурации классификационной головы более длительным обучением. Устойчивого улучшения получить не удалось. Лучший дообученный вариант по macro-F1 на тестовой выборке, `mobilenet_arch_final_05`, незначительно превзошёл `mobilenet_arch_evo_039` по общей macro-F1, но уступил по «active_brazing» F1 и «active_brazing» recall. Кроме того, на временной диаграмме у него появились поздние ложные предсказания «active_brazing» внутри «stabilization». Поэтому в качестве основного результата этого направления оставлена модель `mobilenet_arch_evo_039`, а дообучение пяти лучших конфигураций рассматривается как проверочный эксперимент, не подтвердивший устойчивого улучшения. Расширенные результаты подбора гиперпараметров и классификационной головы MobileNetV3 Small приведены в приложении В.7.

Итоговый набор моделей включает:

- ResNet18 224×224 — основной качественный вариант при наличии GPU;
- ResNet18 64×64 после дообучения — ResNet-вариант для запуска на центральном процессоре;
- MobileNetV3 Small — облегчённый вариант для демонстрации на центральном процессоре и дальнейшей оптимизации.

Этот набор покрывает разные вычислительные условия. На GPU целесообразно использовать ResNet18 224×224 как самый качественный вариант. Если система должна работать на CPU при ограничении 50 мс на кадр, остаются ResNet18 64×64 и MobileNetV3 Small; выбор между ними определяет приоритет — точность распознавания или минимальная задержка инференса.

Блок экспериментов для запуска на центральном процессоре показал, что лимит 50 мс на кадр без GPU достижим, но только при удачной паре «архитектура + размер входа». Снижение разрешения и переход на

облегчённые модели заметно снижают задержку — при этом требуется отдельная проверка качества, особенно по «active_brazing». Разработанный модуль работает и в качественном GPU-режиме, и в ограниченном CPU-режиме.

3.10. Ограничения эксперимента и анализ сложных случаев

Эксперименты подтвердили работоспособность прототипа; результаты следует интерпретировать с учётом ограничений исходных данных, условий съёмки и характера разметки. Система рассматривалась как исследовательский прототип, а не как завершённый промышленный контур управления — поэтому отдельный анализ ограничений входит в экспериментальную оценку.

Первое ограничение — объём и разнообразие видеоданных. Доступный набор записей пайки получен в близких условиях съёмки. Этого достаточно для воспроизводимого датасета и серии экспериментов, но недостаточно для полного охвата технологических сценариев. На результат могут повлиять смена камеры, ракурса, освещения, положения детали, геометрия тракта, состояние поверхности и режим нагрева. Перенос системы на другую установку или другую серию изделий потребует повторной проверки и, вероятно, дообучения.

Второе ограничение — визуальный характер разметки. Стадии размечались по видеозаписям через наблюдаемые признаки, а переходы непрерывные: флюс меняется постепенно, припой иногда начинает деформироваться раньше явного протекания, блики и текстура могут изменяться за несколько секунд до перехода к новой стадии. Из-за этого границы стадий не всегда абсолютно однозначны. Сильнее всего эффект заметен на переходе «flux_activation» → «active_brazing».

Третье ограничение — отсутствие синхронных физических измерений, привязанных к видеопотоку: температуры в зоне пайки, мощности индуктора и данных пирометрии. Из-за этого модель обучалась и оценивалась только по

визуальным признакам, а «active_brazing_started» в работе соответствует визуально размеченному началу активной пайки, а не строго измеренному моменту достижения физической температуры плавления припоя. [5] [6] [7]

Четвёртое ограничение — сложные визуальные условия. Часть видеозаписей содержит засветы, неоднозначные блики, нестабильную видимость флюса или нетипичное поведение припоя. От таких факторов снижается качество работы как классических OpenCV-признаков, так и нейросетевой модели. Подобные записи отнесены в работе к сложным случаям. [8] [9]

Самая показательная сложная видеозапись — MVI_6265. В зоне флюса на ней видны выраженные изменения, визуально похожие на признаки перехода к следующей стадии. Из-за этого модель и конечный автомат иногда преждевременно переходят к «flux_activation» или иначе интерпретируют ранние изменения. Запись из анализа не исключалась — она оставлена как пример сложного сценария и используется для оценки устойчивости системы.

Пример сложного визуального сценария — с неоднозначными изменениями флюса и бликами — приведён на рисунке 3.10.




Рисунок 3.10 — Пример *hard-case* видеозаписи MVI_6265 со сложными визуальными условиями

Без сложной видеозаписи MVI_6265 метрики заметно выше. На штатных видео модель распознаёт стадии устойчивее, а конечный автомат формирует технологически согласованную последовательность без заметных ранних ложных переходов. Это показывает работоспособность архитектуры

— заметная часть ошибок связана не с несостоятельностью метода, а с отдельными сложными визуальными сценариями.

Сложные примеры остаются полезными: они показывают, где системе нужна дополнительная защита — адаптивная настройка ROI, контроль качества изображения, несколько ракурсов, дополнительный температурный канал или более строгая логика подтверждения перехода. В промышленной версии такие случаи разумно выделять отдельно: переходом в режим повышенной осторожности или формированием сигнала «требуется внимание оператора».

Отдельное ограничение — невозвратная логика конечного автомата. Запрет обратных переходов хорошо подавляет хаотичные скачки, но, если переход подтверждён ошибочно, автомат не выполнит обратный переход. Направления для следующей версии — режим неопределённости, confidence-based подтверждение перехода и проверка по нескольким независимым признакам.

Ещё одно ограничение — привязка измерения задержки к конкретному вычислительному окружению. В работе получены оценки задержки в использованной вычислительной среде, в CPU- и GPU-режимах; на целевом промышленном компьютере значения будут иными. Поэтому полученные результаты измерения задержки — подтверждение принципиальной возможности работать в режиме, близком к реальному времени, а не окончательная характеристика любого оборудования. [16]

Также следует учитывать, что демонстрационный «Hold Temperature» — рекомендательный сигнал. Чтобы включить такой сигнал в реальный контур управления, потребуются испытания, синхронизация видеоданных с температурной телеметрией и проверка устойчивости системы на расширенном наборе видеозаписей в разных производственных условиях.

В целом основные ограничения — объём данных, визуальный характер разметки, отсутствие синхронной температурной телеметрии, влияние сложных видеозаписей и привязка производительности к оборудованию. Эти

ограничения не отменяют основной результат: прототип показывает, что видеоданные применимы для определения стадии индукционной пайки и выделения события начала активной пайки. Основные направления дальнейшего развития — больше видеозаписей, синхронизация с температурной телеметрией и адаптация к разным аппаратным платформам.

3.11. Выводы

В третьей главе экспериментально оценён разработанный модуль машинного зрения для анализа процесса индукционной пайки волноводных трактов. Проверке подвергались базовый OpenCV-подход, нейросетевые классификаторы стадий, алгоритм стабилизации, триггер начала активной пайки, демонстрационный режим и задержка обработки кадра.

Первичный OpenCV baseline фиксирует визуальные изменения в зоне пайки лишь частично — этого недостаточно для надёжной классификации всех четырёх стадий. После временного сглаживания он имеет accuracy 0,6296, macro-F1 0,5809 и weighted-F1 0,6964. Это стало основанием перейти к нейросетевым моделям — они сами строят более сложные пространственные признаки.

На 3 FPS нейросетевой baseline показал более высокое качество, чем OpenCV-подход. ResNet18 показала accuracy 0,9347, macro-F1 0,8489 и weighted-F1 0,9307 — это подтвердило применимость свёрточных сетей к определению визуальных стадий пайки. Одновременно эксперимент на 3 FPS выявил предел низкой частоты кадров для коротких переходных стадий.

Финальная нейросетевая классификация выполнена на 10 FPS. По валидации лучшей оказалась ResNet18 base; на тестовой выборке — accuracy 0,8747, macro-F1 0,8209, weighted-F1 0,8895; после temporal smoothing — 0,8776, 0,8290 и 0,8926 соответственно. При исключении сложной видеозаписи MVI_6265 качество заметно возрастает: raw predictions — 0,9598 / 0,9175 / 0,9573; majority smoothing — 0,9624 / 0,9234 / 0,9601. Снижение качества на полном наборе, таким образом, обусловлено не общим методом, а

отдельными сложными сценариями.

Стабилизация операторской стадии выполнялась с помощью конечного автомата. Majority smoothing немного превосходил по покадровым метрикам, но технологически допустимую последовательность и запрет обратных переходов обеспечивал только конечный автомат. Без сложной видеозаписи MVI_6265 state machine v1 показал accuracy 0,9581, macro-F1 0,9155 и weighted-F1 0,9562. Поэтому «Stable Stage» в финальной демонстрационной системе формирует именно state machine v1 — компромисс между метриками и операторской логикой.

Задача обнаружения «active_brazing_started» проверялась отдельно. Лучший основной результат — у нейросетевого триггера на $P(active_brazing)$: при пороге 0,4 и подтверждении 1 кадром событие зафиксировано на всех тестовых видео; средняя абсолютная ошибка по времени — 0,70 с, доля видео с ошибкой не более 1 секунды — 100%. OpenCV-триггер остаётся работоспособным, но даёт больше ранних срабатываний и потому оставлен как резервный объяснимый сигнал.

Оценка задержки показала: стандартная ResNet18 на входе 224×224 не укладывается в 50 мс на кадр на CPU. MobileNetV3 Small и ResNet18 с входом 64×64 этому ограничению удовлетворяют: p95 у ResNet18 64×64 после дообучения — около 39,8 мс, у MobileNetV3 Small — около 38,9 мс. То есть целевое требование по задержке выполнимо при использовании модели для запуска на центральном процессоре или GPU.

Эксперименты для запуска на центральном процессоре показали: уменьшение входного разрешения и облегчённые архитектуры позволяют запускать систему на центральном процессоре. ResNet18 64×64 после дообучения показала accuracy 0,9174 и macro-F1 0,8328 при p95 задержки ниже 50 мс.

Эволюционный подбор классификационной головы и гиперпараметров MobileNetV3 Small показал, что качество компактной модели зависит не только от learning rate, веса класса и размера входа, но и от формы верхней

части сети. Лучшей конфигурацией стала `mobilenet_arch_evo_039` с двухслойной MLP-головой, `avg_max pooling`, активацией `hardswish` и полным дообучением `backbone`-части. На тестовом разбиении она достигла $\text{accuracy} = 0,9013$, $\text{macro-F1} = 0,7792$, $\text{weighted-F1} = 0,8942$ и «`active_brazing`» $\text{F1} = 0,5988$. При этом дополнительное дообучение пяти лучших конфигураций на 30 эпох не дало устойчивого улучшения: часть моделей лучше выглядела на валидационной выборке, но хуже переносилась на тестовую выборку.

Демонстрационный режим подтвердил работоспособность системы как целостного прототипа. В демонстрационном видео выводятся сырая стадия, стабилизированная стадия, вероятность «`active_brazing`», состояния триггеров, сигнал «`Hold Temperature`», время инференса и область интереса — такого набора достаточно, чтобы сопоставлять работу алгоритма с фактическим ходом процесса пайки.

В итоге экспериментальная оценка подтвердила основные положения работы:

1. Нейросетевой подход существенно превосходит `OpenCV baseline` в задаче классификации стадий.
2. Использование датасета 10 FPS улучшает представление коротких стадий процесса.
3. Конечный автомат необходим для формирования технологически согласованной операторской стадии.
4. Событие начала активной пайки может быть выделено на основе вероятности $P(\text{active_brazing})$.
5. `CV-Trigger` может использоваться как дополнительный объяснимый резервный сигнал.
6. Ограничение 50 мс на кадр достижимо при выборе модели для запуска на центральном процессоре или использовании GPU.
7. Созданный прототип может использоваться как основа для дальнейшего развития системы визуального контроля индукционной пайки.

По итогам экспериментов модуль машинного зрения распознаёт визуальные стадии процесса индукционной пайки, выделяет событие начала активной пайки и работает в режиме, близком к реальному времени. Обозначенные ограничения — небольшой объём видеоданных, отсутствие синхронной температурной телеметрии и наличие сложных записей — задают направление дальнейшего развития и расширения прикладной применимости системы.

ЗАКЛЮЧЕНИЕ

В выпускной квалификационной работе разработан и исследован прототип модуля машинного зрения для индукционной пайки волноводных трактов космических аппаратов. По видеопотоку он определяет этапы технологического процесса и формирует сигнал начала активной пайки, дополняя температурный контроль независимой визуальной оценкой состояния зоны пайки. [4]

Цель выпускной квалификационной работы достигнута. Разработан и экспериментально исследован прототип модуля машинного зрения, который по видеоинформации из зоны пайки определяет этапы технологического процесса индукционной пайки волноводных трактов космических аппаратов, стабилизирует результат с учётом технологической последовательности и формирует событие начала активной пайки. Полученные результаты подтверждают возможность обеспечения высокой эффективности процесса индукционной пайки за счёт повышения точности определения этапов технологического процесса на основе видеоинформации из зоны пайки и закладывают основу для дальнейшего развития автоматизированных систем поддержки управления процессом пайки.

Технологический процесс индукционной пайки рассмотрен и формализован в четырёх визуально различимых стадиях: подготовка и предварительный нагрев, активация флюса, активная пайка и стабилизация. Отдельно выделено событие начала активной пайки, привязанное к плавлению и протеканию припоя. На его основе формируется рекомендательный сигнал фиксации температуры.

Для экспериментов собран размеченный видеодатасет процесса пайки. Для видеозаписей выполнена интервальная разметка, далее эта разметка преобразовывалась в покадровую выборку. Подготовлено два датасета — 3 FPS и 10 FPS; разбиение train/val/test выполнялось по идентификатору видеозаписи, и близкие соседние кадры не попадают одновременно в разные

выборки, а оценка качества остаётся корректной.

На первом экспериментальном этапе реализован базовый подход на OpenCV-признаках и классических моделях машинного обучения. Он позволил проверить интерпретируемые признаки изображения — яркость, цвет, блики, текстуру, контуры и межкадровую динамику. По метрикам OpenCV baseline ограничен в распознавании стадий, и именно это стало основанием перейти к нейросетевым моделям.

Главным инструментом определения стадии стали свёрточные сети. Сравнивались ResNet18 и MobileNetV3 Small; нейросетевой baseline на 3 FPS подтвердил преимущество над OpenCV baseline. Финальная модель обучена на 10 FPS, где короткие переходные стадии представлены полнее. На тестовой выборке финальная ResNet18 показала accuracy 0,8747, macro-F1 0,8209, weighted-F1 0,8895; без сложной видеозаписи MVI_6265 — 0,9598, 0,9175 и 0,9573.

Для устойчивости операторского отображения разработан конечный автомат стадий. Он удерживает технологически допустимый порядок и блокирует обратные переходы. На штатных видео без сложной видеозаписи MVI_6265 state machine v1 показал accuracy 0,9581, macro-F1 0,9155 и weighted-F1 0,9562. Этот же алгоритм формирует «Stable Stage» в финальной системе.

Отдельно решена задача обнаружения события начала активной пайки. Триггер основан на вероятности класса «active_brazing» у нейросетевой модели (порог 0,4, подтверждение 1 кадром). Событие зафиксировано на всех тестовых видеозаписях; средняя абсолютная ошибка времени срабатывания — 0,70 с, доля срабатываний с ошибкой не более 1 секунды — 100 %. Резервный OpenCV-триггер проверен как объяснимый дополнительный сигнал; в финальной архитектуре «Hold Temperature» формирует именно нейросетевой триггер. [12] [15]

Оценка задержки обработки кадра показала: стандартная ResNet18 на входе 224×224 в 50 мс на кадр на CPU не укладывается. На GPU или моделях

для запуска на центральном процессоре ограничение достижимо: MobileNetV3 Small и ResNet18 с входом 64×64 удержали p95 ниже 50 мс. ResNet18 64×64 после дообучения показала accuracy 0,9174 и mAP-F1 0,8328 при p95 около 39,8 мс. Это подтверждает применимость разработанной системы на центральном процессоре.

Итоговый программный результат — воспроизводимый прототип: скрипты подготовки данных, извлечения признаков, обучения и оценки моделей, построения демонстрационного видео и измерения задержки. Демонстрационное видео отображает сырую стадию, стабилизированную стадию, вероятность активной пайки, состояния триггеров, сигнал «Hold Temperature», время инференса и область интереса; этого достаточно, чтобы убедиться в работоспособности системы как целостного прототипа визуального контроля.

Практическая ценность прототипа состоит в поддержке оператора, использовании его как исследовательского инструмента для анализа видеозаписей пайки и как основы для дальнейшего развития автоматизированных систем контроля. Прототип не заменяет температурные датчики — он работает совместно с ними как дополнительный визуальный канал, повышающий надёжность совместного контроля процесса.

Главные ограничения работы — небольшой объём видеоданных, визуальный характер разметки, отсутствие синхронной температурной телеметрии и наличие видеозаписей со сложными условиями наблюдения. Для перехода к промышленному применению необходимы испытания на целевом оборудовании, расширение датасета, синхронизация видеоданных с температурными измерениями и более строгая обработка сложных визуальных сценариев.

Перспективными направлениями дальнейшей работы являются:

1. Расширение набора видеоданных и включение новых технологических сценариев;

2. Синхронизация видеопотока с температурной телеметрией и мощностью индуктора;
3. Обучение отдельной или многозадачной модели для прямого формирования сигнала фиксации температуры;
4. Применение ONNX Runtime, квантования и других методов ускорения инференса; [16] [27]
5. Автоматическое определение области интереса;
6. Проверка системы на промышленном стенде и целевом вычислительном оборудовании;
7. Разработка более устойчивой логики обработки сложных сценариев.

Проведённое исследование демонстрирует, что визуальные признаки процесса индукционной пайки могут быть использованы для автоматического определения этапов пайки и формирования события начала активной пайки в режиме, близком к реальному времени. Этот результат формирует основу для дальнейшего развития интеллектуальных систем поддержки контроля и управления технологическими процессами пайки.

СПИСОК ЛИТЕРАТУРЫ

- [1] С. К. Злобин, М. М. Михнев, В. Д. Лаптенко, Ю. Н. Серегин, А. Н. Бочаров, В. С. Тынченко, Ю. П. Дубец и Б. Б. Долгополов, «Автоматизированное оборудование и технология для пайки волноводных трактов космических аппаратов,» *Вестник Сибирского государственного аэрокосмического университета им. академика М.Ф. Решетнева*, № 4(56), р. 219–229, 2014.
- [2] С. К. Злобин, М. М. Михнев, В. Д. Лаптенко, А. Н. Бочаров и Б. Б. Долгополов, «Особенности производства волноводно-распределительных трактов антенно-фидерных устройств космических аппаратов,» *Вестник Сибирского государственного аэрокосмического университета им. академика М.Ф. Решетнева*, № 6(52), р. 196–201, 2013.
- [3] С. К. Злобин, В. Д. Лаптенко, М. М. Михнев и Р. В. Зайцев, «Применение индукционного нагрева при пайке элементов волноводно-распределительных трактов из алюминиевых сплавов,» *Решетневские чтения*, т. 1, р. 14–15, 2013.
- [4] А. В. Мурыгин, Ю. Н. Серегин, В. С. Тынченко, А. Н. Бочаров и О. А. Бочарова, *Автоматизированная пайка методом индукционного нагрева: монография*, Красноярск: Изд-во СибГУ им. М.Ф. Решетнева, 2022.
- [5] В. С. Тынченко, В. Е. Петренко и А. В. Милов, «Управление индукционной пайкой на основе косвенных измерений температуры процесса,» *Системы управления и информационные технологии*, № 4(78), р. 50–54, 2019.

- [6] А. В. Милов, В. С. Тынченко и А. В. Мурыгин, «Влияние флюса на точность измерений в процессе индукционной пайки алюминиевых волноводных трактов», *Современные технологии. Системный анализ. Моделирование*, т. 60, № 4, p. 38–46, 2018.
- [7] V. S. Tynchenko, V. E. Petrenko и A. V. Murygin, «Control of the induction soldering on the basis of process temperature indirect measurements», *MATEC Web of Conferences*, т. 224, p. 01054, 2018.
- [8] Z. Li, Y. Yan, X. Wang, Y. Ge и L. Meng, «A survey of deep learning for industrial visual anomaly detection», *Artificial Intelligence Review*, т. 58, p. Article 279, 2025.
- [9] V. S. Shukla, A. S. Shukla, S. P. S. K. и S. S. Shukla, «A systematic survey: role of deep learning-based image anomaly detection in industrial inspection contexts», *Frontiers in Robotics and AI*, № DOI: 10.3389/frobt.2025.1554196, 2025.
- [10] R. Szeliski, *Computer Vision: Algorithms and Applications* 2nd ed., Cham: Springer, 2022.
- [11] I. Goodfellow, Y. Bengio и A. Courville, *Deep Learning*, Cambridge: MIT Press, 2016.
- [12] K. He, X. Zhang, S. Ren и J. Sun, «Deep Residual Learning for Image Recognition», *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, p. 770–778, 2016.
- [13] A. Paszke и e. al., «PyTorch: An Imperative Style, High-Performance Deep Learning Library», *Advances in Neural Information Processing Systems*, т. 32, 2019.
- [14] G. Bradski, «The OpenCV Library», *Dr. Dobb's Journal of Software Tools*, 2000.

- [15] A. Howard, M. Sandler, G. Chu, L.-C. Chen, B. Chen, M. Tan, W. Wang, Y. Zhu, R. Pang, V. Vasudevan, Q. V. Le и H. Adam, «Searching for MobileNetV3,» *Proceedings of the IEEE/CVF International Conference on Computer Vision*, p. 1314–1324, 2019.
- [16] D. Ngo, H.-C. Park и B. Kang, «Edge Intelligence: A Review of Deep Neural Network Inference in Resource-Limited Environments,» *Electronics*, т. 14, № 12, p. Article 2495, 2025.
- [17] Н. Ф. Лашко и С. В. Лашко, Пайка металлов, Москва: Машиностроение, 1988.
- [18] В. С. Тынченко, А. В. Милов и С. О. Курашкин, «Автоматизированная система тестирования алгоритмов управления процессом индукционной пайки волноводных трактов,» *Промышленные АСУ и контроллеры*, № 1, p. 3–13, 2021.
- [19] В. С. Тынченко и С. О. Курашкин, «Автоматизированная система оптимального управления индукционной пайкой волноводных трактов космических аппаратов,» *Приборы и системы. Управление, контроль, диагностика*, № 1, p. 22–34, 2021.
- [20] В. С. Тынченко, В. Д. Лаптенко, В. Е. Петренко, А. В. Мурыгин и А. В. Милов, «Система автоматизации индукционной пайки на основе двух контуров управления с позиционированием заготовки,» *Программные продукты и системы*, № 32(1), p. 167–173, 2019.
- [21] F. Pedregosa и e. al., «Scikit-learn: Machine Learning in Python,» *Journal of Machine Learning Research*, т. 12, p. 2825–2830, 2011.
- [22] А. В. Милов, В. С. Тынченко и С. О. Курашкин, «Применение коллектива искусственных нейронных сетей для управления индукционной пайкой волноводных трактов космических

аппаратов,» *Интеллектуальные системы*, т. 19, № 2, p. 72–82, 2021.

- [23] A. V. Milov, V. S. Tynchenko, S. O. Kurashkin, V. V. Tynchenko, V. V. Kukartsev, V. V. Bukhtoyarov, R. Sergienko, V. A. Kukartsev и K. A. Bashmur, «The use of collections of artificial neural networks to improve the control quality of the induction soldering process,» *Sensors*, т. 21, № 12, p. 4199, 2021.
- [24] C. Shorten и T. M. Khoshgoftaar, «A survey on Image Data Augmentation for Deep Learning,» *Journal of Big Data*, т. 6, № 60, 2019.
- [25] I. Loshchilov и F. Hutter, «Decoupled Weight Decay Regularization,» в *International Conference on Learning Representations*, 2019.
- [26] A. V. Milov, V. S. Tynchenko и A. V. Murygin, «Neural network modeling to control process of induction soldering,» *2019 International Conference on Industrial Engineering, Applications and Manufacturing, ICIEAM 2019*, p. 8743031, 2019.
- [27] Microsoft, «Quantize ONNX models,» 2025. [В Интернете]. Available: <https://onnxruntime.ai/docs/performance/model-optimizations/quantization.html>. [Дата обращения: 3 Апрель 2026].
- [28] А. В. Милов и В. С. Тынченко, «Методы интеллектуального управления индукционной пайкой волноводных трактов космических аппаратов,» *Промышленные АСУ и контроллеры*, № 11, p. 18–29, 2019.
- [29] V. S. Tynchenko, S. O. Kurashkin, V. V. Tynchenko, V. V. Bukhtoyarov, V. V. Kukartsev, R. B. Sergienko, A. V. Kukartsev и К. А. Башмур, «Mathematical modeling of induction heating of waveguide path assemblies during induction soldering,» *Metals*, т. 11,

№ 5, p. 697, 2021.

- [30] V. S. Tynchenko, A. V. Milov, V. V. Kukartsev, V. V. Tynchenko, V. V. Bukhtoyarov и К. А. Bashmur, «Algorithms for selecting the operating mode of the technological process of waveguide paths induction brazing,» *Journal of Applied Engineering Science*, т. 19, № 2, p. 424–431, 2021.
- [31] A. V. Milov, V. S. Tynchenko, S. O. Kurashkin, V. E. Petrenko, D. V. Rogova и Y. A. Tynchenko, «The induction heating process modelling of the waveguide paths' flanges,» *IOP Conference Series: Materials Science and Engineering*, т. 1047, № 1, p. 012027, 2021.
- [32] М. М. Михнев, С. К. Злобин, В. Д. Лаптенко, В. С. Тынченко, А. В. Мурыгин, Ю. Н. Серегин и А. Н. Бочаров, «Способ пайки волноводных трактов». Российская Федерация Патент 2647964, 17 Август 2017.
- [33] Н. Д. Короткий, «Детектирование сетевого трафика на наличие угроз с помощью машинного обучения,» *BSU Digital Library*, 2025.

ПРИЛОЖЕНИЕ А. СТРУКТУРА РЕПОЗИТОРИЯ ПРОЕКТА




Рисунок А.1 — Структура репозитория проекта BrazingSense

ПРИЛОЖЕНИЕ Б. КОМАНДЫ ЗАПУСКА ПРОГРАММНОГО ПРОТОТИПА

В приложении Б приведены основные команды запуска скриптов, использованных при подготовке данных, построении baseline, запуске финальной демонстрационной системы и измерении задержки обработки кадра. Команды предполагают запуск из корневой директории репозитория BrazingSense. Для скриптов, использующих модули из каталога `src/`, перед запуском указывается переменная окружения `PYTHONPATH=src`.

Б.1. Получение информации о видеозаписи

Скрипт `scripts/video_info.py` используется для просмотра технических параметров исходной видеозаписи: частоты кадров, количества кадров и длительности ролика.

```
python3 scripts/video_info.py data/raw/MVI_6265.MOV
```

Б.2. Создание шаблона интервальной разметки

Скрипт `scripts/create_empty_stage_annotations.py` создаёт шаблон файла интервальной разметки `data/annotations/stage_intervals.csv` на основе видеозаписей из каталога `data/raw/` и списка стадий из `configs/stages.yaml`.

```
python3 scripts/create_empty_stage_annotations.py
```

После выполнения команды в файл разметки добавляются строки для каждой видеозаписи и каждой стадии процесса. Значения `start_s` и `end_s` затем заполняются вручную по результатам просмотра видеозаписей.

Б.3. Формирование временной сетки для одного видео

Скрипт `scripts/make_time_grid.py` используется для формирования изображения с кадрами видеозаписи в заданном временном диапазоне. Такая сетка применялась при просмотре переходов между стадиями и уточнении интервальной разметки.

```
python3 scripts/make_time_grid.py \  
--video data/raw/MVI_6265.MOV \  

```

```
--out reports/figures/grid/MVI_6265_grid.png \  
--start 25 \  
--end 45 \  
--step 1 \  
--scale 0.5 \  
--crop 360,260,900,610
```

Параметр `--crop` задаёт область кадра в формате `x1,y1,x2,y2`. Если требуется построить сетку по полному кадру, параметр `--crop` можно не указывать.

Б.4. Формирование временных сеток для набора видео

Скрипт `scripts/make_time_grid_all.py` запускает построение временных сеток для всех видеозаписей из каталога `data/raw/`.

```
python3 scripts/make_time_grid_all.py \  
--raw-dir data/raw \  
--out-dir reports/figures/grid \  
--start 25 \  
--end 45 \  
--step 1 \  
--scale 0.5 \  
--crop 360,260,900,610 \  
--skip-existing
```

Параметр `--skip-existing` позволяет не пересоздавать уже сформированные изображения.

Б.5. Извлечение кадров и формирование покадровой разметки

Скрипт `scripts/build_frame_dataset.py` преобразует интервальную разметку стадий в покадровую выборку. На вход подаётся файл `stage_intervals.csv`, а на выходе формируются извлечённые кадры и таблица `frame_labels`.

Пример для датасета 10 FPS:

```
python3 scripts/build_frame_dataset.py \  
--intervals data/annotations/stage_intervals.csv \  
--skip-existing
```

```
--output-frames data/processed/frames_10 \  
--output-labels data/annotations/frame_labels_10.csv \  
--fps 10 \  
--save-stats data/annotations/frame_dataset_stats_10.json \  
--overwrite
```

Б.6. Разбиение датасета на train, val и test

Скрипт `scripts/split_frame_dataset.py` выполняет разбиение покадровой выборки на обучающую, валидационную и тестовую части по `video_id`. Такой подход исключает попадание соседних кадров одного видео одновременно в обучение и тест.

Пример для датасета 10 FPS:

```
python3 scripts/split_frame_dataset.py \  
--labels data/annotations/frame_labels_10.csv \  
--output-dir data/annotations/splits_10 \  
--blacklist data/annotations/blacklist.txt \  
--train-ratio 0.70 \  
--val-ratio 0.15 \  
--test-ratio 0.15 \  
--seed 42 \  
--overwrite
```

Б.7. Расчёт OpenCV-признаков

Скрипт `scripts/analyze_cv_features.py` рассчитывает классические признаки компьютерного зрения по ROI-кадрам и формирует табличный датасет признаков. Эти признаки использовались при построении OpenCV baseline и резервного OpenCV-триггера.

Пример для датасета 10 FPS:

```
python3 scripts/analyze_cv_features.py \  
--labels data/annotations/frame_labels_10.csv \  
--output-csv reports/cv_features_10/frame_features_roi.csv \  
--summary-csv reports/cv_features_10/summary_by_stage_roi.csv \  
--figures-dir reports/figures/cv_features_10 \  

```

```
--roi 470,280,430,290 \  
--overwrite
```

Б.8. Запуск демонстрационного видео с нейросетевой моделью

Скрипт `scripts/run_neural_inference_video.py` запускает полный конвейер обработки видеозаписи: выделение ROI, классификацию стадии, стабилизацию через конечный автомат, формирование триггера начала активной пайки и сохранение демонстрационного видео с наложением служебной информации.

Пример запуска для ResNet18:

```
PYTHONPATH=src python3 scripts/run_neural_inference_video.py \  
--video data/raw/MVI_6266.MOV \  
--checkpoint  
models/checkpoints/final_neural_stage_classification_10/resnet18  
_10fps_balanced_best_10fps.pt \  
--output reports/demo/MVI_6266_ResNet18_224.mp4 \  
--model resnet18 \  
--roi 470,280,430,290 \  
--image-size 224 \  
--postprocess state_machine \  
--trigger-threshold 0.4 \  
--trigger-confirm-frames 1 \  
--device cuda
```

Пример запуска для MobileNetV3 Small с эволюционно подобранной классификационной головой:

```
PYTHONPATH=src python3 scripts/run_neural_inference_video.py \  
--video data/raw/MVI_6266.MOV \  
--checkpoint  
models/checkpoints/mobilenet_architecture_evolution/mobilenet_ar  
ch_evo_039_best.pt \  
--output reports/demo/MVI_6266_MobileNet_224H_CPU.mp4 \  
--model mobilenet_v3_small_architecture_evo \  
--roi 470,280,430,290 \  
--image-size 224 \  

```



```
--postprocess state_machine \  
--trigger-threshold 0.2 \  
--trigger-confirm-frames 1 \  
--device cpu
```

Б.9. Запуск демонстрационного видео с OpenCV-триггером

Скрипт `scripts/run_neural_inference_video.py` также поддерживает опциональный OpenCV-триггер, который используется как диагностический или резервный канал.

```
PYTHONPATH=src python3 scripts/run_neural_inference_video.py \  
--video data/raw/MVI_6266.MOV \  
--checkpoint  
models/checkpoints/final_neural_stage_classification_10/resnet18  
_10fps_balanced_best_10fps.pt \  
--output reports/demo/MVI_6266_ResNet18_224.mp4 \  
--model resnet18 \  
--roi 470,280,430,290 \  
--image-size 224 \  
--postprocess state_machine \  
--trigger-threshold 0.4 \  
--trigger-confirm-frames 1 \  
--enable-cv-trigger \  
--cv-threshold 0.38 \  
--cv-confirm-frames 2 \  
--device auto
```

Б.10. Измерение задержки обработки кадра

Скрипт `scripts/benchmark_neural_latency.py` измеряет задержку полного цикла обработки кадра: чтения кадра, выделения ROI, предобработки изображения, инференса модели, работы триггеров и постобработки.

Пример измерения задержки для ResNet18:

```
PYTHONPATH=src python3 scripts/benchmark_neural_latency.py \  
--video data/raw/MVI_6266.MOV \  
--checkpoint
```

```
models/checkpoints/final_neural_stage_classification_10/resnet18
_10fps_balanced_best_10fps.pt \
  --model resnet18 \
  --roi 470,280,430,290 \
  --image-size 224 \
  --postprocess state_machine \
  --trigger-threshold 0.4 \
  --trigger-confirm-frames 1 \
  --device cpu \
  --output reports/neural_latency/MVI_6266_resnet18_latency.csv \
  --summary-output
reports/neural_latency/MVI_6266_resnet18_summary.json
```

Пример измерения задержки для MobileNetV3 Small с эволюционно подобранной классификационной головой:

```
PYTHONPATH=src python3 scripts/benchmark_neural_latency.py \
  --video data/raw/MVI_6266.MOV \
  --checkpoint
models/checkpoints/mobilenet_architecture_evolution/mobilenet_ar
ch_evo_039_best.pt \
  --model mobilenet_v3_small_architecture_evo \
  --roi 470,280,430,290 \
  --image-size 224 \
  --postprocess state_machine \
  --trigger-threshold 0.2 \
  --trigger-confirm-frames 1 \
  --device cpu \
  --output
reports/neural_latency/MVI_6266_mobilenet_arch_evo_039_latency.c
sv \
  --summary-output
reports/neural_latency/MVI_6266_mobilenet_arch_evo_039_summary.j
son
```

ПРИЛОЖЕНИЕ В. ДОПОЛНИТЕЛЬНЫЕ ЭКСПЕРИМЕНТАЛЬНЫЕ АРТЕФАКТЫ

В.1. Структура и распределение данных в сформированном датасете




Рисунок В.1 — Распределение кадров стадий процесса пайки по видеозаписям для 3FPS




Рисунок В.2 — Распределение длительности интервалов стадий процесса пайки

В.2. Анализ области интереса при обработке видеок кадров




Рисунок В.3 — Примеры выделения области интереса на кадрах видеозаписей процесса пайки




Рисунок В.4 — Сравнение разделимости стадий по OpenCV-признакам для полного кадра и области интереса

В.3. Анализ признаков и ошибок базового OpenCV-подхода




Рисунок В.5 — Важность OpenCV-признаков в модели Logistic Regression




Рисунок В.6 — Сравнение истинных и предсказанных стадий OpenCV baseline на 3 FPS для видеозаписи MVI_6265




Рисунок В.7 — Сравнение истинных и предсказанных стадий OpenCV baseline на 3 FPS для видеозаписи MVI_6266

В.4. Временной анализ предсказаний нейросетевого baseline




Рисунок В.8 — Сравнение истинных и предсказанных стадий ResNet18 baseline на 3 FPS для видеозаписи MVI_6265




Рисунок В.9 — Сравнение истинных и предсказанных стадий ResNet18 baseline на 3 FPS для видеозаписи MVI_6266

В.5. Подбор параметров конечного автомата

Таблица В.1 — Результаты подбора по сетке параметров алгоритма стабилизации стадий

min_confirm_framse	window_size	Accuracy	Macro-f1	Weighted-f1	active_brazing F1	active_brazing Recall
3	7	0.8493	0.8083	0.8714	0.8504	0.7398
3	10	0.8493	0.8083	0.8714	0.8504	0.7398
3	15	0.8493	0.8083	0.8714	0.8504	0.7398
3	20	0.8493	0.8083	0.8714	0.8504	0.7398
3	5	0.8482	0.8065	0.8703	0.8455	0.7398
5	10	0.8453	0.8007	0.8685	0.8353	0.7245
5	15	0.8453	0.8007	0.8685	0.8353	0.7245
5	20	0.8453	0.8007	0.8685	0.8353	0.7245
5	7	0.8441	0.7988	0.8674	0.8304	0.7245
5	5	0.8458	0.7935	0.8683	0.7988	0.6786
7	15	0.8412	0.7916	0.8654	0.8131	0.6990
7	20	0.8412	0.7916	0.8654	0.8131	0.6990

7	10	0.8395	0.7882	0.8640	0.8024	0.6837
7	7	0.8424	0.7869	0.8657	0.7868	0.6684
10	15	0.8354	0.7800	0.8612	0.7881	0.6735
10	20	0.8354	0.7800	0.8612	0.7881	0.6735
10	10	0.8285	0.7591	0.8543	0.7107	0.5765
15	20	0.8216	0.7538	0.8497	0.7289	0.6173
15	15	0.8164	0.7359	0.8441	0.6604	0.5357

В.6. Подбор параметров триггера начала активной пайки

Таблица В.2 — Результаты подбора по сетке параметров нейросетевого триггера начала активной пайки

threshold	confirm_frames	detected	early	late	MAE, s	max error, s	within 1s
0.2	7	3/3	0	3	0.7000	1.0000	1.0000
0.3	3	3/3	0	3	0.7000	1.0000	1.0000
0.3	5	3/3	0	3	0.7000	1.0000	1.0000
0.3	7	3/3	0	3	0.7000	1.0000	1.0000
0.4	1	3/3	0	3	0.7000	1.0000	1.0000
0.4	2	3/3	0	3	0.7000	1.0000	1.0000
0.4	3	3/3	0	3	0.7000	1.0000	1.0000
0.5	1	3/3	0	3	0.7000	1.0000	1.0000
0.5	2	3/3	0	3	0.7000	1.0000	1.0000
0.5	3	3/3	0	3	0.7000	1.0000	1.0000
0.6	1	3/3	0	3	0.7000	1.0000	1.0000
0.6	2	3/3	0	3	0.7000	1.0000	1.0000
0.6	3	3/3	0	3	0.7000	1.0000	1.0000
0.7	1	3/3	0	3	0.7333	1.0000	1.0000
0.7	2	3/3	0	3	0.7333	1.0000	1.0000
0.3	1	3/3	1	2	0.8000	1.3000	0.6667
0.3	2	3/3	1	2	0.8000	1.3000	0.6667
0.2	3	3/3	1	2	0.9000	1.6000	0.6667
0.2	5	3/3	1	2	0.9000	1.6000	0.6667
0.4	5	3/3	0	3	0.9667	1.7000	0.6667

В.7. Дополнительные результаты оптимизации моделей




Рисунок В.10 — Сравнение истинных и предсказанных стадий модели ResNet18 64×64 после fine-tune для видеозаписи MVI_6266

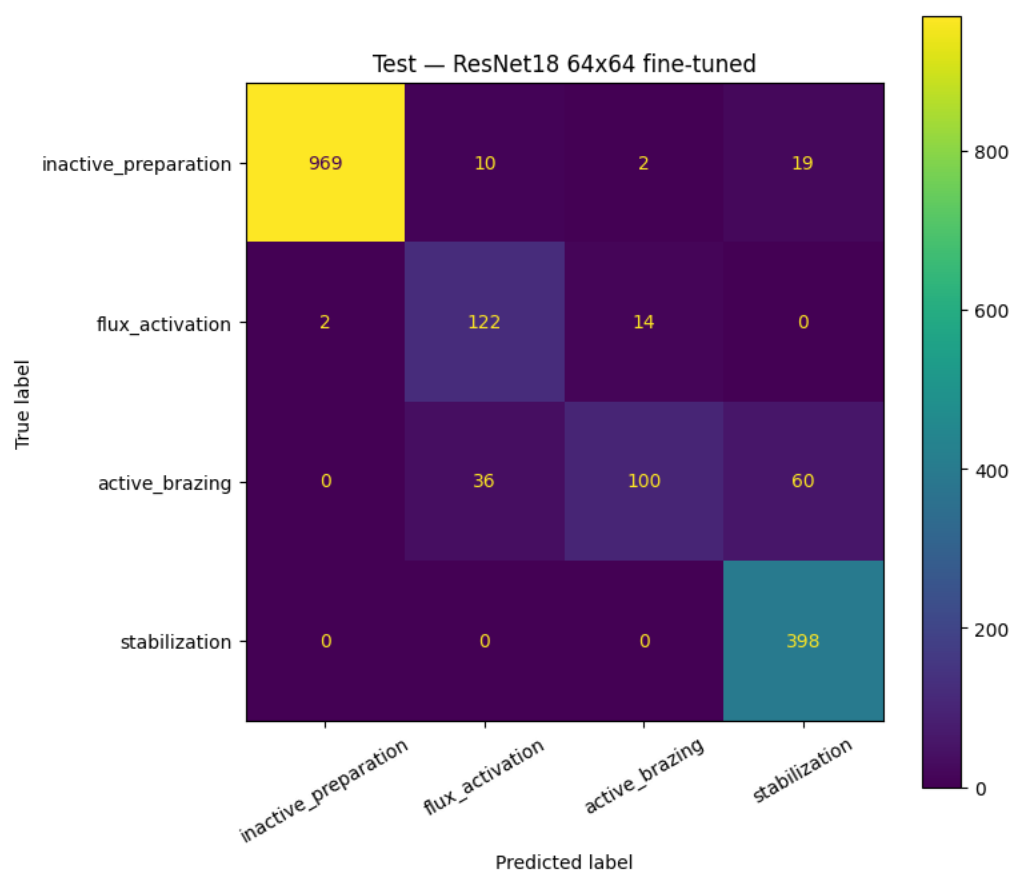


Рисунок В.11 — Матрица ошибок модели ResNet18 64×64 после fine-tune на тестовой выборке

Таблица В.3 — Результаты эволюционного подбора гиперпараметров MobileNetV3 Small

Кандидат	Image size	LR	Weight decay	Active brazing boost	Augmentation	Val macro-F1	Val active brazing F1
mobilenet_evo_005	224	0.0001	0.00030	1.2	low	0.9274	0.9104
mobilenet_evo_002	192	0.0001	0.00030	1.0	medium	0.9145	0.8951
mobilenet_evo_015	128	0.0003	0.00030	1.2	low	0.8877	0.9278
mobilenet_evo_009	128	0.0001	0.00030	1.2	medium	0.8968	0.8745
mobilenet_evo_008	128	0.0001	0.00030	1.2	low	0.8774	0.8550
mobilenet_evo_013	224	0.0001	0.00030	1.0	low	0.8842	0.8226
mobilenet_evo_019	128	0.0001	0.00001	1.2	low	0.8749	0.8370
mobilenet_evo_001	128	0.0003	0.00030	1.2	low	0.8635	0.8240
mobilenet_evo_006	224	0.0001	0.00010	2.0	low	0.8533	0.8000
mobilenet_evo_011	128	0.0001	0.00010	1.0	medium	0.8400	0.8414
mobilenet_evo_000	224	0.0001	0.00030	1.5	low	0.8607	0.7660
mobilenet_evo_004	160	0.0001	0.00001	1.0	low	0.8490	0.7914
mobilenet_evo_017	160	0.0003	0.00030	1.2	medium	0.8414	0.7755
mobilenet_evo_010	224	0.0001	0.00030	1.2	medium	0.8402	0.7742
mobilenet_evo_003	224	0.0001	0.00001	1.5	medium	0.8315	0.7846
mobilenet_evo_007	160	0.0003	0.00010	1.5	medium	0.7395	0.5407




Рисунок В.12 — Сравнение истинных и предсказанных стадий модели MobileNetV3 Small evo best-1 для видеозаписи MVI_6266

Таблица В.4 — Результаты эволюционного подбора конфигурации классификационной головы MobileNetV3 Small

Кандидат	Val macro- F1	Val active brazing F1	head type	head hidden	head bottle neck ratio	drop out	activation	pooling	head norm	freeze mode
mobilenet_arc h_evo_039	0.90 98	0.88 12	mlp_ 2	256	0.5	0.1	hards wish	avg_ max	none	full
mobilenet_arc h_evo_085	0.89 87	0.87 36	mlp_ 1	256	1.0	0.1	hards wish	avg	batch norm	full
mobilenet_arc h_evo_027	0.87 99	0.86 30	mlp_ 2	256	1.0	0.1	hards wish	avg	none	full
mobilenet_arc h_evo_047	0.89 02	0.83 33	mlp_ 1	256	1.0	0.1	hards wish	avg	none	full
mobilenet_arc h_evo_007	0.90 07	0.86 53	mlp_ 1	128	0.5	0.2	hards wish	avg	none	last_bl ocks
mobilenet_arc h_evo_025	0.88 87	0.85 19	mlp_ 1	128	0.5	0.1	hards wish	avg	none	full
mobilenet_arc h_evo_083	0.88 49	0.84 40	mlp_ 1	128	1.0	0.1	hards wish	avg	none	last_bl ocks
mobilenet_arc h_evo_057	0.89 09	0.83 94	mlp_ 1	128	0.5	0.2	relu	avg	batch norm	full
mobilenet_arc h_evo_050	0.86 11	0.82 91	mlp_ 2	128	0.5	0.2	hards wish	avg	none	full
mobilenet_arc h_evo_069	0.87 11	0.86 79	mlp_ 1	256	0.5	0.1	relu	avg	none	full
mobilenet_arc h_evo_065	0.87 56	0.82 99	mlp_ 1	256	0.5	0.3	hards wish	avg	batch norm	last_bl ocks
mobilenet_arc h_evo_059	0.87 53	0.83 16	mlp_ 1	256	1.0	0.1	relu	avg	batch norm	full
mobilenet_arc h_evo_023	0.84 73	0.81 96	mlp_ 1	512	1.0	0.1	hards wish	avg	none	full
mobilenet_arc h_evo_045	0.87 69	0.82 48	linear	256	0.5	0.1	relu	avg	none	full

mobilenet_arc	0.87	0.81	mlp_	256	0.5	0.1	hards	avg	none	full
h_evo_006	73	38	2				wish			




Рисунок B.13 — Сравнение истинных и предсказанных стадий модели *mobilenet_arch_evo_039* для видеозаписи *MVI_6266*